

การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนายภาวะช็อก  
ในแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น

Developing a Time Series Deep Learning Model to Predict Shock  
in ICU Patients at Srinagarind Hospital, Khon Kaen

นายธนบดี ภูมิคุรี รหัสประจำตัว 643020502-4

นายพุทธิพงศ์ ย่างนอก รหัสประจำตัว 643021268-1

รายงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรบริณญาณวิทยาศาสตรบัณฑิต  
หลักสูตรสถิติและวิทยาการข้อมูล วิชาเอกสถิติศาสตร์คณะวิทยาศาสตร์  
มหาวิทยาลัยขอนแก่น  
ปีการศึกษา 2567



การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนายภาวะช็อก

ในแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น

Developing a Time Series Deep Learning Model to Predict Shock

in ICU Patients at Srinagarind Hospital, Khon Kaen

นายธนบดี ภูชนครี

รหัสประจำตัว 643020502-4

นายพุทธิพงค์ ย่างนอก

รหัสประจำตัว 643021268-1

รายงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญาวิทยาศาสตรบัณฑิต

หลักสูตรสถิติและวิทยาการข้อมูล วิชาเอกสถิติศาสตร์คณะวิทยาศาสตร์

มหาวิทยาลัยขอนแก่น

ปีการศึกษา 2567

หัวข้อโครงการวิจัย  
การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนาย  
ภาวะซึ้งอก  
ในแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น

นักศึกษา  
นายธนบดี ภูมศรี รหัสประจำตัว 643020502-4  
นายพุทธิพงศ์ ย่างนกอ รหัสประจำตัว 643021268-1  
อาจารย์ที่ปรึกษา  
ดร.พิชญา วิรัชโฉติเสถียร

---

สาขาวิชาสถิติ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น อนุมัติให้รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษา<sup>1</sup>  
ตามหลักสูตรวิทยาศาสตรบัณฑิต (สถิติและวิทยาการข้อมูล)

.....อาจารย์ที่ปรึกษา

(ดร.พิชญา วิรัชโฉติเสถียร)

วันที่ 8 เดือน เม.ย. พ.ศ. 2568

.....หัวหน้าสาขาวิชาสถิติ

(ผศ.ดร.สุกัญญา เรืองสุวรรณ)

วันที่ 8 เดือน เม.ย. พ.ศ. 2568

หัวข้อโครงการวิจัย	การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนายภาวะซึ่อก	
	ในแผนกผู้ป่วยวิกฤตโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น	
นักศึกษา	นายธนบดี ภูชนครี	รหัสประจำตัว 643020502-4
	นายพุทธิพงศ์ ยางนกอก	รหัสประจำตัว 643021268-1
อาจารย์ที่ปรึกษา	ดร.พิชญา วิรัชโชคิสสีร	

## บทคัดย่อ

ภาวะซึ่อกเป็นภาวะที่พบบ่อยในผู้ป่วยที่เข้ารับการรักษาในห้องผู้ป่วยวิกฤต (Intensive Care Unit; ICU) และมีความสัมพันธ์กับอัตราการเสียชีวิตที่สูงทั่วโลก จากการศึกษาพบว่าภาวะซึ่อกเกิดขึ้นในผู้ป่วยที่เข้ารับการรักษาใน ICU ถึงร้อยละ 29.5 และมีอัตราการเสียชีวิตในโรงพยาบาลสูงถึงร้อยละ 35.3 เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะซึ่อกซึ่งมีอัตราการเสียชีวิตร้อยละ 16.7 การทำนายภาวะซึ่อกล่วงหน้าจึงมีความสำคัญอย่างยิ่งในการลดอัตราการเสียชีวิตและภาวะแทรกซ้อน งานวิจัยนี้ทำการศึกษากับผู้ป่วยใน ICU ที่โรงพยาบาลศринครินทร์ จังหวัดขอนแก่น โดยใช้ข้อมูลทุติยภูมิจากระบบ Smart-ICU ซึ่งรวมถึงข้อมูลทางประชาราศาสตร์ ประวัติการรักษา ผลการตรวจทางห้องปฏิบัติการ สัญญาณชีพ และสมุดสารน้ำในร่างกาย โดยศึกษาในผู้ป่วยที่มีอายุ 18 ปีขึ้นไป ที่เข้ารับการรักษาระหว่างวันที่ 15 ตุลาคม 2565 ถึง 3 กุมภาพันธ์ 2568 และต้องมีการเข้ารับการรักษาใน ICU อย่างน้อย 24 ชั่วโมง โดยภาวะซึ่อกจะถูกกำหนดจากเกณฑ์ อย่างได้อย่างหนึ่งดังนี้ ความดันโลหิตเฉลี่ย  $< 65$  มิลลิเมตรปอร์ท ความดันโลหิตซิสโตลิก  $< 90$  มิลลิเมตรปอร์ท หรือดัชนีซึ่อกของความดันโลหิต  $> 2$  โดยในการทำนายภาวะซึ่อก ผู้วิจัยได้ใช้เทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา (Time-Series Deep Learning) ที่มีความซับซ้อนสูง เช่น โครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Networks หรือ CNN) โครงข่ายหน่วยความจำระยะสั้นและยาว (Long Short-Term Memory Networks หรือ LSTM Networks) และ แบบจำลองทรานส์ฟอร์มเมอร์ (Transformer models) ผลการศึกษาพบว่าแบบจำลองแบบผสม CNN+LSTM ให้ผลลัพธ์ดีที่สุด โดยมีค่า AUC-ROC 0.89 และ AUC-PR 0.91 ซึ่งดีกว่าแบบจำลองเดียวแบบอื่น ๆ แสดงให้เห็นถึงความสามารถของแบบจำลองแบบผสมในการวิเคราะห์ทั้งลักษณะเชิงเวลาและเชิงพื้นที่ ทำให้การทำนายแม่นยำขึ้นอย่างมีนัยสำคัญ ซึ่งสามารถช่วยให้แพทย์วางแผนการรักษาได้อย่างเหมาะสมและทันเวลา

**คำสำคัญ :** ภาวะซึ่อก, แผนกผู้ป่วยวิกฤต (ICU), ข้อมูลอนุกรมเวลา, การเรียนรู้เชิงลึก, โครงข่ายประสาทแบบคอนโวลูชัน (CNN), โครงข่ายหน่วยความจำระยะสั้นและยาว (LSTM)

สาขาวิชาสังคม

ลายมือชื่อนักศึกษา.....

ปีการศึกษา 2567

(นายธนบดี ภูษมศรี)

ลายมือชื่อนักศึกษา.....

(นายพุทธิพงศ์ ยางนอกร)

ลายมือชื่ออาจารย์ที่ปรึกษา .....

(ดร.พิชญา วิรัชโจนติเสถียร)

<b>Title</b>	Developing a Time Series Deep Learning Model to Predict Shock in ICU Patients at Srinagarind Hospital, Khon Kaen
<b>Student</b>	Mr. Thanabodi Phuchomsi Student ID 643020502-4 Mr. Puttipong Yangnork Student ID 643021268-1
<b>Project Advisor</b>	Dr. Pitchaya Wiratchotisatian

## ABSTRACT

Shock is a common condition among patients admitted to the Intensive Care Unit (ICU) and is associated with high mortality rates worldwide. Studies have found that shock occurs in 29.5% of ICU patients, with a hospital mortality rate of 35.3% compared to 16.7% in patients without shock. Early prediction of shock is therefore crucial for reducing mortality and complications. This study investigates ICU patients at Srinagarind Hospital, Khon Kaen, Thailand, using secondary data from the Smart-ICU system. The dataset includes patient demographics, medical histories, laboratory results, vital signs, and fluid balance. The study focuses on patients aged 18 years or older, admitted between October 15, 2022, and February 3, 2025, with a minimum ICU stay of 24 hours. Shock was defined by at least one of the following criteria: mean arterial pressure < 65 mmHg, systolic blood pressure < 90 mmHg, or a diastolic shock index > 2. To predict shock, advanced time-series deep learning techniques were utilized, including Convolutional Neural Networks (CNN), Long Short-Term Memory (LSTM) networks, and Transformer models. The CNN+LSTM hybrid model achieved the best performance, with an AUC-ROC of 0.89 and an AUC-PR of 0.91, outperforming standalone models. This performance underscores the hybrid model's ability to integrate temporal and spatial features, significantly enhancing predictive accuracy. This study demonstrates the potential of using the CNN+LSTM hybrid model for predicting shock among ICU patients, which can be further developed into a real-time shock prediction system.

**Keywords :** Shock, Intensive Care Unit (ICU), Time-series data, Deep learning, Convolutional Neural Networks (CNN), Long Short-Term Memory (LSTM) networks

Department of Statistics  
Academic year 2024

Signature of student.....

(Mr.Thanabodi Phuchoms)

Signature of student.....

(Mr. Puttipong Yangnork)

Signature of project advisor.....

(Dr. Pitchaya Wiratchotisatian)

## กิตติกรรมประกาศ

คณะกรรมการพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลา เพื่อทำนายภาวะซื้อในแผนกผู้ป่วยวิกฤต โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ขอกราบขอบพระคุณผู้ร่วมวิจัยทุกท่านที่เป็นส่วนหนึ่งในการทำให้งานวิจัยสำเร็จสมบูรณ์ไปได้ด้วยดี และจากการได้รับความอนุเคราะห์ รวมทั้งการสนับสนุนเป็นอย่างดีจาก อ.ดร.พิชญา วิรัชโขติเสถียร อาจารย์ที่ปรึกษางานวิจัย ที่กรุณายิ่งช่วยเหลือ ชี้แนะ คอยผลักดัน และตรวจทานแก้ไขข้อบกพร่องเสมอมา จนกระทั่งงานวิจัยครั้งนี้สำเร็จเรียบร้อยด้วยดี ผู้วิจัยขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ ที่นี่

ขอขอบคุณสาขาวิชาสถิติ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น ที่อำนวยความสะดวก สถานที่ในการทำวิจัย และแพทย์ผู้เชี่ยวชาญในแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ ที่ได้ให้ความร่วมมือและสนับสนุนข้อมูลที่สำคัญเกี่ยวกับผู้ป่วยในแผนกผู้ป่วยวิกฤต ซึ่งเป็นข้อมูลที่มีความจำเป็นอย่างยิ่งในการทำวิจัย ขอขอบคุณสำนักเทคโนโลยีดิจิทัล มหาวิทยาลัยขอนแก่น ที่อนุญาตให้ใช้ HPC Server สำหรับการประมวลผลข้อมูล

สุดท้ายนี้ ต้องขอขอบคุณคณะกรรมการผู้วิจัยทุกท่านที่ตั้งใจสร้างสรรค์ผลงานอย่างสุดความสามารถ จนโครงการได้สำเร็จลุล่วงไปด้วยดีตามวัตถุประสงค์ ผู้วิจัยหวังว่างานวิจัยฉบับนี้จะเป็นประโยชน์สำหรับหน่วยงานที่เกี่ยวข้องและผู้ที่สนใจศึกษาต่อไป

ธนบดี ภูชนครี

พุทธิพงษ์ ยางนอกร

## สารบัญ

เรื่อง	หน้า
บทคัดย่อภาษาไทย	ก
บทคัดย่อภาษาอังกฤษ	ค
กิตติกรรมประกาศ	จ
<b>สารบัญ</b>	<b>ฉบับ</b>
สารบัญตาราง	ภู
สารบัญภาพ	ภู
<b>บทที่ 1 บทนำ</b>	<b>1</b>
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์ของการวิจัย	2
1.3 สมมติฐานการวิจัย	2
1.4 ขอบเขตของการวิจัย	2
1.5 นิยามศัพท์เฉพาะ	2
1.6 ประโยชน์ที่คาดว่าจะได้รับ	3
<b>บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง</b>	<b>4</b>
2.1 ทฤษฎีที่เกี่ยวข้อง	4
2.1.1 มาตรฐานการทำโครงการด้านการวิเคราะห์ข้อมูล และการทำเหมืองข้อมูล (Cross-Industry Standard Process for Data Mining; CRISP-DM)	4
2.1.2 ภาวะซื้อขาย	5
2.1.3 ทฤษฎีทางสถิติที่เกี่ยวข้อง	6
2.1.3.1 สถิติเชิงอนุมานสำหรับข้อมูลเชิงปริมาณ	10
2.1.3.2 สถิติเชิงอนุมานสำหรับข้อมูลเชิงคุณภาพ	10

## สารบัญ (ต่อ)

เรื่อง	หน้า
2.1.4 ข้อมูลสูญหาย (Missing Value)	11
2.1.4.1 การเติมค่าสูญหายด้วยวิธีการประมาณค่าเชิงเส้น (Linear Interpolation)	11
2.1.4.2 การเติมค่าสูญหายด้วยวิธี MissForest	12
2.1.5 เทคนิคการเรียนรู้เชิงลึก (Deep Learning; DL)	14
2.1.5.1 โครงข่ายประสาทเทียม (Artificial Neural Networks; ANN)	14
2.1.5.2 โครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Network; CNN)	18
2.1.5.3 หน่วยความจำระยะสั้นระยะยาว (Long Short-Term Memory; LSTM)	20
2.1.5.4 ทรานส์ฟอร์มเมอร์ (Transformer)	22
2.1.6 การป้องกัน Overfitting	24
2.1.7 Area Under the Receiver Operating Characteristics (AUC-ROC Curve)	26
2.1.8 Area Under the Precision-Recall Curve (AUC-PR Curve)	28
2.1.9 SHAP (Shapley Additive explanations)	29
2.2 งานวิจัยที่เกี่ยวข้อง	29
2.2.1 งานวิจัยที่เกี่ยวข้องกับการจัดการค่าสูญหาย	29
2.2.2 งานวิจัยที่เกี่ยวข้องกับแบบจำลองทำนายภาวะติดเชื้อในกระแสเลือดและภาวะซึ่อกจากการติดเชื้อ	31
2.3 กรอบแนวคิดการวิจัย	37
บทที่ 3 วิธีดำเนินการวิจัย	38
3.1 การกำหนดปัญหา (Business Understanding)	38

## สารบัญ (ต่อ)

เรื่อง	หน้า
3.2 การศึกษาทำความเข้าใจข้อมูล (Data Understanding)	38
3.2.1 ข้อมูลที่ใช้ในการวิเคราะห์	39
3.2.2 การวิเคราะห์ข้อมูล	41
3.3 การเตรียมข้อมูล (Data Preparation)	43
3.3.1 รวมข้อมูลผู้ป่วย	43
3.3.2 เลือกตัวแปร	43
3.3.3 Feature Engineering	43
3.3.4 จัดการค่าผิดปกติ และค่านอกเกณฑ์	44
3.3.5 จัดการแ感恩เวลาให้มีมิติที่เท่ากัน	46
3.3.6 การแยกตัวอย่างตามลักษณะของเวลา	47
3.3.7 จัดการค่าสูญหาย	47
3.3.8 ระบุจุดที่เกิดการซื้อขายของผู้ป่วย	47
3.3.9 คัดเลือกช่วงข้อมูล	47
3.3.10 สร้าง Labels สำหรับทำนาย	48
3.3.11 การปรับมาตรฐานข้อมูล (Standardization)	49
3.4 การสร้างแบบจำลอง (Modeling)	51
3.4.1 เครื่องมือที่ใช้ในการสร้างแบบจำลอง	51
3.4.2 การแบ่งชุดข้อมูลด้วย Stratified Group 5-fold Cross Validation	51
3.4.3 การสร้างแบบจำลองสำหรับการทำนายการเกิดภาวะซื้อขายด้วย Deep Learning	52
3.4.4 การใช้ Loss ในการปรับปรุงแบบจำลอง	55
3.4.5 การปรับแต่งและเพิ่มประสิทธิภาพของแบบจำลอง	55
3.5 การประเมินประสิทธิภาพของแบบจำลอง (Evaluation)	57
3.5.1 เครื่องมือที่ใช้ในการประเมินแบบจำลอง	57

## สารบัญ (ต่อ)

เรื่อง	หน้า
3.5.2 ข้อมูลที่ใช้ในการประเมินประสิทธิภาพแบบจำลอง	57
3.5.3 เกณฑ์ในการประเมินประสิทธิภาพแบบจำลอง	57
3.6 การนำไปใช้จริง (Deployment)	58
3.6.1 การแสดงผลบนเว็บแอปพลิเคชัน (Web Application)	58
บทที่ 4 ผลการวิจัย	59
4.1 ผลการศึกษาทำความเข้าใจข้อมูล	59
4.1.1 ข้อมูลที่ใช้วิเคราะห์	59
4.1.2 ผลการสำรวจ และวิเคราะห์ข้อมูล	60
4.2 ผลการเตรียมข้อมูล	66
4.2.1 การจัดการค่าผิดปกติ และค่านอกเกณฑ์	66
4.2.2 ผลการจัดการค่าสูญหาย	69
4.2.3 ผลการสร้างข้อมูลนำเข้า	70
4.3 ผลการสร้างแบบจำลอง	72
4.3.1 ผลการแบ่งชุดข้อมูลด้วย Stratified Group 5-Fold Cross Validation	72
4.3.2 ผลการหาค่าพารามิเตอร์ที่ดีที่สุดในแต่ละแบบจำลอง	73
4.3.3 ผลการเปรียบเทียบประสิทธิภาพแบบจำลอง ทำนายการเกิดภาวะซื้อ-ขาย ของผู้ป่วยในแผนกผู้ป่วยวิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง	80
4.3.4 การทำความเข้าใจแบบจำลองโดยใช้เทคนิค SHAP	83
4.4 ผลการพัฒนาเว็บแอปพลิเคชัน	85
บทที่ 5 สรุปผลการวิจัย	88
5.1 สรุปผลการวิจัย	88
5.2 อภิปรายผลการวิจัย	89
5.3 ประโยชน์ของสถิติหรือสารสนเทศสถิติที่ใช้ในการวิจัย	91
5.4 ข้อเสนอแนะ	91
5.4.1 ข้อเสนอแนะจากการนำผลการวิจัยไปใช้	91

## สารบัญ (ต่อ)

เรื่อง	หน้า
5.4.2 ข้อเสนอแนะในทำงานวิจัยครั้งต่อไป	91
เอกสารอ้างอิง	93
ภาคผนวก	100
ภาคผนวก ก ตัวแปรอิสระ	101
ภาคผนวก ข สถิติที่ใช้ในการวิจัย	104
ภาคผนวก ค ผลการทดสอบแบบจำลอง	110
ภาคผนวก ง ตารางการดำเนินการวิจัย	116

## สารบัญตาราง

ตารางที่	หน้า
ตารางที่ 2.1 การทดสอบสมมติฐานทางสถิติ Independent Sample T Test	8
ตารางที่ 2.2 การทดสอบสมมติฐานทางสถิติทดสอบ Mann Whitney U Test	9
ตารางที่ 2.3 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับการจัดการค่าสูญหาย	30
ตารางที่ 2.4 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับแบบจำลองทำนายภาวะซื้อ	32
ตารางที่ 3.1 ข้อมูลผู้ป่วย (Admission Info)	39
ตารางที่ 3.2 ข้อมูลประวัติการรักษา จากตาราง Redcap	39
ตารางที่ 3.3 ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	40
ตารางที่ 3.4 ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)	40
ตารางที่ 3.5 ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	41
ตารางที่ 4.1 แสดงจำนวนข้อมูลผู้ป่วยในแต่ละชุดข้อมูลและในแต่ละช่วงเวลาการทำนายล่วงหน้า	59
ตารางที่ 4.2 แสดงค่าสถิติของระยะเวลาที่เข้ารับการรักษาใน ICU	60
ตารางที่ 4.3 ผลการเปรียบเทียบความแตกต่างของตัวแปรคงที่เชิงปริมาณต่อภาวะซื้อและไม่ซื้อ	61
ตารางที่ 4.4 ผลการเปรียบเทียบสัดส่วนความแตกต่างของตัวแปรคงที่เชิงคุณภาพต่อภาวะซื้อและไม่ซื้อ	63
ตารางที่ 4.5 แสดงการเปรียบเทียบก่อนและหลังการเติมค่า Tidal Volume ด้วยตัวแปรอื่น	68
ตารางที่ 4.6 แสดงการเปรียบเทียบก่อนและหลังการเติมค่า FIO <sub>2</sub>	69
ตารางที่ 4.7 จำนวนข้อมูลนำเข้าที่ถูกแบ่งตามประเภทชุดข้อมูลของแต่ละช่วงเวลาการทำนาย	70
ตารางที่ 4.8 ผลการแบ่งข้อมูลชุดฝึกสอนและตรวจสอบในแต่ละช่วงเวลาการทำนายล่วงหน้า ของการแบ่งข้อมูลแบบ Stratified Group 5-Fold Cross Validation	72
ตารางที่ 4.9 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN	74
ตารางที่ 4.10 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ LSTM	75
ตารางที่ 4.11 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ Transformer	76

## สารบัญตาราง (ต่อ)

ตารางที่	หน้า
ตารางที่ 4.12 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN + LSTM	77
ตารางที่ 4.13 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN + Transformer	78
ตารางที่ 4.14 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ LSTM + Transformer	79
ตารางที่ 4.15 ผลการเปรียบเทียบประสิทธิภาพแบบจำลองทำนายการเกิดภาวะซึ่อกของผู้ป่วยในแผนกผู้ป่วยวิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง	80

## สารบัญภาพ

ภาพที่	หน้า
ภาพที่ 2.1 แผนภาพมาตรฐานการทำโครงการด้านการวิเคราะห์ข้อมูล และการทำเหมืองข้อมูล	5
ภาพที่ 2.2 การเติมค่าสูญหายด้วยวิธีการประมาณค่าเชิงเส้น	12
ภาพที่ 2.3 การเติมค่าสูญหายด้วยวิธี MissForest	13
ภาพที่ 2.4 โครงข่ายประสาทเทียม	15
ภาพที่ 2.5 Rectified Linear Unit Function (ReLU)	16
ภาพที่ 2.6 Sigmoid Function	17
ภาพที่ 2.7 tanh Function	18
ภาพที่ 2.8 โครงข่ายประสาทแบบคอนโวลูชัน 1 มิติ	19
ภาพที่ 2.9 แผนภาพการทำงานของโครงข่ายประสาทแบบวนซ้ำ (RNN)	20
ภาพที่ 2.10 แผนภาพการทำงานของหน่วยความจำระยะสั้นระยะยาว (LSTM)	21
ภาพที่ 2.11 สถาปัตยกรรมของ Transformer	22
ภาพที่ 2.12 ตัวอย่างการทำงานของ Dropout	25
ภาพที่ 2.13 Regularization ประเภทต่าง ๆ	26
ภาพที่ 2.14 การวัดประสิทธิภาพแบบจำลองจาก Confusion Matrix	27
ภาพที่ 2.15 AUC-ROC Curve	28
ภาพที่ 2.16 LSTM+CNN+Static-repeat	34
ภาพที่ 2.17 LSTM+CNN+Static-last	34
ภาพที่ 2.18 แบบจำลอง CNN และ LSTM ที่ถูกส่งผ่านมา.yังโน้มถ่วง Transformer	35
ภาพที่ 2.19 กรอบแนวคิดการวิจัย	36
ภาพที่ 3.1 การสร้างข้อมูลนำเข้า และกำหนดค่า label ของข้อมูลผู้ป่วยที่มีภาวะซึ่งก	48

## สารบัญภาพ (ต่อ)

ภาพที่	หน้า
ภาพที่ 3.2 การสร้างข้อมูลนำเข้า และกำหนดค่า label ของข้อมูลผู้ป่วยที่ไม่มีภาวะช็อก	49
ภาพที่ 3.3 โครงสร้างของข้อมูลนำเข้า	50
ภาพที่ 3.4 โครงสร้างทั่วไปของแบบจำลองแบบเดี่ยว	54
ภาพที่ 3.5 โครงสร้างทั่วไปของแบบจำลองแบบผสม	55
ภาพที่ 4.1 Histogram ระยะเวลาในการเข้ารับการรักษาใน ICU ของผู้ป่วย	60
ภาพที่ 4.2 แสดงค่าเฉลี่ยตัวแปรรายชั่วโมงเชิงปริมาณในแต่ละชั่วโมง	64
ภาพที่ 4.3 แสดงค่าเฉลี่ยตัวแปรรายนาทีเชิงปริมาณในทุก ๆ 15 นาที	65
ภาพที่ 4.4 ผลก่อนและหลังการจัดการค่าผิดปกติ	66
ภาพที่ 4.5 Boxplot แสดงค่าสูงผิดปกติ และ การแทนที่ให้เป็นค่าสูญหายในตัวแปร BP_SYS	67
ภาพที่ 4.6 กราฟความหนาแน่นแสดงผลก่อนและการเติมค่า Tidal Volume ด้วยตัวแปรอื่น	67
ภาพที่ 4.7 กราฟความหนาแน่นแสดงผลก่อนและการเติมค่า FIO <sub>2</sub> ด้วยตัวแปรอื่น	68
ภาพที่ 4.8 ข้อมูลในแต่ละระดับความล้มเหลวทางการแพทย์และหลังการเติมค่าสูญหาย	69
ภาพที่ 4.9 แผนภูมิแท่งแสดงการเปรียบเทียบจำนวนข้อมูลนำเข้าของผู้ป่วยในแต่ละช่วงเวลาการพยาบาลล่วงหน้า	71
ภาพที่ 4.10 สัดส่วนการกระจายของคลาสเฉลี่ยในแต่ละช่วงเวลาการพยาบาลล่วงหน้า และการแบ่งชุดฝึกสอนและตรวจสอบเฉลี่ยในแต่ละไฟล์	73
ภาพที่ 4.11 ผลการวัดประสิทธิภาพแบบจำลอง CNN+LSTM ในแต่ละช่วงเวลา ด้วย AUC-ROC	82
ภาพที่ 4.12 Learning Curve ของแบบจำลอง CNN+LSTM ในช่วงเวลาการพยาบาลล่วงหน้า 1 ชั่วโมง	83
ภาพที่ 4.13 อิทธิพลของตัวแปรคงที่ที่มีผลต่อการทำนายภาวะช็อก	83
ภาพที่ 4.14 อิทธิพลของตัวแปรพลวัตที่มีผลต่อการทำนายภาวะช็อก	84
ภาพที่ 4.15 Heatmap แสดงอิทธิพลของตัวแปรพลวัตที่มีต่อการทำนายภาวะช็อกในแต่ละ Time windows	85

## สารบัญภาพ (ต่อ)

ภาพที่	หน้า
ภาพที่ 4.16 หน้าหลักของเว็บแอปพลิเคชัน	86
ภาพที่ 4.17 หน้าต่างเว็บแอปพลิเคชันสำหรับอัปโหลดไฟล์ข้อมูลผู้ป่วยที่ต้องการทำนาย	86
ภาพที่ 4.18 หน้าต่างเว็บแอปพลิเคชันหน้าผลลัพธ์การทำนาย	86
ภาพที่ 4.19 หน้าต่างเว็บแอปพลิเคชันหน้าประวัติการทำนาย	87
ภาพที่ 4.20 QR code สำหรับเว็บแอปพลิเคชัน	87

## บทที่ 1

### บทนำ

#### 1.1 ความเป็นมาและความสำคัญของปัญหา

ปัจจุบันภาวะช็อก (Shock) เป็นหนึ่งในภาวะฉุกเฉินที่พบบ่อยในผู้ป่วยที่เข้ารับการรักษาในห้องผู้ป่วยวิกฤต (Intensive Care Unit; ICU) และมีความสัมพันธ์กับอัตราการเสียชีวิตที่สูงทั่วโลก การศึกษาระดับนานาชาติเกี่ยวกับผู้ป่วยใน ICU พบว่าภาวะช็อกเกิดขึ้นในผู้ป่วยที่เข้ารับการรักษาใน ICU ถึงร้อยละ 29.5 และมีอัตราการเสียชีวิตในโรงพยาบาลสูงถึงร้อยละ 35.3 เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อกซึ่งมีอัตราการเสียชีวิตร้อยละ 16.7 (Sakr et al., 2018) ภาวะช็อกมีหลายประเภท เช่น ภาวะช็อกจากการสูญเสียเลือดหรือของเหลว (Hypovolemic Shock), ภาวะช็อกจากการทำงานของหัวใจบกพร่อง (Cardiogenic Shock) และภาวะช็อกจากการกระจายตัวของเลือดผิดปกติ (Distributive Shock) โดยลักษณะร่วมของภาวะช็อกคือการลดลงของการไหลเวียนโลหิตที่ส่งผลต่อการทำงานของอวัยวะสำคัญและนำไปสู่ภาวะขาดออกซิเจนในระดับเซลล์ (cellular hypoxia) (Vincent et al., 2012) ภาวะช็อกใน ICU เป็นปัจจัยเสี่ยงสำคัญที่นำไปสู่การล้มเหลวของอวัยวะหลายระบบ เช่น ระบบหัวใจและหลอดเลือด ระบบทางเดินหายใจ และระบบไต ซึ่งผู้ป่วยที่มีภาวะช็อกอาจมีความดันโลหิตต่ำ (Hypotension) ระดับความดันโลหิตเฉลี่ย (Mean Arterial Pressure; MAP) ต่ำกว่า 65 มิลลิเมตรปรอท หรือมีดัชนีช็อก (Shock Index) ที่สูงเกินปกติ อาการเหล่านี้อาจนำไปสู่ภาวะการล้มเหลวของระบบไหลเวียนเลือดและความเสียหายต่ออวัยวะในที่สุด (Singer et al., 2016; Vincent & De Backer, 2013) ปัจจัยสำคัญที่ทำให้อัตราการเสียชีวิตในภาวะช็อกยังคงสูง คือการวินิจฉัยและการรักษาที่ล่าช้า ซึ่งจะเพิ่มความเสี่ยงต่อการเกิดภาวะอวัยวะล้มเหลวและการเสียชีวิต โดยทุก ๆ ชั่วโมงที่ล่าช้าในการให้ยาปฏิชีวนะในช่วง 6 ชั่วโมงแรก จะเพิ่มความเสี่ยงต่อการเสียชีวิตถึง 7.6% ต่อชั่วโมง (Kumar et al., 2006) อีกทั้งภาวะช็อกสามารถเกิดขึ้นและเปลี่ยนแปลงอย่างรวดเร็วในระยะเวลาอันสั้น ดังนั้น หากมีการท่านายและการจัดการภาวะช็อกล่วงหน้าจะเป็นปัจจัยสำคัญที่ช่วยลดอัตราการเสียชีวิตและการเกิดภาวะแทรกซ้อนในผู้ป่วยได้

งานวิจัยในปัจจุบันมีการนำเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา (Time Series Deep Learning) มาใช้ในการฝึกสอนแบบจำลอง เนื่องจากความรุนแรงของการนั้นเป็นเรื่องละเอียดอ่อนต่อเวลา แบบจำลองที่สามารถจับความสัมพันธ์กับเวลาได้ก็จะยิ่งเพิ่มประสิทธิภาพในการท่านายได้ดียิ่งขึ้น (Deng et al., 2022) เช่น เทคนิคหน่วยความจำระยะสั้นระยะยาว (Long Short-Term Memory; LSTM) ในการจัดการกับข้อมูลอนุกรมเวลาที่ซับซ้อน และเทคนิคทรานส์ฟอร์มเมอร์ (Transformer) ที่สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนและยาวนานในข้อมูลได้เป็นอย่างดี และมีความยืดหยุ่นในการจัดการกับข้อมูลที่มีลำดับเวลาที่แตกต่างกัน ทำให้ผลลัพธ์มีความแม่นยำและทันท่วงทีมากขึ้น (Tang et al., 2024)

จากเทคนิคต่าง ๆ ที่กล่าวมา ผู้วิจัยเห็นความสำคัญของเทคนิคเหล่านี้ที่จะช่วยในการทำนายการเกิดภาวะซ้อก ที่สามารถเรียนรู้รูปแบบและแนวโน้มของข้อมูลที่มีลักษณะเป็นลำดับเวลาได้อย่างมีประสิทธิภาพ และแบบจำลองที่ถูกพัฒนาขึ้นยังสามารถประเมินความเสี่ยงได้แบบทันท่วงที่ งานวิจัยนี้จึงนำเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลาดังกล่าวไปประยุกต์ใช้กับข้อมูลทางการแพทย์ของผู้ป่วยที่มีภาวะซ้อกในโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น โดยการสร้างแบบจำลอง และเปรียบเทียบประสิทธิภาพของแบบจำลองสำหรับการทำนายภาวะซ้อกของผู้ป่วยใน ICU เพื่อหาแบบจำลองการทำนายที่มีประสิทธิภาพที่ดีที่สุด เพื่อที่สามารถนำไปกำหนดแนวทางต่าง ๆ ใน การรักษาป้องกัน และช่วยให้แพทย์สามารถวางแผนการรักษาได้อย่างเหมาะสมและทันเวลา

## 1.2 วัตถุประสงค์ของการวิจัย

1.2.1 เพื่อวิเคราะห์ตัวแปรที่ส่งผลต่อการเกิดภาวะซ้อกของผู้ป่วยใน ICU

1.2.2 เพื่อสร้างแบบจำลองสำหรับการทำนายภาวะซ้อกของผู้ป่วยใน ICU ล่วงหน้า 1,2 หรือ 3 ชั่วโมงก่อนเกิดภาวะซ้อก ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลาจากข้อมูลผู้ป่วยในระบบ Smart-ICU ของโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น

## 1.3 สมมติฐานการวิจัย

เทคนิคโครงข่ายประสาทแบบแบบผสม เช่น แบบจำลอง CNN+LSTM, แบบจำลอง CNN+Transformer หรือแบบจำลอง LSTM+Transformer สามารถทำนายการซ้อกในผู้ป่วยได้อย่างมีประสิทธิภาพกว่าเทคนิคอื่น ๆ

## 1.4 ขอบเขตของการวิจัย

1.4.1 ขอบเขตประชากร คือ ผู้ป่วยที่เข้ารับการรักษาใน ICU ที่ได้รับการบันทึกข้อมูลอยู่ในระบบฐานข้อมูลของโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น ตั้งแต่วันที่ 15 ตุลาคม 2565 - 3 กุมภาพันธ์ 2568

1.4.2 ขอบเขตเนื้อหา คือ โครงการนี้มีวัตถุประสงค์เพื่อสร้างแบบจำลองสำหรับการทำนายภาวะซ้อกของผู้ป่วยใน ICU ล่วงหน้า 1,2 และ 3 ชั่วโมงก่อนเกิดภาวะซ้อก ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลาจากข้อมูลผู้ป่วยในระบบ Smart-ICU โดยใช้ข้อมูลของผู้ป่วยที่มีอายุ 18 ปีขึ้นไป และมีระยะเวลาที่อยู่ใน ICU ไม่ต่ำกว่า 24 ชั่วโมง ของโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น

1.4.3 ขอบเขตด้านระยะเวลา คือ เดือนมิถุนายน 2567 - มีนาคม 2568

1.4.4 ขอบเขตด้านพื้นที่ คือ โรงพยาบาลศринครินทร์ จังหวัดขอนแก่น

## 1.5 นิยามศัพท์เฉพาะ

1.5.1 ภาวะซ้อกในห้องผู้ป่วยวิกฤต (Shock in ICU) หมายถึง ภาวะที่ระบบไหลเวียนโลหิตมีความผิดปกติจนไม่สามารถส่งเลือดไปเลี้ยงอวัยวะสำคัญได้เพียงพอ ซึ่งอาจแสดงออกในรูปของความดันโลหิตเฉลี่ย (Mean Arterial

Pressure; MAP) ต่ำกว่า 65 มิลลิเมตรปอร์ท, ความดันโลหิตตัวบน (Systolic Blood Pressure; SBP) ต่ำกว่า 90 มิลลิเมตรปอร์ท, หรือดัชนีชี้อักด้แอกสโตลิก (Diastolic Shock Index) มีค่ามากกว่า 2 (คำนวณจากอัตราการเต้นหัวใจหารด้วยความดันโลหิตตัวล่าง) โดยภาวะดังกล่าวต้องการการจัดการและการรักษาอย่างเร่งด่วนเพื่อป้องกันการล้มเหลวของอวัยวะและลดอัตราการเสียชีวิตในผู้ป่วย ICU (Singer et al., 2016; Vincent & De Backer, 2013)

1.5.2 การเรียนรู้เชิงลึก (Deep Learning) เป็นเทคนิคในการสร้างปัญญาประดิษฐ์โดยใช้การเรียนแบบโครงข่ายประสาทของมนุษย์ โดยนำโครงข่ายประสาทเทียม (Neural Networks) มาซ้อนกันหลาย ๆ ชั้น เพื่อให้เรียนรู้ข้อมูลตัวอย่าง ประมวลผลและตัดสินใจจากข้อมูลที่ได้รับ สามารถปรับปรุงผลลัพธ์การตัดสินใจได้ด้วยตัวเองโดยไม่ต้องอาศัยการฝึกสอนจากมนุษย์ สามารถวิเคราะห์และเรียนรู้จากข้อมูลที่มีความซับซ้อนได้ดี เช่น ภาพ เสียง ข้อมูลอนุกรมเวลา และข้อความ (LeCun et al., 2015)

1.5.3 ข้อมูลอนุกรมเวลา (Time series data) หมายถึง ข้อมูลที่ถูกบันทึกเป็นลำดับเวลาอย่างต่อเนื่อง โดยที่แต่ละค่าของข้อมูลจะขึ้นอยู่กับเวลาที่เกิด เช่น อัตราการเต้นของหัวใจที่วัดทุกนาที ข้อมูลอนุกรมเวลาจึงมีความสำคัญในการวิเคราะห์แนวโน้มและการพยากรณ์อนาคต (Stasko, 2013)

## 1.6 ประโยชน์ที่คาดว่าจะได้รับ

- 1.6.1 ทำให้เข้าใจถึงปัจจัยที่เกี่ยวข้องกับการเกิดภาวะช็อกใน ICU
- 1.6.2 ได้แบบจำลองที่มีประสิทธิภาพในการทำนายการเกิดภาวะช็อกใน ICU
- 1.6.3 ลดภาวะเสี่ยงต่อการช็อกในผู้ป่วย และนำไปสู่การพัฒนากลยุทธ์สนับสนุนแพทย์ในการกำหนดแผนการรับมือและรักษาได้อย่างทันท่วงที

## บทที่ 2

### ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ในงานวิจัยนี้ได้ทำการศึกษาค้นคว้าทฤษฎีและงานวิจัยที่เกี่ยวข้องกับการสร้างแบบจำลองสำหรับการทำนายภาวะซื้อกองผู้ป่วยใน ICU ล่วงหน้า 1,2 และ 3 ชั่วโมงก่อนเกิดภาวะซื้อก ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรม เวลาจากข้อมูลผู้ป่วยในระบบ Smart-ICU ของโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น เพื่อนำมาเป็นแนวทางในการศึกษางานวิจัย โดยมีการศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้อง ดังนี้

#### 2.1 ทฤษฎีที่เกี่ยวข้อง

##### 2.1.1 มาตรฐานการทำโครงการด้านการวิเคราะห์ข้อมูล และการทำเหมืองข้อมูล (Cross-Industry Standard Process for Data Mining; CRISP-DM)

เป็นกระบวนการมาตรฐานที่ถูกพัฒนาเพื่อช่วยในการทำโครงการวิเคราะห์ข้อมูลหรือการทำเหมืองข้อมูล (Data Mining) อย่างเป็นระบบและมีประสิทธิภาพ ถูกพัฒนาขึ้นในปี 1996 โดยองค์กรและบริษัทที่เกี่ยวข้องกับการทำเหมืองข้อมูล เช่น Daimler AG, SPSS Inc. และ NCR Corporation โดย CRISP-DM เป็นกระบวนการที่ได้รับความนิยมสูงเนื่องจากมีโครงสร้างที่ยึดหยุ่นและปรับใช้ได้ในหลากหลายอุตสาหกรรม และสามารถนำไปปรับใช้กับการพัฒนางานวิทยาศาสตร์ข้อมูล (Data Science) และการสร้างแบบจำลอง Machine Learning ในปัจจุบัน (Chapman et al., 2000; Shearer, 2000)

1) การกำหนดปัญหาทางธุรกิจ (Business Understanding) คือการทำความเข้าใจปัญหาที่แท้จริง โดยเริ่มต้นจากการกำหนดวัตถุประสงค์ของโครงการ เข้าใจเป้าหมายทางธุรกิจอย่างละเอียด และแปลงวัตถุประสงค์เหล่านั้นให้เป็นเป้าหมายเชิงข้อมูล (data mining goals) (Chapman et al., 2000)

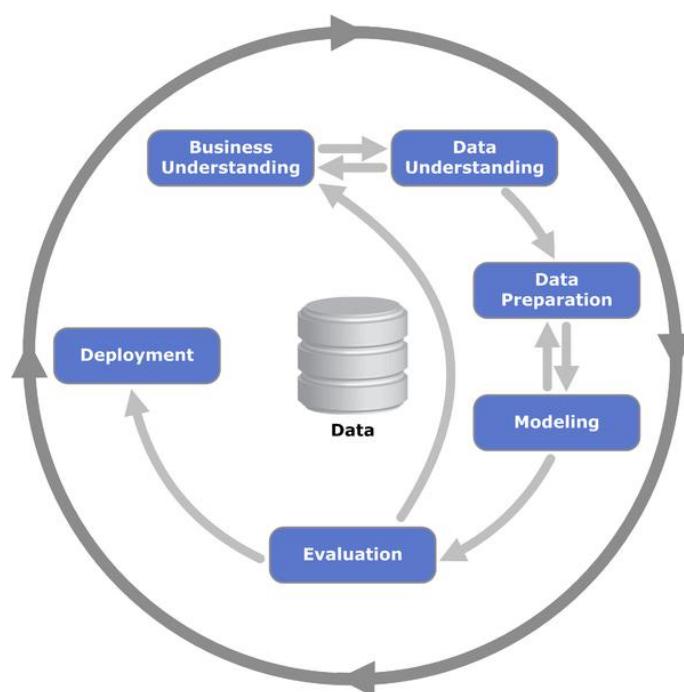
2) การศึกษาทำความเข้าใจข้อมูล (Data Understanding) คือขั้นตอนการรวบรวมข้อมูลเบื้องต้น ทำการตรวจสอบคุณภาพของข้อมูล การระบุปัญหาที่มี เช่น ข้อมูลสูญหาย (missing data) หรือข้อมูลที่มีค่าผิดปกติ หรือค่าที่ไม่สอดคล้องกัน การสำรวจความสัมพันธ์เบื้องต้นระหว่างตัวแปรต่าง ๆ และทำการวิเคราะห์เบื้องต้นเพื่อทำความเข้าใจข้อมูล (Shearer, 2000)

3) การเตรียมข้อมูล (Data Preparation) คือขั้นตอนการเตรียมข้อมูลให้พร้อมสำหรับการสร้างแบบจำลอง รวมถึงการทำความสะอาดข้อมูล (data cleaning) การแปลงข้อมูล (data transformation) และการเลือกคุณลักษณะ (feature selection) ที่จะนำมาใช้ การเตรียมข้อมูลที่ดีจะช่วยให้แบบจำลองที่สร้างมีความแม่นยำ และประสิทธิภาพมากขึ้น การทำความสะอาดข้อมูลอาจรวมถึงการจัดการกับค่าที่หายไป การแก้ไขค่าที่ผิดพลาด หรือการทำ normalization และ scaling ข้อมูลในรูปแบบที่เหมาะสมกับแบบจำลอง

4) การสร้างแบบจำลอง (Modeling) เป็นขั้นตอนการเลือกเทคนิคการวิเคราะห์ข้อมูลหรือสร้างแบบจำลองที่เหมาะสมกับข้อมูล และวัตถุประสงค์ที่ตั้งไว้ โดยอาจเลือกใช้แบบจำลองทางสถิติ แบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) หรือ แบบจำลองการเรียนรู้เชิงลึก (Deep Learning) โดยการสร้างแบบจำลองในขั้นตอนนี้ อาจต้องทำการทดสอบและปรับแต่งแบบจำลองหลายครั้ง เพื่อให้ได้ผลลัพธ์ที่ดีที่สุด

5) การประเมินประสิทธิภาพแบบจำลอง (Evaluation) เป็นขั้นตอนการประเมินประสิทธิภาพของแบบจำลองที่สร้างขึ้นว่าตอบโจทย์ หรือสอดคล้องกับวัตถุประสงค์ที่ตั้งไว้หรือไม่ โดยใช้ metric ต่าง ๆ ในการวัด เช่น accuracy, precision, recall, F1-score, AUC-ROC เป็นต้น การประเมินประสิทธิภาพต้องคำนึงถึงความเหมาะสมของแบบจำลองกับข้อมูลจริง หากผลลัพธ์ไม่ดีพอ อาจต้องกลับไปปรับปรุงแบบจำลองหรือขั้นตอนการเตรียมข้อมูลใหม่ เพื่อให้มั่นใจว่าแบบจำลองนั้นพร้อมสำหรับการใช้งานจริง

6) การนำไปใช้จริง (Deployment) คือการนำแบบจำลองที่ผ่านการประเมินแล้วไปใช้งานจริง ซึ่งในขั้นตอนนี้จะรวมถึงการพัฒนาแอปพลิเคชันหรือระบบที่สามารถใช้งานได้โดยตรงสำหรับผู้ใช้ หรือการรายงานผลลัพธ์ที่ได้ให้กับผู้มีส่วนเกี่ยวข้อง (Chapman et al., 2000; Shearer, 2000; Wirth & Hipp, 2000)



ภาพที่ 2.1 แผนภาพมาตรฐานการทำโครงการด้านการวิเคราะห์ข้อมูล และการทำเหมืองข้อมูล

### 2.1.2 ภาวะช็อก

ภาวะช็อก เป็นภาวะทางการแพทย์ที่เกิดจากการให้เลวี่นเลือดที่ผิดปกติ ส่งผลให้เกิดการลดลงของเลือดที่ไปเลี้ยงเนื้อเยื่อและอวัยวะต่างๆ อย่างรุนแรง นำไปสู่ภาวะขาดออกซิเจนในระดับเซลล์ (cellular hypoxia)

และการล้มเหลวของอวัยวะหล่ายระบบในที่สุด ภาวะซึ่อกสามารถแบ่งออกได้เป็นหล่ายประเทตตามกลไกการเกิดได้แก่ ภาวะซึ่อกจากการสูญเสียเลือดหรือสารน้ำ (Hypovolemic shock), ภาวะซึ่อกจากการทำงานของหัวใจที่ผิดปกติ (Cardiogenic shock), ภาวะซึ่อกจากการอุดกั้นทางเดินเลือด (Obstructive shock) และภาวะซึ่อกจากการกระจายตัวของเลือดที่ผิดปกติ (Distributive shock) ซึ่งรวมถึงภาวะซึ่อกจากการติดเชื้อ (Septic shock) (Vincent & De Backer, 2013)

การวินิจฉัยภาวะซึ่อกในทางการแพทย์อาศัยเกณฑ์หล่ายประการ โดยเฉพาะค่าความดันโลหิต ซึ่งเกณฑ์ที่ได้รับการยอมรับในปัจจุบันประกอบด้วย

- 1) ความดันโลหิตเฉลี่ย (Mean Arterial Pressure; MAP) ต่ำกว่า 65 มิลลิเมตรปอร์ท

ค่า MAP ต่ำกว่า 65 มิลลิเมตรปอร์ทเป็นจุดวิกฤตที่ส่งผลให้การไหลเวียนเลือดไปเลี้ยงอวัยวะสำคัญไม่เพียงพอ โดยเฉพาะไต ซึ่งเพิ่มความเสี่ยงต่อการเกิดภาวะไตวายเฉียบพลัน (Asfar et al., 2014)

- 2) ความดันโลหิตตัวบน (Systolic Blood Pressure; SBP) ต่ำกว่า 90 มิลลิเมตรปอร์ท

ผู้ป่วยที่มีความดันโลหิตตัวบนต่ำกว่า 90 มิลลิเมตรปอร์ทมีอัตราการเสียชีวิตสูงถึง 46% เทียบกับเพียง 5% ในกลุ่มที่มีความดันโลหิตตัวบนอยู่ในช่วง 90-109 มิลลิเมตรปอร์ท และ 1% ในกลุ่มที่มีความดันโลหิตตัวบนตั้งแต่ 110 มิลลิเมตรปอร์ทขึ้นไป นอกจากนี้ ผู้ป่วยกลุ่มนี้ยังมีอัตราการติดเชื้อสูงถึง 60% และระยะเวลาอนโรงพยาบาลเฉลี่ยนานกว่า 24 วัน ซึ่งมากกว่ากลุ่มอื่นอย่างมีนัยสำคัญทางสถิติ การใช้ความดันโลหิตตัวบนต่ำกว่า 90 มิลลิเมตรปอร์ท เป็นเกณฑ์วินิจฉัยภาวะซึ่อกได้รับการยอมรับอย่างกว้างขวางและถูกใช้ในการศึกษาเกี่ยวกับการรักษาภาวะซึ่อกจากการสูญเสียเลือดและการประเมินในผู้ป่วยบาดเจ็บมาอย่างยาวนาน (Edelman et al., 2007)

- 3) ดัชนีซึ่อกได้แอสโตรลิก (Diastolic Shock Index; DSI) มากกว่า 2.0

โดยค่า DSI ซึ่งคำนวณจากอัตราการเต้นของหัวใจหารด้วยความดันโลหิตตัวล่าง เป็นตัวทำนายการเสียชีวิตที่แม่นยำในผู้ป่วยภาวะซึ่อก โดยค่า  $DSI > 2.0$  สัมพันธ์กับอัตราการเสียชีวิตที่สูงขึ้น กว่าผู้ป่วยที่มีค่า DSI ต่ำกว่าอย่างมีนัยสำคัญ (Ospina-Tascón et al., 2020)

การประเมินและวินิจฉัยภาวะซึ่อกอย่างรวดเร็วโดยใช้เกณฑ์ทั้งสามประการนี้มีความสำคัญอย่างยิ่งต่อการรักษา เนื่องจากภาวะซึ่อกที่ไม่ได้รับการวินิจฉัยและรักษาอย่างทันท่วงทีจะนำไปสู่การล้มเหลวของอวัยวะหล่ายระบบ และเพิ่มความเสี่ยงต่อการเสียชีวิตอย่างมีนัยสำคัญ โดยเฉพาะในผู้ป่วยวิกฤตที่มีระบบภูมิคุ้มกันหรือการไหลเวียนเลือดที่ไม่แข็งแรงอยู่แล้ว

### 2.1.3 ทฤษฎีทางสถิติที่เกี่ยวข้อง

#### 2.1.3.1 สถิติเชิงอนุมานสำหรับข้อมูลเชิงปริมาณ

- 1) การทดสอบการแจกแจงปกติ การทดสอบ Kolmogorov-Smirnov Test

การทดสอบ Kolmogorov - Smirnov One Sample Test เป็นการทดสอบความแตกต่างระหว่างความถี่ที่สังเกตุได้กับความถี่ที่คาดหวัง หรือที่เรียกว่าเป็นการทดสอบภาวะความเหมาะสมอีก วิธีหนึ่งวิธีนี้ใช้

ความถี่สะสมแทนความถี่ปกติ ไม่ว่าจะเป็นความถี่ที่สังเกตได้หรือ ความถี่ที่คาดหวัง จุดมุ่งหมายในการทดสอบ เมื่อกับการทดสอบ ไคสแควร์ คือ ต้องการทดสอบว่าการแจกแจงของข้อมูล ที่สังเกตได้แตกต่างจากการแจกแจงที่คาดหวังตามทฤษฎีหรือไม่ แต่วิธีนี้มีประสิทธิภาพมากกว่า การทดสอบไคสแควร์ และใช้ได้กับข้อมูลทุกรูปแบบ แม้ว่า ความถี่ บางกลุ่มจะเป็นศูนย์ก็ตาม และใช้กับ ข้อมูลที่อยู่ในมาตราวัดต่ำสุด คือ มาตรเรียงอันดับ และเลือกใช้ Kolmogorov Smirnov test เมื่อขนาดตัวอย่าง มีจำนวน 50 ตัวอย่างขึ้นไป (สุคนธ์ ประสิทธิ์วัฒนเสรี, 2552)

### ข้อตกลงเบื้องต้น

- (1) ข้อมูลอยู่ในมาตราเรียงอันดับ (Ordinal Scale) ขึ้นไป
- (2) ข้อมูลทั้งสองกลุ่มจะต้องเป็นอิสระต่อกัน
- (3) ตัวอย่างต้องได้มาจากการสุ่ม

### การทดสอบสมมติฐาน

$H_0$ : ประชากรมีการแจกแจงปกติ

$H_1$ : ประชากรไม่มีการแจกแจงปกติ

### สถิติทดสอบ

$$D = \max|F(X) - S(X)|$$

เมื่อ  $D$  คือ ตัวสถิติทดสอบของ Kolmogorov Smirnov

$F(X)$  คือ ความถี่สะสมของตัวอย่าง

$S(X)$  คือ ความถี่ที่คาดหวังไว้

การตัดสินใจด้วยค่า p-value ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ )

### 1) สถิติทดสอบ Independent Sample t-Test

สถิติที่ใช้ในการทดสอบกลุ่มตัวอย่างที่เป็นอิสระต่อกัน โดยเป็นสถิติที่ใช้ในการเปรียบเทียบความแตกต่างของค่าเฉลี่ยระหว่าง 2 กลุ่มประชากร (ชัชวาล เรื่องประพันธ์, 2556)

### ข้อตกลงเบื้องต้น

- (1) ประชากรทั้งสองกลุ่มจะต้องเป็นอิสระต่อกัน
- (2) ประชากรทั้งสองกลุ่มมีการแจกแจงปกติ
- (3) ข้อมูลอยู่ในมาตราอันตรภาค (Interval scale) ขึ้นไป

## การทดสอบสมมติฐาน

ตารางที่ 2.1 การทดสอบสมมติฐานทางสถิติ Independent Sample T Test

$H_0$	$H_1$
$H_0: \mu_1 - \mu_2 = d_0$	$H_0: \mu_1 - \mu_2 > 0$
$H_0: \mu_1 - \mu_2 = d_0$	$H_0: \mu_1 - \mu_2 < 0$
$H_0: \mu_1 - \mu_2 = d_0$	$H_0: \mu_1 - \mu_2 \neq 0$

เมื่อ  $\mu_1, \mu_2$  คือ ค่าเฉลี่ยของประชากรที่ 1 และ 2 ตามลำดับ  $d_0$  คือ ค่าของผลต่างของค่าเฉลี่ย ของประชากรกลุ่มที่ 1 และ 2 ตามลำดับ

### สถิติทดสอบ

กรณีไม่ทราบค่าความแปรปรวน แต่ความแปรปรวนเท่ากัน ( $\sigma_1^2 = \sigma_2^2$ )

$$T = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}}$$

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

$$df = n_1 + n_2 - 2$$

กรณีไม่ทราบค่าความแปรปรวน แต่ความแปรปรวนไม่เท่ากัน ( $\sigma_1^2 \neq \sigma_2^2$ )

$$T = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

$$df = \frac{\left[ \left( \frac{s_1^2}{n_1} \right) + \left( \frac{s_2^2}{n_2} \right) \right]^2}{\frac{\left( \frac{s_1^2}{n_1} \right)^2}{n_1 - 1} + \frac{\left( \frac{s_2^2}{n_2} \right)^2}{n_2 - 1}}$$

ปฏิเสธ  $H_0$  เมื่อค่า P-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ )

## 2) สถิติทดสอบ Mann Whitney U Test

สถิตินอนพารามեต릭 (non-parametric) ใช้เมื่อการตรวจสอบข้อตกลงเบื้องต้นของ Independent Sample T-test ไม่เป็นไปตามเงื่อนไข ซึ่งใช้ทดสอบสมมติฐานที่กลุ่มตัวอย่างทั้งสองเป็น อิสระต่อกัน มาจากประชากร ที่มีการแจกแจงเหมือนกัน จึงเป็นการทดสอบที่เหมาะสมสำหรับนำไปใช้ในการเปรียบเทียบประชากร 2 กลุ่มที่เป็น อิสระต่อกัน (สมนึก ภัทธิยธนี, สมบัตร ท้ายเรือคำ, 2563)

### ข้อตกลงเบื้องต้น

- (1) กลุ่มประชากรจะต้องได้มาจากการสุ่ม และเป็นอิสระต่อกัน
- (2) ข้อมูลจากกลุ่มประชากรอย่างน้อยจะต้องอยู่ในมาตราเรียงอันดับ (Ordinal Scale)

### การทดสอบสมมติฐาน

ตารางที่ 2.2 การทดสอบสมมติฐานทางสถิติทดสอบ Mann Whitney U Test

$H_0$	$H_1$
$H_0: M_1 = M_2$	$H_0: M_1 > M_2$
$H_0: M_1 = M_2$	$H_0: M_1 < M_2$
$H_0: M_1 = M_2$	$H_0: M_1 \neq M_2$

เมื่อ  $M_1$  และ  $M_2$  คือ ค่ามัธยฐานของประชากรกลุ่มที่ 1 และ 2 ตามลำดับ

### สถิติทดสอบ

$$U = \min(U_1, U_2)$$

$$U_1 = n_1 n_2 + \frac{n_1(n_1+1)}{2} - \sum R_1$$

$$U_2 = n_1 n_2 + \frac{n_2(n_2+1)}{2} - \sum R_2$$

เมื่อ  $U$  คือ ค่า U statistic (ค่าที่น้อยที่สุดระหว่าง  $U_1, U_2$ )

$n_1 n_2$  คือ กลุ่มตัวอย่างที่สุ่มมาจากประชากรกลุ่มที่ 1,2

$\sum R_1, \sum R_2$  คือ ผลรวมของอันดับของข้อมูลจากกลุ่มตัวอย่างที่ 1,2

การตัดสินใจด้วยค่า p-value โดยปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ )

### 2.1.3.2 สติติเชิงอนุมานสำหรับข้อมูลเชิงคุณภาพ

#### 1) การทดสอบความคล้ายคลึงกัน (Test of homogeneity)

เป็นการทดสอบความเท่ากันของสัดส่วนระหว่างประชากร 2 กลุ่มขึ้นไป โดยใช้การทดสอบไคสแควร์ (สรุป พิศาลบุตร, 2554)

#### ข้อตกลงเบื้องต้น

(1) ข้อมูลจะต้องอยู่ในมาตรฐานนามบัญญัติ (Nominal scale)

(2) ประชากรที่ต้องการทดสอบเป็นอิสระต่อกัน

#### การทดสอบสมมติฐาน

$H_0$  : สัดส่วนของประชากรกลุ่มที่ 1 และประชากรกลุ่มที่ 2 ไม่แตกต่างกัน

$H_1$  : สัดส่วนของประชากรกลุ่มที่ 1 และประชากรกลุ่มที่ 2 แตกต่างกัน

#### สติติทดสอบ

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

เมื่อ  $\chi^2$  คือ ตัวสถิติทดสอบไคสแควร์ที่องศาความเป็นอิสระ  $(r-1)(c-1)$

$O_{ij}$  คือ ความถี่ที่ได้จากการสังเกตใน cell(i,j)

$E_{ij}$  คือ ความถี่คาดหวัง หรือตามทฤษฎีใน cell(i,j)

$r$  คือ จำนวนแถว (row)

$c$  คือ จำนวนคอลัมน์ (column)

และ

$$E_{ij} = \frac{r_i c_j}{n}$$

เมื่อ  $r_i$  คือ ความถี่รวมของตัวแปรที่ 1 กลุ่มที่ i ;  $i=1,\dots,r$

$c_j$  คือ ความถี่รวมของตัวแปรที่ 2 กลุ่มที่ j ;  $j=1,\dots,c$

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ )

#### 2.1.4 ข้อมูลสูญหาย (Missing Value)

ข้อมูลสูญหาย (Missing Data) หมายถึงข้อมูลที่มีค่าสังเกตที่ไม่มีการระบุค่า การขาดหายไปของค่าสังเกต หรือที่เรียกว่าค่าว่าง ซึ่งอาจเกิดได้หลายสาเหตุ เช่น การที่ผู้ให้ข้อมูลไม่ประสงค์จะตอบ หรือข้อมูลที่มีการเก็บรวบรวมไว้แล้วแต่เป็นข้อมูลที่ไม่สมบูรณ์ เกิดข้อผิดพลาดในการป้อนข้อมูล และอุปกรณ์ที่บันทึกค่าผิดปกติ เป็นต้น (พัชนา สุวรรณเสน, 2562) แบ่งออกเป็น 3 ประเภท

1) การสูญหายแบบสุ่มสมบูรณ์ (Missing Completely at Random; MCAR)

เป็นลักษณะของข้อมูลสูญหายที่เกิดจากการสุ่มไม่ได้เกี่ยวข้องกับตัวแปรใดๆ เนื่องจากข้อมูลสูญหายเป็นอิสระจากตัวแปรอื่นๆ ทั้งที่ทราบค่าหรือไม่ทราบค่า

2) การสูญหายแบบสุ่ม (Missing at Random; MAR)

หรือเรียกอีกอย่างว่าเป็นการสูญหายแบบสุ่มแบบมีเงื่อนไข (Missing Conditionally at Random) เป็นข้อมูลสูญหายซึ่งไม่ได้เกิดขึ้นอย่างสุ่มจากค่าสังเกตทั้งหมดแต่เกิดขึ้นอย่างสุ่มในบางกลุ่มของค่าสังเกต เกิดในกรณีที่ตัวแปรอื่นมีอิทธิพลต่อค่าสูญหาย ที่วัดได้ และจัดการถูกต้อง

3) การสูญหายแบบไม่สุ่ม (Missing not at Random; MNAR)

เป็นลักษณะของข้อมูลสูญหายซึ่งไม่ได้เกิดขึ้นอย่างสุ่ม เกิดขึ้นในกรณีที่ค่าสูญหายเกิดจากอิทธิพลตัวแปรอื่นหรือภัยในค่าของตนเอง (พัชนา สุวรรณเสน, 2562; สันทัด ประเสริฐมนิตร, 2562)

การจัดการค่าสูญหายมีหลายวิธี ขึ้นอยู่กับลักษณะของข้อมูลหรือประเภทของค่าสูญหาย หากจัดการแบบผิดวิธี อาจทำให้เกิดความอคติต่อข้อมูลส่งผลทำให้แบบจำลองไม่มีประสิทธิภาพในการทำนายเท่าที่ควร ซึ่งการจัดการค่าสูญหายมีหลายวิธี ดังนี้

##### 2.1.4.1 การเติมค่าสูญหายด้วยวิธีการประมาณค่าเชิงเส้น (Linear Interpolation)

การเติมค่าสูญหายด้วยวิธีการประมาณค่าช่วง (Interpolation) คือกระบวนการคาดเดาค่าที่สูญหายระหว่างจุดข้อมูลที่มีอยู่ โดยใช้สมการทางคณิตศาสตร์เพื่อหาค่ากลางระหว่างจุดข้อมูลที่ใกล้เคียงกัน โดยการเติมค่าสูญหายด้วยวิธีการประมาณค่าเชิงเส้น เป็นหนึ่งในกระบวนการประมาณค่าช่วงแบบหนึ่ง ที่จะคำนวณค่าใหม่ตามเส้นตรงระหว่างจุดข้อมูลที่อยู่ติดกัน โดยสมมติว่าค่าระหว่างจุดทั้งสองเปลี่ยนแปลงตามเส้นตรง ซึ่งหลักการทำงานของวิธีนี้จะอยู่บนพื้นฐานของ Linear Polynomials หรือ สมการเส้นตรง (GISTDA, 2024) โดยที่จุดที่ต้องการประมาณค่าในช่วงจุด  $(x,y)$  สามารถคำนวณได้ดังนี้

หากมีจุดข้อมูลสองจุด  $(x_1, y_1)$  และ  $(x_2, y_2)$  และต้องการหาค่าของ  $y$  ที่สอดคล้องกับ  $x$  ที่อยู่ระหว่าง  $x_1$  และ  $x_2$  เช่น  $(x_1 < x < x_2)$  ค่าที่ได้จาก Linear Interpolation จะคำนวณจากสมการ

$$y = y_1 + (x - x_1) \frac{y_2 - y_1}{x_2 - x_1}$$

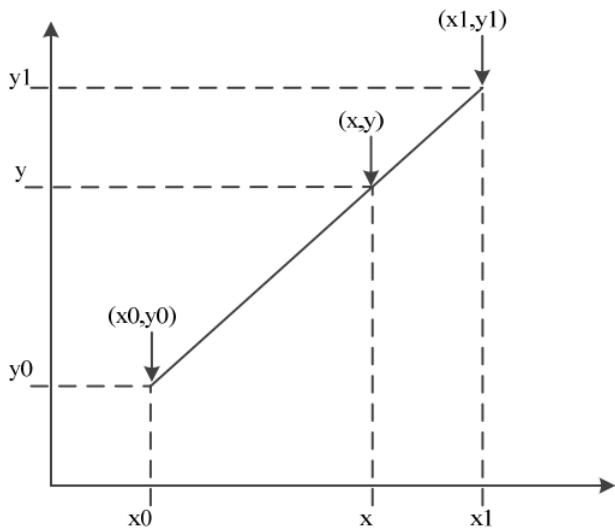
หรือ

$$y = y_1 + m(x - x_1)$$

เมื่อ	$x$	คือ ค่าที่ต้องการประมาณค่า ซึ่งอยู่ระหว่าง $x_1$ และ $x_2$
	$y$	คือ ค่าที่ต้องการหาที่ $y$ สำหรับค่าของ $x$ ที่กำหนด
	$x_1$ และ $y_1$	คือ พิกัดจุดข้อมูลแรกของช่วงที่ต้องการประมาณค่า
	$x_2$ และ $y_2$	คือ พิกัดจุดข้อมูลที่สองของช่วงที่ต้องการประมาณค่า
	$m$	คือ ความชันหรืออัตราการเปลี่ยนแปลงของเส้นตรงระหว่างสองจุด

$$m = \left( \frac{y_2 - y_1}{x_2 - x_1} \right)$$

การประมาณค่าในช่วงแบบ Linear จะใช้เวลาในการคำนวณน้อย มีประสิทธิภาพต่อการประมาณค่าข้อมูลที่หายไปจากการที่มีคุณลักษณะความเป็นเชิงเส้นสูง (Bayen & Siauw, 2015; BYJUS, 2024)

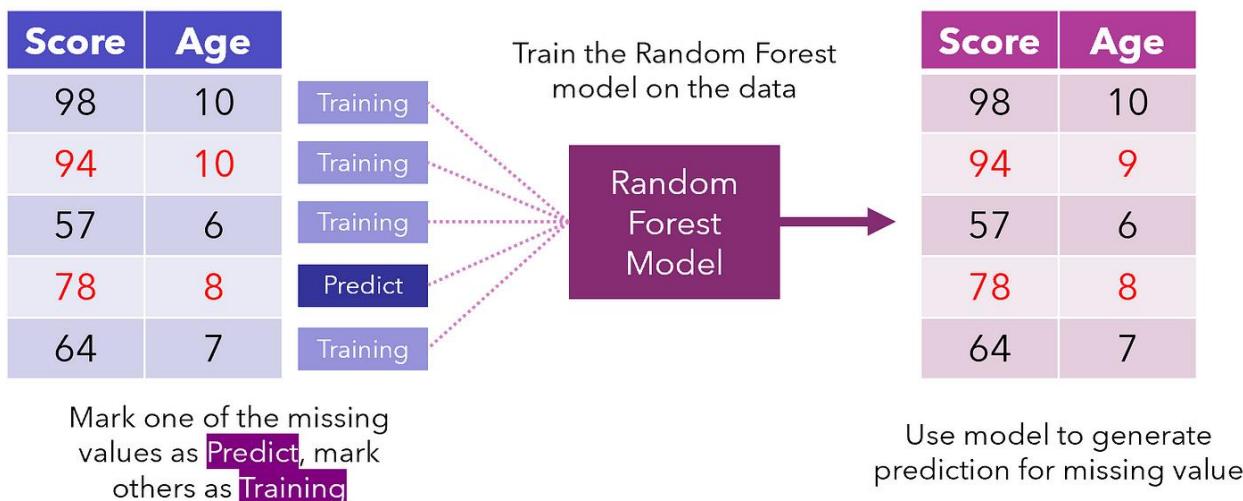


ภาพที่ 2.2 การเติมค่าสูญหายด้วยวิธีการประมาณค่าเชิงเส้น (Huang, 2021)

#### 2.1.4.2 การเติมค่าสูญหายด้วยวิธี MissForest

วิธี MissForest เป็นวิธีการเติมค่าสูญหายที่ใช้การเรียนรู้ของเครื่องในการทำนายค่าที่สูญหาย โดยอาศัยอัลกอริทึมการสุ่มป้าไม้ (Random Forest) ในการสร้างแบบจำลองการทำนาย วิธีนี้สามารถจัดการกับข้อมูลที่มีความไม่เป็นเชิงเส้น และสามารถจัดการกับข้อมูลที่มีหลายประเภทได้ดี ไม่ว่าจะเป็นข้อมูลเชิงปริมาณ หรือข้อมูลเชิงหมวดหมู่ โดย MissForest ได้รับการพิสูจน์ว่ามีประสิทธิภาพสูงในการเติมค่าสูญหายและสามารถรักษาความสมบูรณ์ของข้อมูลได้ดี

หลักการทำงานของ MissForest จะเริ่มจากการประมาณค่าเบื้องต้น (Initialization) โดยข้อมูลที่สูญหายไปในแต่ละตัวแปร (Feature) จะถูกแทนที่ด้วยค่าที่ประมาณได้ในขั้นต้น หากเป็นตัวแปรเชิงปริมาณจะใช้ค่าเฉลี่ยหรือค่ามัธยฐานในการแทนที่ สำหรับตัวแปรเชิงหมวดหมู่ (Categorical Data) จะถูกแทนที่ด้วยฐานนิยมเพื่อให้สามารถเริ่มต้นการประมาณได้ จากนั้นจะใช้การวนซ้ำแบบใช้ Random Forest สำหรับแต่ละตัวแปรที่มีข้อมูลหายไป (Feature with Missing Values) จะถูกตั้งให้เป็นตัวแปรเป้าหมาย (Target Variable) โดยที่ตัวแปรอื่น ๆ จะถูกใช้เป็นตัวแปรอิสระ (Predictor Variables) จากนั้นใช้ Random Forest ซึ่งเป็นแบบจำลองการเรียนรู้ที่ประกอบด้วยต้นไม้ตัดสินใจหลายต้น (Decision Trees) เพื่อประมาณค่าของตัวแปรที่หายไป โดยการฝึกแบบจำลอง Random Forest กับตัวแปรที่ไม่มีค่าหายไปในชุดข้อมูลนั้น เมื่อแบบจำลองเรียนรู้เสร็จสิ้น จะใช้แบบจำลองนั้นในการทำนายค่าของตัวแปรที่หายไป โดยค่าใหม่ที่ได้จากการคาดการณ์ของ Random Forest จะถูกนำมาแทนที่ค่าที่หายไปเดิม และวนทำขั้นตอนนี้กับตัวแปรอื่น ๆ ที่มีค่าหายไปจนกว่าจะไม่มีการเปลี่ยนแปลงในค่าเหล่านี้ หรือถึงจำนวนรอบของการวนซ้ำที่ตั้งไว้ เมื่อถึงการหยุดของการวนซ้ำ (Stopping Criterion) จะมีการหยุดเมื่อการเปลี่ยนแปลงระหว่างการทำนายของรอบล่าสุดที่มีค่าน้อยกว่าค่ากำหนด เช่น ค่าคลาดเคลื่อนกำลังสองเฉลี่ย (Mean Squared Error) ระหว่างค่าที่ประมาณได้ในการวนซ้ำปัจจุบันและค่าก่อนหน้า หรือถึงจำนวนรอบที่กำหนดไว้ (Stekhoven & Bühlmann, 2012)



ภาพที่ 2.3 การเติมค่าสูญหายด้วยวิธี MissForest (Ye, 2020)

### 2.1.5 เทคนิคการเรียนรู้เชิงลึก (Deep Learning; DL)

การเรียนรู้เชิงลึก (Deep Learning) เป็นเทคนิคในการสร้างปัญญาประดิษฐ์โดยใช้การเรียนแบบโครงข่ายประสาทของมนุษย์ โดยนำโครงข่ายประสาทเทียม (Neural Networks) มาซ้อนกันหลาย ๆ ชั้น (layers) เพื่อให้เรียนรู้ข้อมูลตัวอย่าง ประมวลผลและตัดสินใจจากข้อมูลที่ได้รับมา สามารถปรับปรุงผลลัพธ์การตัดสินใจได้ด้วยตัวเอง โดยไม่ต้องอาศัยการฝึกสอนจากมนุษย์ หรือให้ความรู้พื้นฐานไว้ล่วงหน้า สามารถวิเคราะห์และเรียนรู้จากข้อมูลที่มีความซับซ้อนได้ดี เช่น ภาพ เสียง ข้อมูลอนุกรมเวลา และข้อความ (LeCun et al., 2015) เทคนิคนี้ได้รับความนิยมเป็นอย่างมากในงานวิจัยทางการแพทย์เนื่องจากสามารถเรียนรู้และวิเคราะห์รูปแบบของข้อมูลที่มีความซับซ้อนสูง เช่น ข้อมูลสัญญาณชีพ ภาพทางการแพทย์ และข้อมูลประวัติผู้ป่วย ในการทำนายภาวะต่างๆ เช่น การวินิจฉัยโรค การทำนายความเสี่ยง และการวิเคราะห์ภาพ MRI ด้วยคลื่นแม่เหล็กไฟฟ้า (Bakator & Radosav, 2018)

ในปัจจุบันได้มีการพัฒนาอัลกอริทึมการเรียนรู้เชิงลึกในรูปแบบต่าง ๆ ขึ้นมาเพื่อใช้ในการวิเคราะห์ข้อมูลที่เป็นลำดับ (Sequences) หรือข้อมูลอนุกรมเวลา (Time series) เช่น Convolutional Neural Network (CNN), Recurrent Neural Networks (RNN), Gated Recurrent Units (GRU), Long Short-Term Memory (LSTM) และ Transformer เป็นต้น

#### 2.1.5.1 โครงข่ายประสาทเทียม (Artificial Neural Networks; ANN)

โครงข่ายประสาทเทียม (Artificial Neural Networks: ANN) คือแบบจำลองทางคณิตศาสตร์ที่เลียนแบบโครงสร้างและการทำงานของสมองมนุษย์ ใช้สำหรับการเรียนรู้และประมวลผลข้อมูลที่ซับซ้อนโดยการฝึกแบบจำลองผ่านข้อมูลที่มีความซับซ้อน โครงข่ายประสาทเทียมประกอบไปด้วยชั้นของหน่วยประสาท (Neurons) ซึ่งสามารถเชื่อมต่อกันได้หลายชั้น ทำให้เกิดความสามารถในการเรียนรู้และจำรูปแบบที่ซับซ้อนในข้อมูล (Walczak & Cerpa, 2003) โครงสร้างพื้นฐานของ ANN ประกอบไปด้วย 3 ส่วน ได้แก่

##### (1) ชั้นนำเข้า (Input Layer)

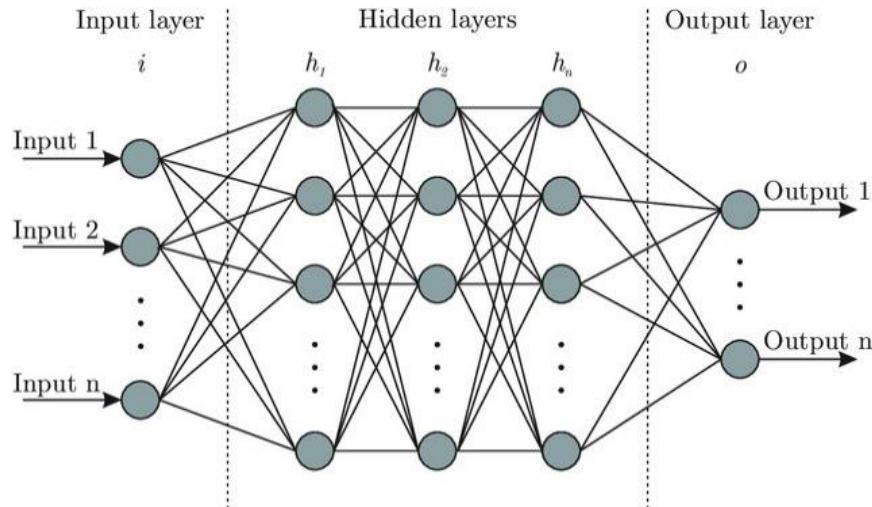
เป็นชั้นแรกที่รับข้อมูลเข้าสู่ระบบข้อมูลจะถูกแปลงเป็นตัวเลขหรือเวกเตอร์เพื่อนำไปประมวลผลต่อในชั้นถัดไป โดยข้อมูลอาจมาจากภาพ เสียง หรือข้อมูลตัวเลขที่เป็นตัวแทนของปัญหาที่ต้องการวิเคราะห์

##### (2) ชั้นซ่อน (Hidden Layer)

ชั้นนี้เป็นที่ที่กระบวนการประมวลผลที่ซับซ้อนเกิดขึ้น แต่ละหน่วยประสาทในชั้นนี้จะได้รับน้ำหนัก (Weights) ที่กำหนดค่าเพื่อช่วยให้โครงข่ายสามารถจับคู่ข้อมูลอินพุตกับผลลัพธ์ที่ถูกต้องได้ ชั้นซ่อนสามารถมีหลายชั้นในโครงข่ายเชิงลึก (Deep Neural Networks: DNN)

##### (3) ชั้นผลลัพธ์ (Output Layer)

เป็นชั้นสุดท้ายของโครงข่ายที่ทำการสร้างผลลัพธ์ ซึ่งอาจเป็นการจำแนกประเภท (Classification) หรือการทำนายค่าเชิงปริมาณ (Regression) ทั้งนี้ขึ้นอยู่กับประเภทของงานที่ใช้ (Bre et al., 2018)



ภาพที่ 2.4 โครงข่ายประสาทเทียม (Bre et al., 2018)

ในกระบวนการฝึก ANN ข้อมูลจะถูกส่งผ่านจากชั้นอินพุตไปยังชั้นเอ้าต์พุตโดยใช้วิธีการคำนวณแบบ Forward Propagation ซึ่งเป็นกระบวนการส่งข้อมูลไปข้างหน้าในโครงข่าย โดยข้อมูลจะถูกคำนวณผ่านชั้นต่าง ๆ จากชั้นอินพุตผ่านชั้นชั้นจนถึงชั้นเอ้าต์พุต (LeCun et al., 2015) ซึ่งให้ผลลัพธ์เป็นต้นที่ทำนายจากแบบจำลองผลลัพธ์นี้จะถูกนำไปเปรียบเทียบกับค่าจริง (Target) เพื่อคำนวณค่าความคลาดเคลื่อน (Error) ว่าผลลัพธ์ที่แบบจำลองคาดการณ์นั้นต่างจากค่าจริงมากน้อยแค่ไหน จากนั้นจะทำการย้อนกลับไปปรับปรุงน้ำหนักของโครงข่ายผ่านกระบวนการ Backpropagation ซึ่งเป็นการถ่ายทอดค่าความคลาดเคลื่อนจากชั้นเอ้าต์พุตย้อนกลับผ่านชั้นต่าง ๆ ของโครงข่ายไปยังชั้นอินพุต (Rumelhart et al., 1986) ในขั้นตอนนี้ ค่าความคลาดเคลื่อนจะถูกใช้ในการปรับปรุงน้ำหนัก (Weights) และค่าอคติ (Bias) ของโครงข่าย เพื่อให้โครงข่ายสามารถเรียนรู้และทำนายข้อมูลใหม่ได้ดีขึ้นในการฝึกครั้งถัดไป

การฝึก ANN ให้มีประสิทธิภาพนั้นขึ้นอยู่กับการปรับค่าพารามิเตอร์หลายตัว โดยเฉพาะอย่างยิ่ง อัตราการเรียนรู้ (Learning Rate), ขนาดของแบตช์ (Batch Size), และจำนวนจำนวนรอบของการฝึก (Epochs) (Bengio, 2012) การเลือกอัตราการเรียนรู้ที่เหมาะสมมีความสำคัญอย่างยิ่งต่อประสิทธิภาพของการเรียนรู้ (Smith, 2018) นอกจากนี้ การเลือกขนาดของแบตช์ที่เหมาะสมช่วยสร้างสมดุลระหว่างความเสถียรของการเรียนรู้และความเร็วในการฝึก (Goodfellow et al., 2016) ดังนี้

(1) อัตราการเรียนรู้ (Learning Rate) จะกำหนดความเร็วในการปรับปรุงน้ำหนักของแบบจำลองในแต่ละรอบการเรียนรู้ หากอัตราการเรียนรู้สูงเกินไป อาจทำให้แบบจำลองกระโดดข้ามค่าเหมาะสม (Optimal Value) ไปมาทำให้ไม่สามารถหาค่าเฉลี่ยที่ดีที่สุดได้ แต่หากอัตราการเรียนรู้ต่ำเกินไปจะทำให้แบบจำลองเรียนรู้ช้า การกำหนดค่าอัตราการเรียนรู้ที่เหมาะสมจึงเป็นสิ่งสำคัญเพื่อให้การเรียนรู้ราบรื่นและมีประสิทธิภาพ

(2) ขนาดของแบตช์ (Batch Size) คือจำนวนข้อมูลตัวอย่างที่ถูกใช้ในการคำนวณปรับปรุงน้ำหนักต่อหนึ่งรอบ (Iteration) แบตช์ขนาดใหญ่จะทำให้การปรับปรุงเสถียร แต่ใช้เวลาและหน่วยความจำมากอาจทำให้การฝึกซัลลง ในขณะที่แบตช์ขนาดเล็กจะทำให้การเรียนรู้เร็วขึ้น และใช้หน่วยความจำน้อยกว่า แต่ค่าที่ได้อาจไม่เสถียร การเลือกขนาดของแบตช์ที่เหมาะสมช่วยให้แบบจำลองเรียนรู้ได้ดีขึ้นในแต่ละรอบการฝึก (Smith, 2018)

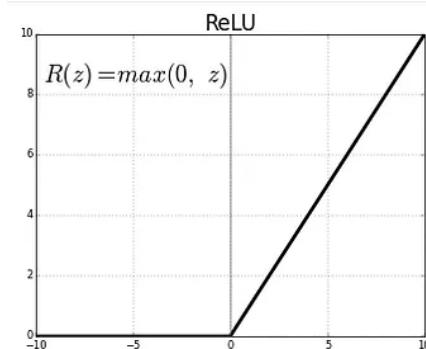
(3) จำนวนรอบของการฝึก (Epoch) คือจำนวนครั้งที่แบบจำลองได้เรียนรู้ข้อมูลทั้งหมดในชุดข้อมูลฝึก (Training Data) การเพิ่มจำนวนรอบของการฝึก จะช่วยให้แบบจำลองมีโอกาสได้เรียนรู้จากข้อมูลมากขึ้น แต่ถ้าใช้จำนวนรอบของการฝึกมากเกินไปโดยไม่มีการปรับปรุงเทคนิคอื่นๆ อาจทำให้เกิด Overfitting เนื่องจากแบบจำลองจะเริ่มจำข้อมูลฝึกมากเกินไปแทนที่จะเรียนรู้จากรูปแบบของข้อมูล แต่ถ้ามีน้อยเกินไปแบบจำลองอาจยังไม่เรียนรู้ข้อมูลเพียงพอ (Bengio, 2012)

ในโครงข่ายประสาทเทียม การทำงานของหน่วยประสาทแต่ละตัวจะถูกควบคุมโดยฟังก์ชันการกระตุ้น (Activation Function) ซึ่งเป็นฟังก์ชันทางคณิตศาสตร์ที่ใช้ในการเปลี่ยนแปลงผลลัพธ์จากการคำนวณน้ำหนัก (Weights) และอคติ (Bias) ให้กลไกเป็นค่าที่สามารถส่งต่อไปยังหน่วยประสาทในขั้นถัดไปได้ การเลือก Activation Function ที่เหมาะสมจะส่งผลต่อความสามารถในการเรียนรู้และการหาผลลัพธ์ของโครงข่ายประสาทเทียม ฟังก์ชันการกระตุ้นที่ใช้กันอย่างแพร่หลาย ได้แก่

(1) ReLU (Rectified Linear Unit) เป็นฟังก์ชันที่นิยมใช้ในโครงข่ายประสาทเทียม โดยเฉพาะในโครงข่ายเชิงลึก (Deep Neural Networks) โดยฟังก์ชัน ReLU มีการคำนวณที่ง่ายและช่วยให้การเรียนรู้เป็นไปอย่างรวดเร็ว โดยนิยามฟังก์ชัน ReLU คือ

$$R(z) = \max(0, z)$$

หมายความว่า ถ้าค่าที่คำนวณได้ต่ำกว่า 0 ฟังก์ชันจะให้ค่าเป็น 0 แต่ถ้าค่ามากกว่า 0 ฟังก์ชันจะให้ค่าเท่ากับค่าที่คำนวณได้ (He et al., 2015) ข้อดีของ ReLU คือการลดปัญหาค่าต่ำเกินไป (Vanishing Gradient) ซึ่งมักเกิดในฟังก์ชันอื่นๆ แต่ ReLU อาจมีปัญหา Dead Neurons ซึ่งเกิดจากค่าคงที่ 0 ตลอดทำให้หน่วยประสาทบางตัวไม่ถูกฝึกอย่างเหมาะสม (Maas et al., 2013)

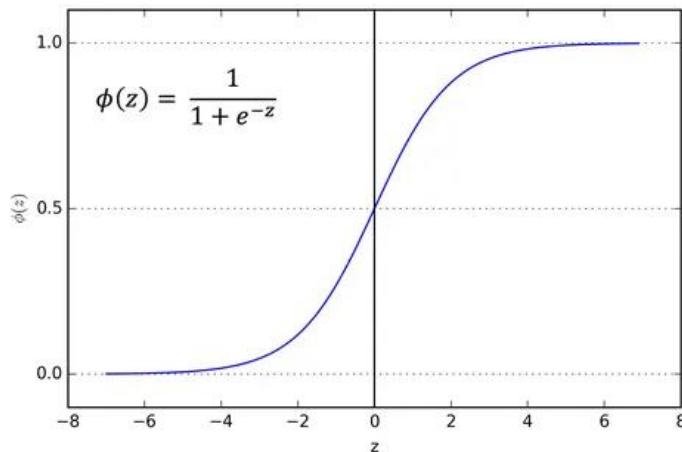


ภาพที่ 2.5 Rectified Linear Unit Function (ReLU) (Sharma, 2017)

(2) Sigmoid Function Sigmoid Function เป็นฟังก์ชันที่นิยมใช้ในโครงข่ายประสาทเทียมที่ต้องการจำแนกข้อมูลออกเป็นประเภทต่างๆ (Classification) ฟังก์ชันนี้จะให้ค่าผลลัพธ์อยู่ระหว่าง 0 ถึง 1 โดยนิยามของฟังก์ชันคือ

$$\phi(z) = \frac{1}{1 + e^{-z}}$$

ฟังก์ชัน Sigmoid ช่วยให้ผลลัพธ์อยู่ในช่วงที่คงที่ ซึ่งเหมาะสมสำหรับการใช้งานในการจำแนกประเภทที่ต้องการให้ผลลัพธ์เป็นความน่าจะเป็น (LeCun et al., 2012) อย่างไรก็ตาม ฟังก์ชันนี้อาจเกิดปัญหา Vanishing Gradient เมื่อค่าของ  $x$  มีขนาดใหญ่หรือน้อยเกินไป ซึ่งทำให้การฝึกแบบจำลองเป็นไปได้ยากขึ้น

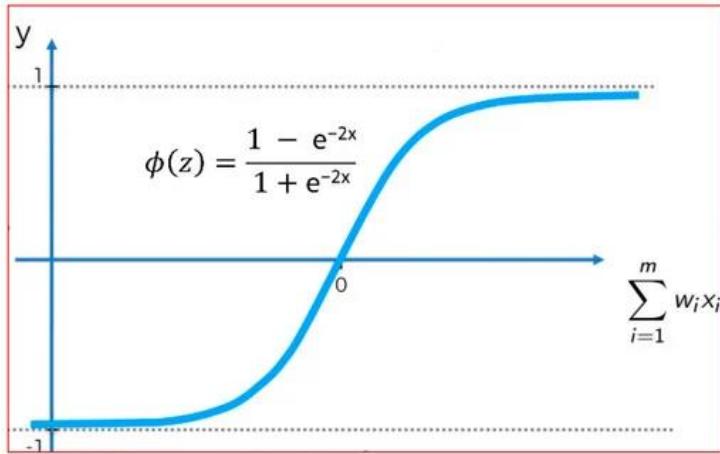


ภาพที่ 2.6 Sigmoid Function (Sharma, 2017)

(3) tanh (Hyperbolic Tangent) ฟังก์ชัน tanh มีลักษณะคล้ายคลึงกับ Sigmoid Function แต่ค่าผลลัพธ์จะอยู่ระหว่าง -1 ถึง 1 ซึ่งช่วยให้การเรียนรู้มีความคอมเพ็กซ์ขึ้นเมื่อเทียบกับ Sigmoid (Goodfellow et al., 2016) ฟังก์ชันนี้มีนิยามดังนี้

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

ฟังก์ชัน tanh ถูกใช้ป้อยในโครงข่ายประสาทเทียมที่มีความลึกระดับกลาง (Intermediate Depth) เนื่องจากสามารถจับความสัมพันธ์เชิงลบได้ดี เช่น ค่าที่ติดลบในข้อมูล (Kalman & Kwasny, 1992) อย่างไรก็ตาม ฟังก์ชันนี้ก็ยังมีปัญหา Vanishing Gradient คล้ายกับ Sigmoid แต่มีประสิทธิภาพดีกว่าในหลายกรณี

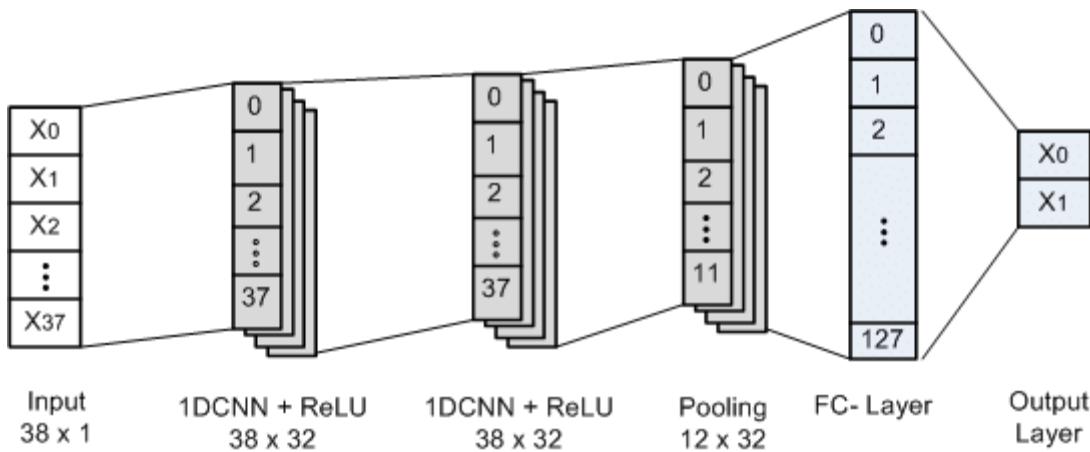


ภาพที่ 2.7 tanh Function (Khandelwal, 2019)

### 2.1.5.2 โครงข่ายประสาทแบบคอนโวโลชัน (Convolutional Neural Network; CNN)

โครงข่ายประสาทแบบคอนโวโลชัน (Convolution Neural Network; CNN) เป็นโครงข่ายประสาทเทียมชนิดหนึ่ง ซึ่งเป็นโครงข่ายประสาทเทียม (Neural Network) แบบพิเศษ ที่มีความสามารถในการจำแนกข้อมูลประเภทรูปภาพได้ดีกว่าโครงข่ายประสาทเทียมทั่วไป แนวคิดหลักของ CNN คือการที่ใช้ชั้น (Layer) ชนิดพิเศษ ที่เรียกว่า Convolution layer ซึ่งทำหน้าที่สกัดส่วนต่างๆ ของรูปภาพออกมามา เช่น เส้นขอบของวัตถุต่าง ๆ เพื่อให้แบบจำลองสามารถเรียนรู้ลักษณะและรูปแบบของภาพได้อย่างแม่นยำและมีประสิทธิภาพ (ชิตพงษ์ กิตตินราดร, 2563; Natthawat Natthawat, 2018) โดยทั่วไปแล้ว CNN ถูกออกแบบมาเพื่อจัดการข้อมูลที่เป็นรูปภาพซึ่งข้อมูลที่เป็นรูปภาพนั้นจะมีลักษณะเป็นข้อมูลขนาด 2 มิติ (2D CNN) ได้แก่ ความกว้าง (Width) และความสูง (Height)

นอกจากนี้ CNN ยังได้ถูกนำมาประยุกต์ใช้กับข้อมูลที่มีลักษณะเป็นลำดับ หรือข้อมูลที่มีลักษณะเป็น 1 มิติ (1D) หรือที่เรียกว่า โครงข่ายประสาทแบบคอนโวโลชัน 1 มิติ (1D Convolution Neural Network; 1D CNN) เป็นโครงสร้างของโครงข่ายประสาทที่ถูกออกแบบมาเพื่อทำงานกับข้อมูลที่เป็นลำดับเวลา (Time Series) หรือข้อมูลที่มีลักษณะเป็น 1 มิติ เช่น ข้อมูลอนุกรมเวลา (time series) สัญญาณที่มีลักษณะเป็นสเกลาร์ (scalar signals) ข้อมูลสัญญาณซีพ การเคลื่อนไหว หรือข้อมูลชีวภาพต่างๆ โครงข่ายนี้ใช้การคอนโวโลชันในการสกัดคุณลักษณะ (Features) ที่สำคัญจากข้อมูล เช่นเดียวกับ 2D CNN ซึ่งช่วยให้สามารถเรียนรู้รูปแบบของข้อมูลที่มีลักษณะเฉพาะตัวได้อย่างมีประสิทธิภาพ (Kiranyaz et al., 2021)



ภาพที่ 2.8 โครงข่ายประสาทแบบคอนโวลูชัน 1 มิติ (Cho et al., 2019)

### หลักการทำงานของ 1D CNN มีดังนี้

#### (1) Convolutional Layer

ในการสกัดคุณลักษณะ (features) ข้อมูลจะถูกส่งผ่านตัวกรอง (Filters) หรือเครื่องเนล (Kernels) ในชั้น Convolutional Layer ซึ่งเป็นชั้นแรก ๆ ของการสร้างแบบจำลอง CNN (LeCun et al., 2015) โดยเครื่องเนลแต่ละตัวจะสกัดคุณลักษณะเฉพาะที่สนใจออกมา เช่น ขอบหรือรูปร่างต่าง ๆ สำหรับข้อมูล 1 มิติ เครื่องเนลจะเป็นสเกลาร์ที่สเลต์ผ่านข้อมูลอินพุต (Input) เพื่อตึงคุณลักษณะเหล่านั้นออกมา กระบวนการนี้จะดำเนินการตามหลักการ Convolution ระหว่างอินพุตและเครื่องเนล ผลลัพธ์ที่ได้จะถูกนำเข้า Activation Function เช่น ReLU เพื่อสร้างผังคุณลักษณะ (Feature Map) ของแต่ละชั้น

ขนาดของผลลัพธ์จาก Convolution ขึ้นอยู่กับจำนวนก้าว (Stride) ที่ฟิลเตอร์สไลด์ผ่านข้อมูล และการใช้ Padding เพื่อเพิ่มขอบข้อมูลให้คงขนาดอินพุตเดิม หากค่า Stride ที่สูงจะทำให้ผลลัพธ์มีขนาดเล็กลง เมื่อออกจากเครื่องเนลสไลด์ผ่านข้อมูลด้วยก้าวที่กว้างขึ้น ขณะที่ Stride ที่ต่ำจะให้ผลลัพธ์ขนาดใหญ่ขึ้น และ Padding จะช่วยรักษาขนาดของอินพุตในแต่ละชั้น เพื่อให้ขนาดของผลลัพธ์จาก Convolution ไม่เล็กลง และช่วยให้แบบจำลองสามารถเรียนรู้รายละเอียดที่อยู่บริเวณขอบของข้อมูลได้ดีขึ้น

#### (2) Pooling Layer

หลังจากที่ได้คุณลักษณะจากชั้น Convolution แล้ว ข้อมูลจะถูกลดขนาดและลดความซับซ้อน ผ่าน Pooling Layer ซึ่งเป็นชั้นที่ใช้ลดขนาดข้อมูลและลดจำนวนพารามิเตอร์ที่ต้องเรียนรู้ ซึ่งช่วยลดความซับซ้อน และเพิ่มความเร็วในการประมวลผล เทคนิคที่ใช้บ่อยคือ Max Pooling หรือ Average Pooling ซึ่งจะเลือกค่า Maximum หรือค่าเฉลี่ยจากแต่ละกลุ่มของข้อมูลในแผนที่คุณลักษณะ เพื่อให้ได้ผลลัพธ์ใหม่ไปใช้คำนวณต่อ (Kiranyaz et al., 2021)

### 3) Fully Connected Layer

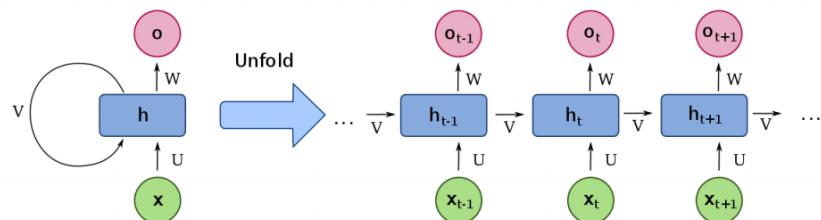
หลังจากผ่านหลายๆ ชั้น Convolution และ Pooling ข้อมูลจะถูกส่งผ่านไปยังชั้น Fully Connected (Dense Layer) ซึ่งคล้ายกับโครงข่ายประสาทเทียมทั่วไป เพื่อทำการรวมคุณลักษณะที่ได้จากชั้นก่อนหน้าและทำการจำแนกประเภทข้อมูล

### (4) Forward Propagation และ Backpropagation

ในขั้นตอนการฝึกโครงข่าย (Training) ข้อมูลจะถูกส่งผ่านจากชั้นอินพุตไปยังชั้นเอ้าต์พุต (Forward Propagation) ผลลัพธ์ที่ได้จะถูกนำมาเปรียบเทียบกับผลลัพธ์ที่ต้องการและคำนวณค่าความผิดพลาด (Error) จากนั้นค่าความผิดพลาดนี้จะถูกย้อนกลับไปปรับพารามิเตอร์ของโครงข่ายผ่านกระบวนการ Backpropagation ซึ่งจะปรับน้ำหนักของพิลเตอร์และอคติ (Bias) เพื่อให้โครงข่ายเรียนรู้และทำการคาดการณ์ได้แม่นยำมากขึ้น (Liu & Si, 2022)

#### 2.1.5.3 หน่วยความจำระยะสั้นระยะยาว (Long Short-Term Memory; LSTM)

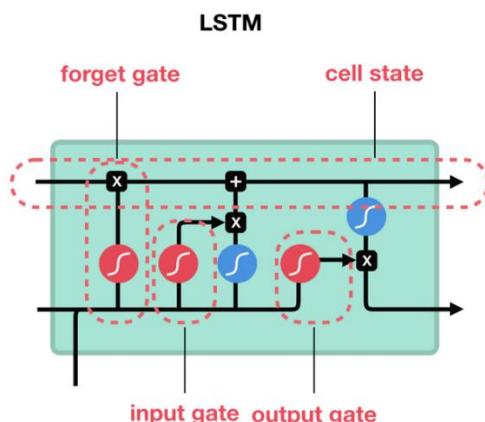
โครงข่ายประสาทแบบวนซ้ำ (Recurrent Neural Networks; RNN) เป็นแบบจำลองการเรียนรู้เชิงลึกที่ได้รับการฝึกฝนเพื่อประมวลผล และแปลงข้อมูลอินพุตเป็นเอ้าต์พุตข้อมูลตามลำดับ (Sequence) โดยใช้หลักการป้อนข้อมูลเข้า (Feed) นั่นคือการป้อนข้อมูลเข้าไปในแบบจำลองที่ละเอียดข้อมูลตามลำดับเวลา โดยสถานะภายในของแบบจำลองจะทำหน้าที่เก็บข้อมูลจากลำดับก่อนหน้าไว้เพื่อกลับมาเป็นอินพุตใหม่คู่กับอินพุตปกติเรียกว่า Hidden State หรือ Memory ซึ่งช่วยให้แบบจำลองจดจำรูปแบบของลำดับอินพุตได้ (Bisong, 2019; Surapong, 2019)



ภาพที่ 2.9 แผนภาพการทำงานของโครงข่ายประสาทแบบวนซ้ำ (RNN) (Saxena, 2023)

Long Short Term Memory Network (LSTM) เป็นโครงข่ายประสาทแบบวนซ้ำประภาคหนึ่งที่พัฒนามาจาก RNN (Hochreiter & Schmidhuber, 1997) ซึ่งถูกออกแบบมาเพื่อให้สามารถจดจำลำดับอินพุตที่ยาวนาน และแก้ปัญหาค่าต่ำเกินไป (Vanishing Gradient) ที่เกิดขึ้นในโครงสร้าง RNN โดยเฉพาะอย่างยิ่งเมื่อข้อมูลมีลำดับยาวหรือมีชั้นหลายชั้น (Bengio et al., 1994) ปัญหานี้เกิดขึ้นเมื่อค่า gradient ที่ต้องใช้ในการปรับน้ำหนักลดลงจนเกือบเป็นศูนย์ ทำให้แบบจำลองไม่สามารถปรับน้ำหนักได้อย่างถูกต้อง ส่งผลให้ไม่สามารถจดจำข้อมูลจากลำดับที่อยู่ห่างออกໄไปได้ นอกจากปัญหา Vanishing Gradient แล้ว ยังมีปัญหาค่าเกินขอบ (Exploding Gradient) ที่

เกิดจากค่า Gradient ที่ใช้ในการอัปเดตหน้าหักมีค่ามากเกินไปในระหว่างการเรียนรู้แบบ Backpropagation ซึ่งส่งผลให้แบบจำลองไม่เสถียร (Pascanu et al., 2013) ปัญหาทั้งสองนี้ส่งผลให้ RNN ไม่สามารถจำจำดับข้อมูลที่อยู่ไกลออกไปได้ดี ดังนั้n LSTM จึงถูกพัฒนาขึ้นมาเพื่อแก้ปัญหาดังกล่าว โดย LSTM นั้นมีการออกแบบที่ประกอบไปด้วย เกตลิม (Forget Gate), เกตนำเข้า (Input Gate), และเกตผลลัพธ์ (Output Gate) ที่ช่วยควบคุมการให้ของข้อมูล และช่วยให้แบบจำลองสามารถเก็บและจดจำข้อมูลลำดับที่สำคัญได้ดีขึ้น (Gers et al., 2000; Graves, 2012)



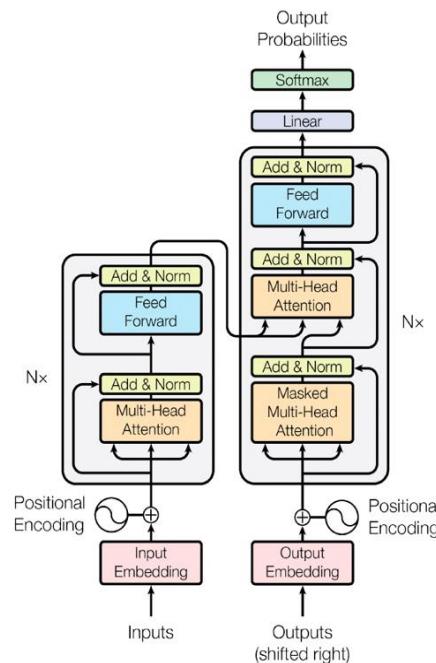
ภาพที่ 2.10 แผนภาพการทำงานของหน่วยความจำระยะสั้นระยะยาว (LSTM) (Verpalen, 2019)

จากภาพที่ 2.10 LSTM จะนำอินพุตจากเวลา ก่อนหน้ามาพิจารณาใน Forget Gate โดยจะทำหน้าที่ตัดสินใจว่าจะลบข้อมูลจากหน่วยความจำหรือไม่ โดยประเมินจากอินพุตปัจจุบัน และสถานะชั่วคราว (Hidden State) ก่อนหน้า คำนวนโดยใช้ฟังก์ชันซิกมอยด์ (Sigmoid Function) ซึ่งให้ค่าอยู่ระหว่าง 0 ถึง 1 โดย 0 คือไม่จำอะไรเลย และ 1 คือจำทุกอย่าง (Gers et al., 2000; Hochreiter & Schmidhuber, 1997) เมื่อแก้ไขหน่วยความจำของแบบจำลองและนำหนักอินพุต Input Gate จะตัดสินใจว่าควรเพิ่มข้อมูลใหม่เข้ามาในหน่วยความจำหรือไม่ โดยพิจารณาจาก อินพุตปัจจุบัน และ Hidden State ก่อนหน้า ซึ่งใน Input Gate จะใช้ฟังก์ชันซิกมอยด์ ในการทำหน้าที่กำหนดว่าค่าใดที่จะส่งต่อผ่านเครือข่าย ถ้าค่า Input Gate เข้าใกล้ศูนย์หมายถึงไม่ควรเพิ่มข้อมูลใหม่ ขณะที่ค่าอินพุตเกตเข้าใกล้ 1 หมายถึงการคงค่าไว้ และใน Input Gate มีการใช้ฟังก์ชัน tanh (Hyperbolic Tangent Activation Function) เพื่อให้ตัดสินว่าค่าอินพุตใหม่ที่เพิ่มเข้าไปในหน่วยความจำมีความสำคัญต่อแบบจำลองมากน้อยเพียงใดซึ่ง มีค่าอยู่ระหว่าง -1 ถึง 1 (Nelson, 2020) หลังจากพิจารณาอินพุตปัจจุบันและสถานะหน่วยความจำแล้ว Output Gate จะทำหน้าที่ตัดสินใจว่าจะส่งข้อมูลใดออกไปเป็น Hidden State ของลำดับเวลาปัจจุบัน ซึ่งใช้เป็นเอตพุตของ LSTM และส่งไปใช้ในลำดับเวลาต่อไป โดยค่าต่างๆใน Output Gate จะคำนวนโดยใช้ฟังก์ชันซิกมอยด์ เพื่อควบคุมว่าจะส่งข้อมูลจากหน่วยความจำออกไปมากน้อยเพียงใด นอกจากนี้ฟังก์ชัน tanh ยังใช้ในการประมวลผลข้อมูลในหน่วยความจำก่อนที่จะส่งออกมาเป็น Hidden State (GeeksforGeeks, 2023; Graves, 2012; Nelson, 2020)

#### 2.1.5.4 ทรานส์ฟอร์มเมอร์ (Transformer)

Transformer มีความสามารถในการจัดการกับข้อมูลที่มีลำดับได้ดีกว่าสถาปัตยกรรมแบบตั้งเดิม เช่น RNN หรือ LSTM โดย Transformer สามารถเรียนรู้บริบทและความสัมพันธ์ระหว่างข้อมูลในลำดับเวลาได้ดีผ่าน Attention Mechanism ซึ่งกลไก Attention Mechanism นี้เป็นส่วนที่ทำให้ Transformer มีประสิทธิภาพมากขึ้น ในการทำนายข้อมูลลำดับถัดไป แทนที่จะประมวลผลข้อมูลทีละช่วงเวลา แบบจำลองจะสามารถประมวลผลข้อมูลทั้งหมดพร้อมกันและระบุว่าส่วนใดของข้อมูลในลำดับก่อนหน้าที่มีความสำคัญที่สุดในการคาดการณ์ผลลัพธ์ในอนาคต กลไกนี้ทำงานโดยคำนวณความสัมพันธ์ระหว่างทุกจุดข้อมูลในลำดับเวลาเดียวกัน ซึ่งทำให้ Transformer สามารถเรียนรู้จากข้อมูลทั้งหมดและให้ความสำคัญกับข้อมูลที่เกี่ยวข้องกับการทำนายลำดับถัดไปได้ดียิ่งขึ้น (Han et al., 2022)

Transformer ประกอบด้วยสองส่วนสำคัญคือ ตัวเข้ารหัส (Encoder) และตัวถอดรหัส (Decoder) ในการทำนายข้อมูลลำดับถัดไป Encoder จะอ่านลำดับข้อมูลเวลาทั้งหมดที่เกิดขึ้นก่อนหน้าแล้ว รับอินพุตเข้ามาและทำการสร้างตัวแทน (Representation) ของอินพุต เรียกว่าตัวแปร (features) ส่วนนี้เป็นการพยายามทำความเข้าใจข้อมูลเพื่อนำไปเป็นตัวแทน จากนั้น Decoder จะรับตัวแปรที่ได้มาจากการส่วนของ Encoder พร้อมกับอินพุตเพื่อทำการสร้างเอ็ตพุตออกมากเพื่อทำนายลำดับถัดไปจากข้อมูลที่มีอยู่ (Kanyawee, 2021) โดยทั้ง Encoder และ Decoder มีขั้นตอนการทำงาน ดังนี้



ภาพที่ 2.11 สถาปัตยกรรมของ Transformer (Vaswani et al., 2017)

จากภาพที่ 2.11 ในส่วนของ Encoder ข้อมูลอินพุตจะถูกส่งไปยัง Input Embedding ซึ่งข้อมูลอินพุตจะถูกแปลงเป็นเวกเตอร์ (Embedding) ที่มีขนาด (Shape) ที่แน่นอนเพื่อใช้เป็นอินพุตสำหรับแบบจำลอง

จากนั้น Positional Encoding จะถูกนำมาเพิ่มข้อมูลตำแหน่งให้กับเวกเตอร์นี้ โดยใช้ฟังก์ชัน Sine และ Cosine ดังสมการ เพื่อให้แบบจำลองเข้าใจลำดับเวลาของข้อมูล

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000(\frac{2i}{d_{model}})}\right)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000(\frac{2i}{d_{model}})}\right)$$

เมื่อ  $pos$  คือ ตำแหน่งของข้อมูลในลำดับเวลา

$i$  คือ ดัชนีของมิติในเวกเตอร์

$d_{model}$  คือ ขนาดของเวกเตอร์ในแบบจำลอง

การใช้ Sine และ Cosine ใน Positional Encoding สำหรับข้อมูล ICU ช่วยให้แบบจำลอง Transformer สามารถรับรู้และเข้าใจลำดับเวลาของข้อมูลทางการแพทย์ได้อย่างมีประสิทธิภาพมากขึ้น โดยช่วยจับความสัมพันธ์ระหว่างข้อมูลที่เกิดขึ้นในเวลาต่าง ๆ ซึ่งมีความสำคัญต่อการวิเคราะห์ทางการแพทย์ จากนั้น Self-Attention ใน Transformer จะใช้เทคนิค Multi-Head Attention เพื่อเปรียบเทียบข้อมูลภายในลำดับเดียวกันจากหลาย ๆ มุมมองในเวลาเดียวกัน (หลาย Attention Heads) การทำเช่นนี้ช่วยให้แบบจำลองเข้าใจความสัมพันธ์ระหว่างข้อมูลในหลากหลายลักษณะได้อย่างมีประสิทธิภาพมากยิ่งขึ้น (Han et al., 2022) หลังจากนั้นแต่ละ Attention Head จะถูกรวม (Concat) เพื่อส่งต่อไปยัง Add and Layer Normalization (Add & Norm) โดยผลลัพธ์จาก Multi-Head Attention จะถูกนำมารวมกับอินพุตเดิมผ่านการทำการบวกเข้าด้วยกัน (Residual Connection) เป็นการช่วยแก้ปัญหา Gradient vanishing หรือ Exploding จากนั้นจะทำการ Normalization ด้วย Layer Normalization เพื่อปรับค่าของข้อมูลให้อยู่ในช่วงที่เหมาะสม เพื่อเป็นการลดการเปลี่ยนแปลงที่มากเกินไปในค่าผลลัพธ์ จากนั้นจะเข้าสู่ Feed Forward เป็นเลเยอร์ที่เมื่อข้อมูลผ่าน Attention และจะถูกส่งเข้าโครงข่ายประสาทแบบ Fully Connected ที่ประกอบด้วยเลเยอร์แบบ Linear และฟังก์ชัน Activation เช่น ReLU เพื่อแปลงข้อมูลให้มีลักษณะใหม่ จากนั้นจะเข้าสู่เลเยอร์ Add & Norm ที่เป็นขั้นตอนสุดท้ายของ Encoder แต่ละเลเยอร์จะการทำ Residual Connection และ Normalization อีกครั้ง ก่อนจะส่งผลลัพธ์เข้าสู่เลเยอร์ถัดไป

ในส่วนของ Decoder ข้อมูลที่เป็นเป้าหมาย (Target) จะถูกส่งไปยัง Output Embedding & Positional Encoding เป็นขั้นตอนที่ข้อมูลเป้าหมาย จะถูกแปลงเป็นเวกเตอร์ผ่าน Embedding เช่นเดียวกับอินพุต และจะถูกเพิ่ม Positional Encoding เข้าไปเพื่อบอกลำดับของข้อมูล จากนั้นข้อมูลเป้าหมายจะถูกส่งไปยังเลเยอร์ Masked Multi-Head Attention เป็นเลเยอร์ที่ Attention ในขั้นตอนนี้จะถูก Masked หรือปิดบังค่าบางส่วนของ

ข้อมูล เพื่อให้แบบจำลองสามารถทำนายข้อมูลลำดับถัดไปโดยอิงจากลำดับก่อนหน้าเท่านั้น (Prevent Look-Ahead) เมื่อเข้าสู่ Multi-Head Attention ตัว Attention ขั้นตอนนี้จะนำผลลัพธ์จาก Encoder มาใช้ร่วมกับ Output Embedding เพื่อให้แบบจำลองเข้าใจความสัมพันธ์ระหว่างข้อมูลอินพุตของตัวแปร และเป้าหมาย จากนั้นจะเข้าสู่เลเยอร์ Add & Norm ในขั้นตอนนี้จะมีการทำ Residual Connection และ Normalization เช่นเดียวกับใน Encoder และจะเข้าสู่เลเยอร์ Feed Forward เพื่อให้ข้อมูลถูกแปลงในเลเยอร์ Fully Connected อีกรอบ จากนั้นจะเข้าสู่เลเยอร์ Add & Norm เพื่อทำ Residual Connection และ Normalization ก่อนส่งต่อไปยังเลเยอร์ถัดไป

สุดท้ายนี้ผลลัพธ์จาก Decoder จะถูกส่งไปยังเลเยอร์ Linear เพื่อลดขนาดของเวกเตอร์ และตามด้วย Softmax เพื่อแปลงผลลัพธ์ให้อยู่ในรูปของความน่าจะเป็นสำหรับการทำนายผลลัพธ์ในแต่ละลำดับของข้อมูล อนุกรมเวลา (Han et al., 2022; Vaswani et al., 2017; Wen et al., 2023)

### 2.1.6 การป้องกัน Overfitting

Overfitting คือปัญหาที่เกิดขึ้นเมื่อแบบจำลองสามารถเรียนรู้รายละเอียดของข้อมูลฝึกสอน (training data) ได้มากเกินไป ทำให้สามารถจำข้อมูลได้ดีเกินไปแต่ไม่สามารถทำนายข้อมูลใหม่ (testing data) ได้อย่างมีประสิทธิภาพ ซึ่งส่งผลให้ความแม่นยำในการทำนายลดลง โดยเฉพาะเมื่อทำงานกับข้อมูลที่มีความซับซ้อนหรือมีจำนวนข้อมูลน้อยเกินไป

ปัญหานี้มักเกิดขึ้นในแบบจำลองที่มีพารามิเตอร์จำนวนมาก เช่น โครงข่ายประสาทเทียมเชิงลึก (Deep Neural Networks) เนื่องจากแบบจำลองสามารถปรับพารามิเตอร์ตามข้อมูลฝึกได้มากเกินไป การป้องกัน Overfitting มีหลายวิธีที่สามารถนำไปใช้เพื่อให้แบบจำลองสามารถเรียนรู้ข้อมูลได้อย่างมีประสิทธิภาพ โดยไม่สูญเสียความสามารถในการทำนายข้อมูลใหม่ (Goodfellow et al., 2016) ซึ่งสามารถทำได้ผ่านหลายเทคนิค ดังนี้

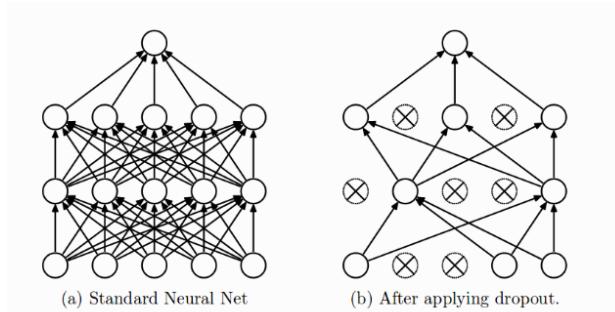
#### (1) Batch Normalization

Batch Normalization เป็นเทคนิคที่ช่วยปรับค่าความแปรปรวนและค่าเฉลี่ยของข้อมูลในแต่ละชั้น (Layer) ให้อยู่ในช่วงที่มาตรฐาน ก่อนที่จะส่งต่อข้อมูลเข้าสู่ Activation Function ทำให้แบบจำลองสามารถเรียนรู้ได้เร็วขึ้นและทำให้การกระจายค่าของข้อมูลไม่กว้างเกินไป การใช้ Batch Normalization ยังช่วยให้แบบจำลองสามารถฝึกได้ในช่วงอัตราการเรียนรู้ (Learning Rate) ที่สูงขึ้น โดยลดปัญหา Exploding Gradient หรือ Vanishing Gradient ซึ่งเป็นอีกปัจจัยที่ส่งผลให้เกิด Overfitting (Ioffe & Szegedy, 2015)

#### (2) Dropout

Dropout คือเทคนิคการสุ่มปิดหน่วยประสาทบางส่วนในแต่ละชั้นของโครงข่ายระหว่างการฝึกโดยในแต่ละรอบของการฝึก (Epoch) หน่วยประสาทบางส่วนจะถูกปิดไม่ให้ทำงานชั่วคราว เทคนิคนี้ช่วยลดการพึ่งพา (Dependency) ของหน่วยประสาทใด ๆ ที่เป็นหน่วยเฉพาะ และส่งเสริมให้โครงข่ายสามารถเรียนรู้คุณลักษณะอื่น ๆ ของข้อมูลได้อย่างหลากหลายมากขึ้น โดยทั่วไป Dropout จะถูกใช้ในชั้น Fully Connected (Dense Layers) ซึ่งมัก

เป็นชั้นที่มีจำนวนพารามิเตอร์มากและมีโอกาสเกิด Overfitting สูง หากมีการเชื่อมต่อข้อมูลมากเกินไป (Srivastava et al., 2014)

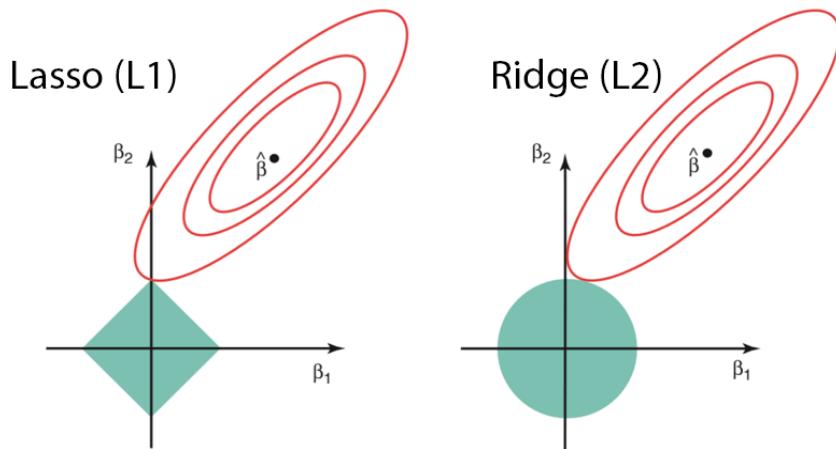


ภาพที่ 2.12 ตัวอย่างการทำงานของ Dropout (Srivastava et al., 2014)

### (3) Regularization

Regularization เป็นเทคนิคการป้องกัน Overfitting โดยการเพิ่มค่าปรับ (Penalty) ให้กับพารามิเตอร์ที่มีค่าสูงหรือน้ำหนักมากเกินไป เพื่อลดความซับซ้อนของแบบจำลอง (Girosi et al., 1995; Goodfellow et al., 2016) ได้แก่ Lasso regression หรือ L1 Regularization เป็นเทคนิคที่เพิ่มค่าปรับตามขนาดสัมบูรณ์ของน้ำหนักแต่ละตัว ( $|w|$ ) ทำให้แบบจำลองสามารถลดจำนวนพารามิเตอร์ที่ไม่จำเป็นลงได้ โดยเน้นการปรับน้ำหนักให้เป็นศูนย์ (Tibshirani, 1996) และ Ridge regression หรือ L2 Regularization เป็นเทคนิคที่เพิ่มค่าปรับตามกำลังสองของน้ำหนักแต่ละตัว ( $w^2$ ) ซึ่งส่งผลให้แบบจำลองพยายามรักษาขนาดน้ำหนักทุกตัวให้มีขนาดเล็กอยู่เสมอ เป็นการลดน้ำหนักทั้งหมดให้มีค่าต่ำลง โดย Regularization จะช่วยลดการปรับพารามิเตอร์ที่มากเกินไปใน Loss Function ทำให้แบบจำลองไม่เรียนรู้ข้อมูลฝึกมากเกินไปจนเกินไป ซึ่งเป็นการควบคุมความซับซ้อนของแบบจำลองให้อยู่ในระดับที่เหมาะสม (Hoerl & Kennard, 1970)

ความแตกต่างระหว่าง Lasso regression และ Ridge regression คือ Lasso regression จะเพิ่มค่าปรับตามมูลค่าสัมบูรณ์ของค่าสัมประสิทธิ์ ( $|w|$ ) ซึ่งจะบังคับให้ค่าสัมประสิทธิ์ของตัวแปรบางตัวเป็นศูนย์ (Tibshirani, 1996) ส่งผลให้เกิดการคัดเลือกตัวแปร (Feature Selection) เพราะตัวแปรที่ไม่สำคัญจะถูกกำจัดออกไป ในขณะที่ Ridge จะเพิ่มค่าปรับตามผลรวมกำลังสองของค่าสัมประสิทธิ์ ( $w^2$ ) ซึ่งช่วยลดค่าน้ำหนักของตัวแปรทั้งหมดให้ใกล้ศูนย์ (Hoerl & Kennard, 1970) แต่ไม่ทำให้ค่าสัมประสิทธิ์เป็นศูนย์ นั่นหมายความว่าจะไม่มีการคัดเลือกตัวแปรออกจากแบบจำลอง อีกทั้ง Lasso regression จะเหมาะสมสำหรับข้อมูลที่มีจำนวนตัวแปรมากและบางตัวแปรอาจไม่สำคัญ แต่ Ridge regression จะเหมาะสมสำหรับข้อมูลที่มีปัญหาความสัมพันธ์กันระหว่างตัวแปร (Multicollinearity) โดยจะลดความเข้มข้นของตัวแปรที่มีความสัมพันธ์กันสูง แต่ยังคงเก็บตัวแปรทั้งหมดไว้ในแบบจำลอง (Zou & Hastie, 2005)



ภาพที่ 2.13 Regularization ประเพณฑ์ต่าง ๆ (Mami et al., 2021)

### 2.1.7 Area Under the Receiver Operating Characteristics (AUC-ROC Curve)

หนึ่งในเครื่องมือในการประเมินประสิทธิภาพของแบบจำลองในการทำนายผลลัพธ์ประเพณฑ์การจำแนกประเพณฑ์ (classification) คือ Confusion Matrix โดยที่จะใช้ในปัญหาการจำแนกสองกลุ่ม (binary classification) แต่สามารถใช้กับหลายการจำแนกประเพณฑ์หลายกลุ่มได้ โดยมีแนวคิดการวัดว่า สิ่งที่แบบจำลองทำนาย กับสิ่งที่เกิดขึ้นจริงมีสัดส่วนเป็นอย่างไร (Pagon, 2019) โดยสร้างของ Confusion Matrix ประกอบด้วย 4 ส่วน ดังนี้

- 1) True Positive (TP) คือจำนวนการทำนายที่ถูกต้องว่าผลลัพธ์เป็น "บวก" (positive) และผลลัพธ์จริงก็เป็นบวก
- 2) True Negative (TN) คือจำนวนการทำนายที่ถูกต้องว่าผลลัพธ์เป็น "ลบ" (negative) และผลลัพธ์จริงก็เป็นลบ
- 3) False Positive (FP) หรือ Type I Error คือจำนวนการทำนายว่าผลลัพธ์เป็นบวก แต่ผลลัพธ์จริงเป็นลบ (แบบจำลองทำนายผิด)
- 4) False Negative (FN) หรือ Type II Error คือจำนวนการทำนายว่าผลลัพธ์เป็นลบ แต่ผลลัพธ์จริงเป็นบวก (แบบจำลองทำนายผิด)

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

ภาพที่ 2.14 การวัดประสิทธิภาพแบบจำลองจาก Confusion Matrix (Chengz, 2019)

การประเมินประสิทธิภาพแบบจำลองถือเป็นสิ่งที่สำคัญสำหรับแบบจำลองการจำแนกประเภท AUC-ROC Curve เป็นตัววัดประสิทธิภาพของแบบจำลองในการทำนายที่ได้รับความนิยมสูง โดยเฉพาะในงานที่เกี่ยวข้องกับการทำนายประเภทการจำแนกแบบไบนาเรีย (Binary Classification) โดย พื้นที่ใต้เส้นโค้ง (Area Under Curve; AUC) จะคำนวณพื้นที่ใต้กราฟของลักษณะการทำงานของตัวรับ (Receiver Operating Characteristic; ROC) ซึ่งแสดงความสัมพันธ์ระหว่างอัตราการทำนายผลบวกที่ถูกต้อง (True Positive Rate; TPR) และอัตราการทำนายผลบวกที่ผิดพลาด (False Positive Rate; FPR) ซึ่งค่า AUC-ROC มีค่าอยู่ระหว่าง 0 ถึง 1 โดยค่าที่สูงใกล้ 1 หมายถึงแบบจำลองมีความสามารถในการแยกแยะระหว่างกลุ่มเป้าหมายได้ดี ยิ่ง ROC สูงยิ่งบ่งบอกว่าแบบจำลองมีความสามารถแม่นยำในการทำนายผลลัพธ์ (Narkhede, 2018; Pasith, 2022)

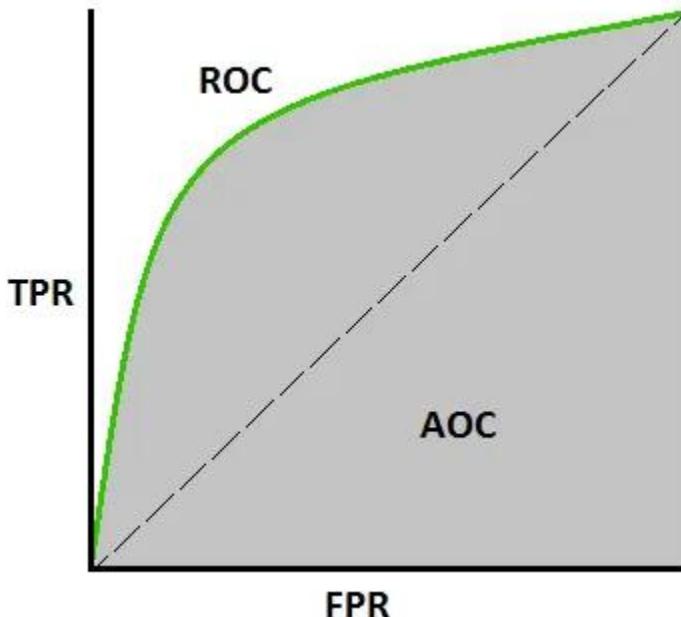
AUC-ROC Curve จะถูกคำนวณโดยใช้ TPR เทียบกับ FPR โดยที่ TPR อยู่ในแนวแกน y และ FPR อยู่ในแนวแกน x ดังภาพที่ 2.9

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = 1 - Specificity$$

$$Specificity = \frac{TN}{TN + FP}$$

เมื่อ Specificity คือ ค่าความจำเพาะ



ภาพที่ 2.15 AUC-ROC Curve (Narkhede, 2018)

#### 2.1.8 Area Under the Precision-Recall Curve (AUC-PR Curve)

AUC-PR หรือ คือพื้นที่ใต้เส้นโค้งของกราฟความสัมพันธ์ระหว่างค่า Precision หรือ Specificity และค่า Recall หรือ TPR โดย AUC-PR เป็นเครื่องมือวัดประสิทธิภาพที่สำคัญสำหรับแบบจำลองการจำแนกประเภท โดย AUC-PR ใช้สำหรับประเมินประสิทธิภาพของแบบจำลองโดยเฉพาะในกรณีที่ข้อมูลมีความไม่สมดุลระหว่างคลาส (Imbalanced Dataset) (Luo et al., 2023) ซึ่งมีความหมายว่าข้อมูลที่ไม่สมดุล เพราะให้ความสำคัญกับการจำแนกตัวอย่างในคลาสส่วนน้อย (minority class) ซึ่งมักเป็นกลุ่มที่สนใจศึกษา เช่น ผู้ป่วยที่มีความเสี่ยงเสียชีวิต การฉ้อโกงทางการเงิน หรือโรคหายาก โดย AUC-PR ไม่คำนึงถึง True Negative ซึ่งมักมีจำนวนมากในข้อมูลไม่สมดุล ทำให้ไม่ถูกบิดเบือนโดยตัวอย่างในคลาสส่วนใหญ่ (majority class) เมื่อเทียบกับ AUC-ROC

นอกจากนี้ AUC-PR ยังมีประโยชน์ในการเปรียบเทียบแบบจำลองต่างๆ โดยไม่จำเป็นต้องกำหนดค่า threshold ที่แน่นอน เนื่องจากคำนวนจากประสิทธิภาพที่ threshold ทุกค่าที่เป็นไปได้ ทำให้เห็นภาพรวมของประสิทธิภาพแบบจำลองได้ดีกว่า ที่แสดงให้เห็นว่า AUC-PR มีความไวต่อการเปลี่ยนแปลงในประสิทธิภาพของแบบจำลองมากกว่า AUC-ROC เมื่อทำงานกับข้อมูลที่ไม่สมดุล (Davis & Goadrich, 2006)

ในทางปฏิบัติ เช่นในงานด้านการแพทย์อย่างการทำนายความเสี่ยงในผู้ป่วยภาวะติดเชื้อในกระแสเลือด การใช้ AUC-PR ช่วยให้นักวิจัยประเมินความสามารถของแบบจำลองในการระบุกลุ่มผู้ป่วยเสี่ยงสูงได้อย่างแม่นยำ ซึ่งสำคัญอย่างยิ่งต่อการช่วยเหลือผู้ป่วยได้ทันเวลา (Luo et al., 2023)

### 2.1.9 SHAP (Shapley Additive explanations)

เทคนิค SHAP ใช้ในการอธิบายผลลัพธ์ของแบบจำลองการเรียนรู้ของเครื่อง (Machine Learning) โดยใช้แนวคิดของทฤษฎีเกมที่เรียกว่า Shapley values ซึ่งถูกพัฒนาโดย Lloyd Shapley ในปี 1953 ในเชิงทฤษฎีเกม เพื่อให้เข้าใจถึงบทบาทของแต่ละฟีเจอร์ที่มีผลต่อการตัดสินใจของแบบจำลอง โดย SHAP มีจุดประสงค์เพื่อทำให้ผลลัพธ์ของแบบจำลองที่ซับซ้อน เช่น Random Forest, Gradient Boosting Neural Networks หรือแม้กระทั่ง Deep learning ให้สามารถเข้าใจได้ง่ายขึ้น โดยการให้ค่าความสำคัญของแต่ละตัวแปรที่มีผลต่อการทำนายผล นอกจากนี้ SHAP ยังสามารถใช้เพื่อเปรียบเทียบความสำคัญของตัวแปรต่างๆ ในการตัดสินใจของแบบจำลอง รวมทั้งสามารถใช้เพื่อการตีความผลการตัดสินใจของแบบจำลองในรูปแบบที่เป็นมิตรกับผู้ใช้ โดยการคำนวณค่าของ Shapley value สำหรับฟีเจอร์ต่างๆ จะพิจารณาจากความสำคัญในการมีหรือไม่มีกลุ่มฟีเจอร์ในการทำนายผลลัพธ์ ซึ่งทำให้ผลลัพธ์ที่ได้สามารถแสดงความสำคัญของแต่ละฟีเจอร์ได้อย่างโปร่งใส (Lundberg & Lee, 2017)

$$\phi_i(N, v) = \frac{1}{|N|!} \sum_{S \subseteq N \setminus i} |S|! \cdot (|N| - |S| - 1)! \cdot [v(S \cup \{i\}) - v(S)]$$

เมื่อ  $N$  คือ กลุ่มฟีเจอร์ทั้งหมด

$i$  คือ ฟีเจอร์ที่สนใจว่าสำคัญต่อผลลัพธ์ของแบบจำลองมากเพียงใด

$S$  คือ กลุ่มของฟีเจอร์ที่ยังไม่รวมฟีเจอร์  $i$

$v(S)$  คือ ค่าผลลัพธ์ของแบบจำลอง เมื่อใช้แค่ฟีเจอร์ในกลุ่ม  $S$

$v(S \cup \{i\})$  คือ ค่าผลลัพธ์ของแบบจำลอง เมื่อเพิ่มฟีเจอร์  $i$  เข้าไปในกลุ่ม  $S$

## 2.2 งานวิจัยที่เกี่ยวข้อง

### 2.2.1 งานวิจัยที่เกี่ยวข้องกับการจัดการค่าสูญหาย

การจัดการกับข้อมูลที่สูญหายในข้อมูลแบบอนุกรมเวลา มีความสำคัญอย่างยิ่ง เนื่องจากข้อมูลแบบอนุกรมเวลา มักมีค่าสูญหายจากหลายสาเหตุ ซึ่งส่งผลต่อประสิทธิภาพในการวิเคราะห์และการทำนาย หลายงานวิจัยได้นำเสนอวิธีการจัดการกับข้อมูลสูญหายที่หลากหลาย ทั้งวิธีการเติมค่าและ การปั๊มค่าสูญหาย โดยใช้เทคนิคต่างๆ ตั้งแต่วิธีพื้นฐานไปจนถึงการใช้การเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep Learning) เพื่อพัฒนาประสิทธิภาพในการจัดการข้อมูลสูญหาย รวมถึงการรักษาโครงสร้างและความสมมูลของข้อมูลดังเดิม งานวิจัยที่สำคัญมีดังนี้

### ตารางที่ 2.3 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับการจัดการค่าสูญหาย

งานวิจัย	วัตถุประสงค์	วิธีที่ใช้	ข้อมูลที่ใช้ทดสอบ	วิธีที่ดีที่สุด	ผลลัพธ์	ลักษณะเด่น
Huang (2021)	พัฒนาวิธีการเติมค่าสูญหายในข้อมูลเครือข่ายไฟฟ้า	Linear Interpolation, LightGBM, Random Forest	ข้อมูลจริงจากโรงไฟฟ้าพลังงานความร้อนจำนวน 80,000 ตัวอย่าง	Linear Interpolation + LightGBM	ค่าความคาดเคลื่อนต่ำกว่า Random Forest, ใช้เวลาประมวลผลน้อยกว่า	เหมาะสมกับข้อมูลที่มีความผันผวนสูง, แยกจัดการข้อมูลสูญหายระยะสั้นและระยะยาว เหมาะสมกับข้อมูลอนุกรมเวลา
Zhang et al. (2021)	เปรียบเทียบประสิทธิภาพ MissForest กับวิธีตั้งเดิม ในข้อมูล GPS	MissForest, Cubic Spline, Orthogonal Polynomial, Hermite, RegEM	ข้อมูล GPS จาก 20 สถานีในกรีนแลนด์ (2016-2018)	MissForest	MissForest สามารถเติมค่าสูญหายได้แม่นยำกว่าและสามารถรักษาโครงสร้างข้อมูลได้ดีแม้ในเมืองว่างในข้อมูลนานถึง 30 วัน	มีประสิทธิภาพสูงในการคาดเดาค่าที่หาย และลดความผิดพลาดในการเติมค่า

Huang (2021) ได้ศึกษาเรื่องวิธีการเติมค่าสูญหายโดยอาศัยการประมาณค่าแบบเชิงเส้น (Linear Interpolation) และ LightGBM โดยมีวัตถุประสงค์เพื่อพัฒนาวิธีการเติมค่าสูญหายในกระบวนการเก็บรวบรวมข้อมูลเครือข่ายไฟฟ้า (Power Grid Data) ที่เป็นข้อมูลที่มีความสำคัญในการดำเนินงานและความปลอดภัยของระบบไฟฟ้า เพื่อเพิ่มประสิทธิภาพในการใช้งานข้อมูลและความแม่นยำในการประยุกต์ใช้ข้อมูล งานวิจัยนี้ได้นำเสนอวิธีการทำงานร่วมกันระหว่าง Linear Interpolation และอัลกอริทึม LightGBM โดยใช้ Linear Interpolation สำหรับการเติมข้อมูลที่มีค่าสูญหายในระยะสั้น (Short-term Missing Data) จากนั้นใช้ LightGBM สำหรับการเติมข้อมูลที่มีค่าสูญหายในระยะยาว (Long-term Missing Data) โดยในขั้นตอนนี้จะใช้ Linear Interpolation เพื่อประมาณค่าตัวแปรอิสระที่เป็นข้อมูลอินพุตของแบบจำลอง LightGBM ก่อน จากนั้นดำเนินการเติมข้อมูลตามลำดับจากจุดวัดที่มีสัดส่วนข้อมูลสูญหายมากที่สุดไปหาน้อยที่สุด ซึ่งพบว่าการเติมค่าสูญหายด้วยวิธีนี้มีประสิทธิภาพในการเติมข้อมูลที่มีค่าสูญหายได้ดีกว่าวิธี Random Forest โดยเปรียบเทียบผลลัพธ์จากการทดสอบบนชุดข้อมูลจริงที่เกี่ยวข้องกับกระบวนการควบคุมประตูของโรงไฟฟ้าพลังงานความร้อน ซึ่งประกอบด้วยข้อมูล 4 ตัวแปร ได้แก่ คำสั่งควบคุมหลัก ความดันไอน้ำ

หลัก กำลังไฟฟ้า และระดับการเปิดของประตูควบคุมที่ 1 โดยมีจำนวนตัวอย่างทั้งหมด 80,000 ตัวอย่าง และมีสัดส่วนข้อมูลที่มีค่าสูญหายอยู่ในช่วง 0.26-0.39 ผลการเปรียบเทียบแสดงให้เห็นว่าวิธีการที่นำเสนอ มีค่าความคลาดเคลื่อนต่ำกว่าและใช้เวลาในการประมวลผลน้อยกว่าวิธี Random Forest อายุร่วมกัน สำหรับตัวแปรที่มีความผันผวนสูง เช่น ระดับการเปิดของประตูควบคุม ซึ่งแสดงให้เห็นถึงประสิทธิภาพของการใช้ linear interpolation ร่วมกับ LightGBM ในการจัดการกับข้อมูลที่มีลักษณะซับซ้อนได้

Zhang et al. (2021) ได้ศึกษาเรื่องการใช้วิธี MissForest ในการเติมค่าสูญหายไปในข้อมูลอนุกรมเวลาของพิกัดใน GPS โดยมีวัตถุประสงค์เพื่อเปรียบเทียบประสิทธิภาพของ MissForest กับวิธีการเติมข้อมูลแบบดั้งเดิมอื่นๆ งานวิจัยนี้ใช้ชุดข้อมูลอนุกรมเวลาของพิกัดใน GPS จาก 20 สถานีในกรีนแลนด์ ในช่วงเดือนมกราคม 2016 ถึงมิถุนายน 2018 โดยมีขั้นตอนคือ สร้างช่องว่างข้อมูลแบบสุ่มในข้อมูลอนุกรมเวลาของพิกัดใน GPS ด้วยขนาดช่องว่างต่างๆ ได้แก่ 2, 7, 30 และ 180 วันตามลำดับ และอัตราการสูญหายต่างๆ 10%, 20%, 30% และ 40% ตามลำดับ จากนั้นทำการเติมค่าสูญหายด้วยวิธีต่างๆ ได้แก่ Cubic Spline, Orthogonal Polynomial, Hermite, RegEM และ MissForest โดยการเปรียบเทียบประสิทธิภาพการเติมข้อมูลสูญหายด้วยค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ (Mean Absolute Error; MAE), ค่ารากที่สองของความคลาดเคลื่อนที่เป็นมาตรฐาน (Normalized Root Mean Squared Error; NRMSE) และสัมประสิทธิ์สหสัมพันธ์ของเพียร์สัน จากนั้นวิเคราะห์ผลกราฟของ การเติมข้อมูลสูญหายต่อการวิเคราะห์องค์ประกอบหลัก (Principal Component Analysis; PCA) ผลการวิจัยพบว่าวิธี MissForest ให้ผลลัพธ์ที่ดีที่สุดในทุกขนาดช่องว่างและอัตราการสูญหายของข้อมูล โดยมีค่า MAE และ NRMSE ต่ำที่สุด เมื่อขนาดช่องว่างเพิ่มขึ้นจาก 2 วันเป็น 180 วัน ค่า MAE ของ MissForest เพิ่มขึ้นเพียง 0.4 มม. และถึงความทนทานต่อขนาดช่องว่างที่เพิ่มขึ้น นอกจากนี้ผลการวิเคราะห์ PCA ยังแสดงให้เห็นว่าวิธี MissForest สามารถรักษาโครงสร้างของข้อมูลดั้งเดิมได้ดีที่สุด โดยมีระยะทางและมุมของ PC1 ที่ใกล้เคียงกับข้อมูลดั้งเดิมมากที่สุด ดังนั้นวิธี MissForest เป็นวิธีการเติมข้อมูลที่มีประสิทธิภาพสูงสำหรับข้อมูลอนุกรมเวลาของพิกัดใน GPS โดยสามารถรักษาข้อมูลเชิงพื้นที่และเวลาได้ดี และสามารถถอดรหัสขนาดช่องว่างและอัตราการสูญหายของข้อมูลที่แตกต่างกัน

### 2.2.2 งานวิจัยที่เกี่ยวข้องกับแบบจำลองทำนายภาวะติดเชื้อในกระแสเลือดและภาวะซื้อกจากการติดเชื้อ

การสร้างแบบจำลองสำหรับการทำนายภาวะซื้อกจากการติดเชื้อของผู้ป่วยใน ICU ล่วงหน้าด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา มีความสำคัญอย่างยิ่ง เนื่องจากการวินิจฉัยภาวะนี้ในระยะแรก ๆ สามารถช่วยชีวิตผู้ป่วยได้ หลายงานวิจัยได้ใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) และการเรียนรู้เชิงลึก (Deep

Learning) เพื่อพัฒนาแบบจำลองที่สามารถวิเคราะห์ข้อมูลและทำนายภาวะติดเชื้อในกระแสเลือดจากข้อมูลสัญญาณซีพและข้อมูลบันทึกสุขภาพอิเล็กทรอนิกส์ งานวิจัยที่สำคัญมีดังนี้

ตารางที่ 2.4 เปรียบเทียบงานวิจัยที่เกี่ยวข้องกับแบบจำลองทำนายภาวะซึ่งออก

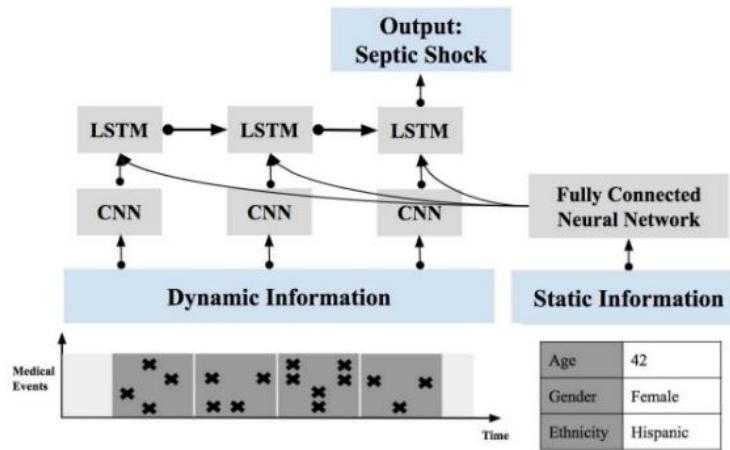
งาน วิจัย	วัตถุ ประสงค์	ชุดข้อมูล	แบบจำลอง ทั้งหมด	แบบจำลองที่ ให้ผลดีที่สุด	ระยะเวลา ในการ ทำนาย ล่วงหน้า	ผลลัพธ์ที่ดี ที่สุด
Lin et al. (2018)	การทำนาย การเกิดภาวะ ซึ่งมาจากติด เชื้อในผู้ป่วย จากการรักษา	ผู้ป่วยใน ICU จำนวน 3,738 ราย จาก Christiana Care Health System	Logistic Regression, Gaussian Naive Bayes, SVM, Decision Tree, LSTM, CNN	LSTM + CNN + Static-last	น้อยกว่า 4.5, ตั้งแต่ 5- 24 ชั่วโมง ที่ 4.5 ชั่วโมง	AUC-ROC: 94.08%  F1 Score: 85.79%
Tang et al. (2024)	การทำนาย ภาวะติด เชื้อในกระแส เลือด ระยะแรก	ผู้ป่วยใน ICU จำนวน 17,932 ราย จาก eICU	RNN, LSTM, CNN+Transfor mer, LSTM+Transfor mer	LSTM+Transformer	4,8,12 ชั่วโมง	AUC-ROC: 0.99, Accuracy 96.4% ที่ 4 ชั่วโมง
Luo et al. (2023)	ทำนายความ เสี่ยงในการ เสียชีวิตจาก ภาวะติดเชื้อ <sup>†</sup> ในกระแส เลือดล่วงหน้า	ชุดข้อมูล จาก MIMIC- IV และ eICU	PT3 Transformer, T- LSTM, GRU-D, RAPT	PT3 Transformer	6,24,48 ชั่วโมง (eICU) ที่ 6 ชั่วโมง	AUC-ROC: 0.9067 (MIMIC-IV), 0.8733 (eICU) ที่ 6 ชั่วโมง

Lin et al. (2018) ได้ศึกษาเรื่องการวินิจฉัยและทำนายภาวะซื้อกจากการติดเชื้อในระยะแรก โดยใช้ข้อมูลทั้งแบบคงที่ (Static) และแบบพลวัต (Dynamic) ร่วมกับแบบจำลอง Convolutional-LSTM เพื่อวิเคราะห์ข้อมูลจากบันทึกสุขภาพอิเล็กทรอนิกส์ (EHRs) งานวิจัยนี้ใช้ข้อมูลผู้ป่วยจำนวน 3,738 ราย เป็นผู้ป่วยที่มีภาวะซื้อกจากการติดเชื้อจำนวน 1,869 และไม่เป็นผู้ป่วยที่มีภาวะซื้อกจากการติดเชื้อจำนวน 1,869 รายจาก Christiana Care Health System และพัฒนาแบบจำลองการเรียนรู้เชิงลึก 6 แบบ โดยเพิ่มส่วนประกอบต่างๆ เข้าไปในแบบจำลอง LSTM พื้นฐาน ได้แก่ การเพิ่ม CNN, การเพิ่มข้อมูลคงที่แบบ Static-repeat และ Static-last, และการรวม CNN กับข้อมูลคงที่ทั้งสองแบบ โดยการผสม (integration) แบบจำลอง Convolutional Neural Network (CNN) และ Long Short-Term Memory (LSTM) เข้าด้วยกัน รวมถึงการเพิ่มข้อมูลแบบคงที่ด้วย Fully Connected layer (FC layer) มีรายละเอียด ดังนี้

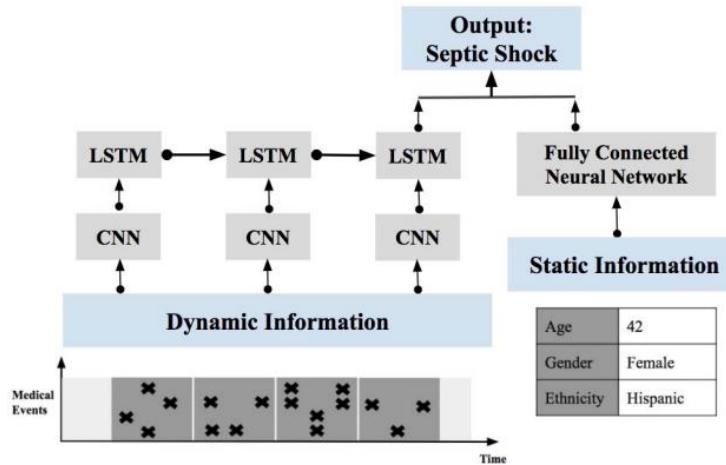
1) CNN + LSTM แบบจำลองจะใช้ CNN เพื่อสกัดลักษณะเฉพาะในข้อมูลที่เปลี่ยนแปลงตามเวลา (dynamic information) จาก EHRs เช่น การตรวจเลือดหรือสัญญาณชีพ ซึ่ง CNN จะช่วยจับลักษณะที่เปลี่ยนอยู่กับเวลาในระยะสั้น ทำให้สามารถดึงคุณสมบัติสำคัญออกมาได้ จากนั้นข้อมูลที่ผ่าน CNN จะถูกส่งต่อเข้าไปใน LSTM เพื่อใช้ในการวิเคราะห์ความสัมพันธ์ระยะยาวในข้อมูลที่มีลำดับการเปลี่ยนแปลง

2) การรวมข้อมูล Static ข้อมูลที่ไม่เปลี่ยนแปลงระหว่างการรักษา เช่น อายุ หรือโรคประจำตัว จะถูกประมวลผลผ่าน FC layer โดยงานวิจัยนี้ได้รวมข้อมูลแบบคงที่เข้ากับ LSTM สองวิธี ได้แก่ 1) Static-repeat จะนำผลลัพธ์จาก FC layer มาต่อกับ hidden state ของ LSTM ในทุกช่วงเวลา (time step) ทำให้ข้อมูลแบบคงที่มีอิทธิพลต่อการทำนายทุกช่วงเวลา 2) Static-last นำผลลัพธ์จาก FC layer มาต่อกับผลลัพธ์สุดท้าย (output) ของ LSTM ที่ขั้นตอนสุดท้ายเท่านั้น วิธีนี้ทำให้ข้อมูลแบบคงที่มีอิทธิพลเฉพาะ time step สุดท้ายก่อนการทำนาย

ผลการศึกษาพบว่า สำหรับการวินิจฉัยระดับการเข้ารักษา แบบจำลอง LSTM+CNN+Static-last ให้ผลดีที่สุด โดยมีค่า AUC เฉลี่ย 94.08% และ F1 Score เฉลี่ย 85.79% ที่เวลาการทำนายล่วงหน้าอยกว่า 4.5 ชั่วโมง และที่เวลาการทำนายล่วงหน้า 5 ชั่วโมงขึ้นไป CNN+ LSTM ให้ผลดีที่สุด โดยทั้งสองแบบจำลองนี้ให้ผลดีกว่าแบบจำลองการเรียนรู้ของเครื่องแบบดั้งเดิมอย่างมีนัยสำคัญ



ภาพที่ 2.16 LSTM+CNN+Static-repeat (Lin et al, 2018)

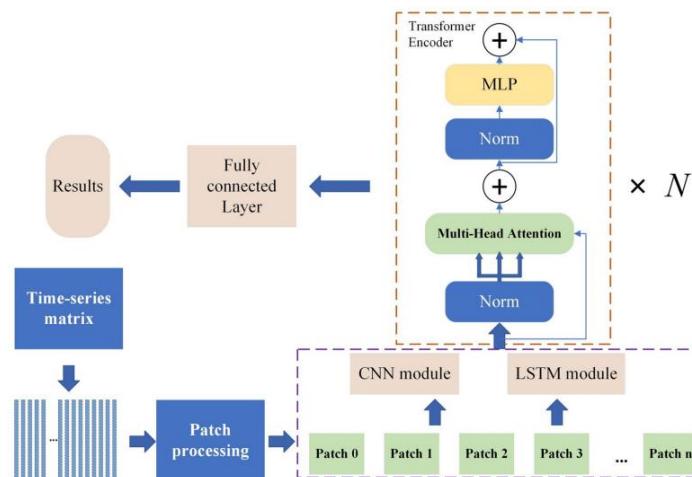


ภาพที่ 2.17 LSTM+CNN+Static-last (Lin et al, 2018)

Tang et al. (2024) ได้ศึกษาเรื่องการพัฒนาแบบจำลองที่นำภาระเกิดภาวะติดเชื้อในกระแสเลือดในระยะแรก ๆ โดยใช้ข้อมูลอนุกรมเวลาร่วมกับแบบจำลอง Transformer เพื่อช่วยในการวินิจฉัยและรักษาผู้ป่วยได้เร็ว ขึ้น งานวิจัยนี้ใช้ข้อมูลจากฐานข้อมูล eICU Collaborative Research Database ซึ่งมีข้อมูลผู้ป่วยที่เข้ารับการรักษาใน ICU จำนวน 17,932 ราย โดยพัฒนาแบบจำลอง 2 แบบคือ CNN-Transformer และ LSTM-Transformer และเปรียบเทียบกับแบบจำลองพื้นฐานอื่นๆ เช่น RNN และ LSTM และทดสอบแบบจำลองโดยใช้ข้อมูลก่อนเกิดภาวะติดเชื้อในกระแสเลือด 4, 8 และ 12 ชั่วโมง โดยการผสานแบบจำลอง CNN และ LSTM กับ Transformer มีหลักการดังนี้

- 1) CNN-Transformer แบบจำลองนี้จะใช้ CNN เพื่อดึงคุณลักษณะจากข้อมูลอนุกรมเวลาและส่งผ่านไปยังโมดูล Transformer โดย CNN จะใช้ฟิลเตอร์ขนาดเล็กเพื่อวิเคราะห์ช่วงเวลาสั้น ๆ ของข้อมูล ทำให้สามารถตรวจจับรูปแบบเฉพาะที่อาจเกิดขึ้นในระยะเวลาสั้น ๆ ได้
- 2) LSTM-Transformer แบบจำลองนี้จะรวม LSTM เข้ากับ Transformer โดยที่ LSTM ช่วยในการตรวจสอบความสัมพันธ์เชิงเวลาที่เป็นระยะยาวได้อย่างดี ก่อนที่ข้อมูลจะถูกส่งต่อไปยังโมดูล Transformer ทั้งแบบจำลอง CNN และ LSTM ที่ถูกส่งผ่านมายังโมดูล Transformer แล้ว Transformer จะใช้กลไก self-attention เพื่อเชื่อมโยงความสัมพันธ์ของข้อมูลที่ปรากฏในช่วงเวลาใกล้เคียงกัน และระยะเวลาที่ห่างออกไป ทำให้แบบจำลองมีความสามารถในการจัดการกับรูปแบบที่ซับซ้อน ช่วยลดความเบาบางและกระจัดกระจาดตามเวลาของข้อมูล

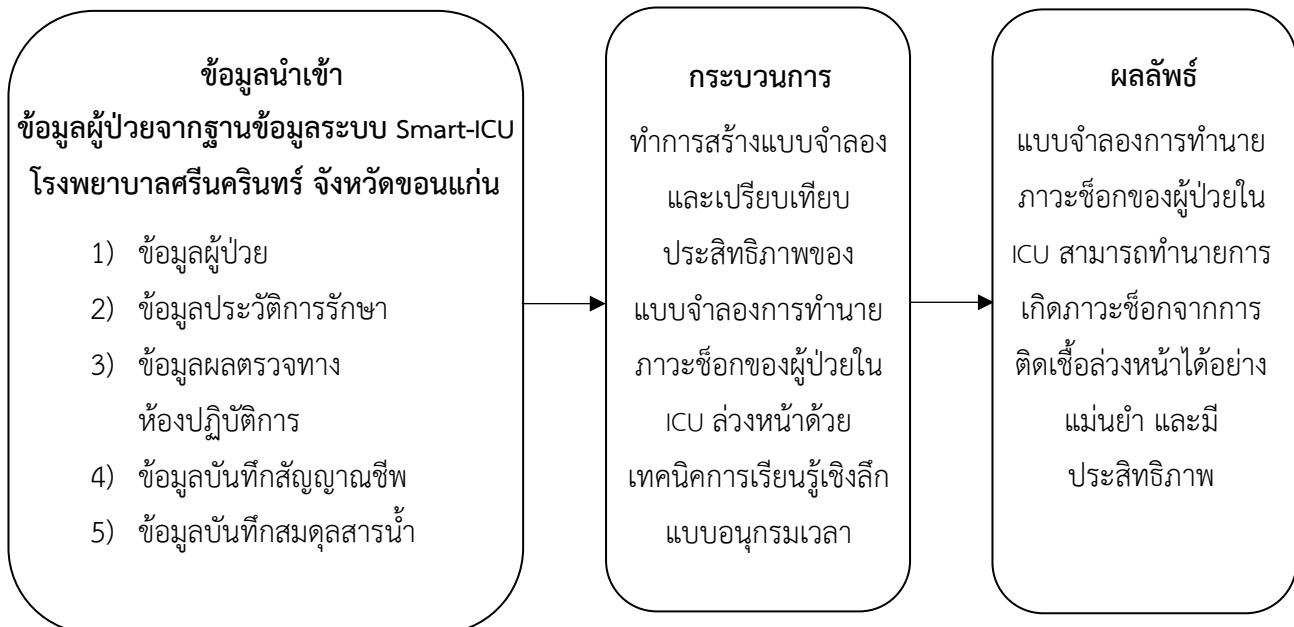
ผลการวิจัยพบว่าแบบจำลอง LSTM-Transformer ให้ผลลัพธ์ที่สุด โดยมีค่าเฉลี่ย AUC 0.99, accuracy 0.964, precision 0.956, recall 0.967 และ F1 score 0.959 ซึ่งดีกว่าแบบจำลอง RNN ทั่วไปประมาณ 20% นอกจากนี้ยังพบว่าแบบจำลองสามารถทำงานได้แม่นยำเมื่อในช่วงเวลาที่ทำงานก่อนเกิดภาวะติดเชื้อในกระแสเลือด 12 ชั่วโมง ซึ่งเป็นประโยชน์อย่างมากในการวินิจฉัยและรักษาในระยะแรก ๆ อีกทั้งยังใช้อัลกอริทึม SHAP เพื่อแสดงภาพและอธิบายน้ำหนักความสำคัญของแต่ละปัจจัย พบร่วมกับการเต้นของหัวใจ, BNP, AST, อัตราการหายใจ, ความอิ่มตัวของออกซิเจนในเลือด และจำนวนเกล็ดเลือด เป็นปัจจัยสำคัญในการทำงาน



ภาพที่ 2.18 แบบจำลอง CNN และ LSTM ที่ถูกส่งผ่านมายังโมดูล Transformer (Tang et al, 2024)

Luo et al. (2023) ได้ศึกษาเรื่องการพัฒนาแบบจำลอง Pre-trained Triplet-loss Time-aware Transformer (PT3) สำหรับการทำนายความเสี่ยงในการเสียชีวิตของผู้ป่วยติดเชื้อในกระแสเลือด (sepsis) โดยใช้ข้อมูลสัญญาณชีพแบบอนุกรมเวลา งานวิจัยนี้ใช้ข้อมูลจากฐานข้อมูล MIMIC-IV และ eICU โดย PT3 สามารถจัดการข้อมูลอนุกรมเวลาที่มีช่วงเวลาไม่สม่ำเสมอและข้อมูลสูญหายได้ โดยใช้ Time-Aware Mechanism และ Auto-Imputing Mechanism และใช้วิธีการ Pre-Training แบบใหม่ด้วย Triplet-loss Function เพื่อเพิ่มความสามารถในการเรียนรู้การแทนข้อมูล นอกจากนี้ยังสามารถทำนายความเสี่ยงในการเสียชีวิตล่วงหน้า 6, 24 และ 48 ชั่วโมง โดยใช้เพียงข้อมูลสัญญาณชีพ ผลการวิจัยพบว่า PT3 มีประสิทธิภาพดีกว่าแบบจำลองอื่นๆ โดยเฉพาะการทำนายล่วงหน้า 6 ชั่วโมง โดยมีค่า AUC 0.9067 บนชุดข้อมูลจาก MIMIC-IV และ 0.8733 บนชุดข้อมูลจาก eICU นอกจากนี้ยังพบว่า การ Pre-training และ Fine-tuning ช่วยเพิ่มความสามารถในการเรียนรู้การแทนข้อมูลของแบบจำลองได้อย่างมีนัยสำคัญ

### 2.3 กรอบแนวคิดการวิจัย



ภาพที่ 2.19 กรอบแนวคิดการวิจัย

ภาพที่ 2.19 แสดงกรอบแนวคิดของการวิจัยโดยมีข้อมูลนำเข้า (Input) เป็นข้อมูลผู้ป่วยจากฐานข้อมูลระบบ Smart-ICU โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ประกอบไปด้วยชุดข้อมูลจำนวน 5 ชนิด ได้แก่ 1) ข้อมูลผู้ป่วย 2) ข้อมูลประวัติการรักษา 3) ข้อมูลผลตรวจทางห้องปฏิบัติการ 4) ข้อมูลบันทึกสัญญาณชีพ 5) ข้อมูลบันทึกสมดุลสารน้ำ งานวิจัยนี้ทำการเลือกตัวอย่างเป็นผู้ป่วยที่มีอายุ 18 ปีขึ้นไป และมีระยะเวลาที่อยู่ใน ICU ไม่ต่ำกว่า 24 ชั่วโมง จากนั้นทำการเตรียมข้อมูล เข้าสู่กระบวนการ (Process) สร้างแบบจำลองโดยใช้ CNN, LSTM, Transformer และแบบจำลองแบบสมมติ โดยเปรียบเทียบประสิทธิภาพ และให้ผลลัพธ์ (Output) เป็นแบบจำลองการทำนายภาวะซื้อขายใน ICU ที่สามารถทำนายการเกิดภาวะซื้อขายใน ICU ล่วงหน้าได้อย่างแม่นยำ และมีประสิทธิภาพ

## บทที่ 3

### วิธีดำเนินการวิจัย

งานวิจัยเรื่องการพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลา เพื่อทำนายภาวะซื้อกในแผนกผู้ป่วย วิกฤต โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ได้มีการดำเนินวิจัยตามกำหนดขั้นตอนตามมาตรฐานการทำโครงการ ด้านการวิเคราะห์ข้อมูล และการทำเหมืองข้อมูล (Cross-Industry Standard Process for Data Mining; CRISP-DM) โดยมีรายละเอียดของวิธีการดำเนินวิจัย ดังต่อไปนี้

#### 3.1 การกำหนดปัญหา (Business Understanding)

ภาวะซื้อกเกิดขึ้นในผู้ป่วยที่เข้ารับการรักษาใน ICU ถึงร้อยละ 29.5 และมีอัตราการเสียชีวิตในโรงพยาบาลสูง ถึงร้อยละ 35.3 เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะซื้อกซึ่งมีอัตราการเสียชีวิตร้อยละ 16.7 (Sakr et al., 2018) ซึ่งในขณะนี้ยังคงมีแนวโน้มเพิ่มสูงขึ้น ทำให้เกิดความจำเป็นในการพัฒนาการวินิจฉัยและจัดการภาวะซื้อกใน ICU ล่วงหน้าเพื่อป้องกันการเสียชีวิตและภาวะแทรกซ้อนที่อาจเกิดขึ้น โดยผู้ป่วยที่เกิดภาวะซื้อกมักมีสัญญาณชีพที่เปลี่ยนแปลงอย่างรวดเร็ว โดยเฉพาะผู้ป่วยใน ICU ซึ่งการวินิจฉัยล่าช้าเป็นปัจจัยหลักที่นำไปสู่การเสียชีวิต หากสามารถทำนายและจัดการภาวะซื้อกล่วงหน้าได้ จะสามารถช่วยลดอัตราการเสียชีวิตในผู้ป่วยที่มีภาวะซื้อกได้อย่างมีนัยสำคัญ

ปัจจุบันมีหลายงานวิจัยที่เริ่มน้ำหนาด้วยการเรียนรู้เชิงลึกแบบอนุกรมเวลา (Time Series Deep Learning) มาใช้ในการทำนาย เนื่องจากแบบจำลองที่สามารถจับความสัมพันธ์กับเวลาได้จะช่วยเพิ่มความแม่นยำในการทำนายภาวะซื้อก เทคนิคเช่น Long Short-Term Memory (LSTM) และ Transformer มีศักยภาพในการเรียนรู้รูปแบบข้อมูลที่มีความซับซ้อนและเปลี่ยนแปลงตามเวลา

ผู้วิจัยจึงมีเป้าหมายที่จะพัฒนาแบบจำลองการเรียนรู้เชิงลึกเพื่อใช้ในการทำนายภาวะซื้อกใน ICU จากข้อมูลที่เก็บรวบรวมในฐานข้อมูลระบบ Smart-ICU โดยนำข้อมูลผู้ป่วย ข้อมูลประวัติการรักษา ข้อมูลบันทึกสัญญาณชีพ ข้อมูลบันทึกสมดุลสารน้ำ และข้อมูลผลตรวจทางห้องปฏิบัติการมาใช้ เพื่อเพิ่มประสิทธิภาพในการทำนายภาวะเสี่ยง ตั้งกล่าว นำไปประยุกต์ใช้กับข้อมูลทางการแพทย์ของผู้ป่วยที่มีภาวะซื้อกใน ICU โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น โดยการสร้างแบบจำลอง และเปรียบเทียบประสิทธิภาพของแบบจำลองสำหรับการทำนายภาวะซื้อกของผู้ป่วยใน ICU เพื่อหาแบบจำลองการทำนายที่มีประสิทธิภาพที่ดีที่สุด เพื่อที่สามารถนำไปกำหนดแนวทางต่าง ๆ ใน การรักษาป้องกัน และช่วยให้แพทย์สามารถวางแผนการรักษาได้อย่างเหมาะสมและทันเวลา

#### 3.2 การศึกษาทำความเข้าใจข้อมูล (Data Understanding)

ในการศึกษาทำความเข้าใจข้อมูล ผู้วิจัยมีการเก็บรวบรวมข้อมูลดังนี้

### 3.2.1 ข้อมูลที่ใช้ในการวิเคราะห์

งานวิจัยนี้ ผู้วิจัยได้ใช้ข้อมูลทุติยภูมิจากระบบฐานข้อมูล Smart-ICU ของแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น จำนวน 2 ชุด ได้แก่ ชุดสำหรับฝึกสอน (Training set) และตรวจสอบ (Validation set) กับชุดสำหรับทดสอบ (Test set) อีก 1 ชุด ตั้งแต่วันที่ 15 ตุลาคม 2565 – 3 กุมภาพันธ์ 2568 ประกอบด้วยข้อมูลจำนวน 5 ชนิด ที่แบ่งตามระดับความละเอียดทางเวลา 3 ประเภท ได้แก่

- 1) ข้อมูลคงที่ ทั้งหมด 18 ตัวแปร

1.1) ข้อมูลผู้ป่วย ประกอบไปด้วยข้อมูลจากตาราง Admission Info ทั้งหมด 2 ตัวแปร ดังตารางที่ 3.1

ตารางที่ 3.1 ข้อมูลผู้ป่วย (Admission Info)

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
1	Age	varchar	อายุ
2	Sex	varchar	เพศ

1.2) ข้อมูลประวัติการรักษา ประกอบไปด้วยข้อมูลจากตาราง Redcap ทั้งหมด 11 ตัวแปร ดังตารางที่ 3.2

ตารางที่ 3.2 ข้อมูลประวัติการรักษา จากตาราง Redcap

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
1	Height	float	ความสูง
2	Weight	float	น้ำหนัก
3	BMI	float	ดัชนีมวลกาย
4	RRT	int	มีการบำบัดทดแทนไต
5	Lactate	float	ค่า lactate
6	CKD	int	โรคไตเรื้อรัง
7	AKI	int	ภาวะไตวายเฉียบพลัน
8	SOFA	int	คะแนนแบบประเมินการล้มเหลวของอวัยวะ
9	CCI total	int	ผลรวมค่า charlson comorbidity index

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
10	SAP II	int	ค่าคะแนน SAP-2
11	Apache III	int	ค่าคะแนน APACHE-3

1.3) ข้อมูลบันทึกสมดุลสารน้ำ ประกอบไปด้วยข้อมูลจากตาราง Intake Output ทั้งหมด 5 ตัวแปร ดังตารางที่ 3.3

ตารางที่ 3.3 ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
1	Total Intake 24hr	float	ปริมาณการรับสารน้ำทั้งหมดของวันนั้น
2	Total Intake IV	float	ปริมาณการรับสารผ่านการฉีดเข้าเส้นเลือด
3	Total Intake ORAL	float	ปริมาณการรับสารผ่านทางปาก
4	Total Output 24hr	float	ปริมาณสารน้ำออกทั้งหมดของวันนั้น
5	IO 24hr	float	ปริมาณการรับสารน้ำ - ปริมาณสารน้ำออก ทั้งหมดของวันนั้น

2) ข้อมูลรายชั่วโมง ทั้งหมด 4 ตัวแปร

2.1) ข้อมูลผลตรวจทางห้องปฏิบัติการ ประกอบไปด้วยข้อมูลจากตาราง Bedccr ทั้งหมด 4 ตัวแปร ดังตารางที่ 3.4

ตารางที่ 3.4 ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
1	Temp	float	อุณหภูมิ
2	LIVE Tidal Volume	float	ปริมาตรหายใจเข้าออกปกติ
3	LIVE RR	int	อัตราการหายใจ
4	SETTING FIO2	float	ค่าความเข้มข้นของออกซิเจนจากเครื่องช่วยหายใจ

### 3) ข้อมูลรายนาที ทั้งหมด 13 ตัวแปร

3.1) ข้อมูลบันทึกสัญญาณชีพ ประกอบไปด้วยข้อมูลจากตาราง Bedmonitor track ทั้งหมด 13 ตัวแปรดังตารางที่ 3.5

ตารางที่ 3.5 ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)

ลำดับ	ชื่อคอลัมน์	ชนิดของข้อมูล	คำอธิบายข้อมูล
1	HR	float	อัตราการเต้นของหัวใจ
2	RR	float	อัตราการหายใจ
3	BP SYS	float	ความดันโลหิตขณะหัวใจบีบตัว
4	BP DIA	float	ความดันโลหิตขณะหัวใจคลายตัว
5	BP TYPE	varchar	ประเภทการวัดค่าความดันโลหิต
6	MAP	float	ค่าความดันโลหิตหลอดเลือดแดงเฉลี่ย
7	O2SAT	float	ความเข้มข้นของออกซิเจนในเลือด
8	DSI	float	ดัชนีชี้ออกซิเจนในเลือด (Diastolic Shock Index)
9	SI	float	ดัชนีชี้ออกซิเจน (Shock Index)
10	MSI	float	ดัชนีชี้ออกแบบดัดแปลง (Modified Shock Index)
11	ASI	float	ดัชนีชี้ออกแบบปรับ (Adjusted Shock Index)
12	AMSI	float	ดัชนีชี้ออกแบบปรับตามอายุ (Age Modified Shock Index)
13	RASI	float	ดัชนีชี้ออกแบบปรับตามการหายใจ (Respiratory Adjusted Shock Index)

#### 3.2.2 การวิเคราะห์ข้อมูล

วิเคราะห์ข้อมูลด้วยภาษา Python แพ็คเกจ SciPy เพื่อทดสอบสมมติฐานทางสถิติ โดยกำหนดระดับนัยสำคัญทางสถิติ 0.05 ที่ระดับความเชื่อมั่น 95%

- 1) ใช้สถิติเชิงพรรณนา ได้แก่ ค่าเฉลี่ย, ส่วนเบี่ยงเบนมาตรฐาน และค่ามัธยฐาน
- 2) เปรียบเทียบความแตกต่างของตัวแปรคงที่ต่อภาวะชีอกและไม่ชีอก

เปรียบเทียบความแตกต่างของตัวแปรคงที่ต่อภาวะซื้อและไม่ซื้อกของผู้ป่วยใน ICU หากข้อมูลมีการแจกแจงปกติจะใช้สถิติ Independent Sample T Test และหากข้อมูลไม่มีการแจกแจงปกติจะใช้สถิตินอนพารามетริกคือ Mann Whitney U Test โดยมีสมมติฐานการทดสอบ ดังนี้

$H_0$ : ค่าเฉลี่ยของตัวแปรคงที่ที่ทดสอบของผู้ป่วยที่มีภาวะซื้อและไม่ซื้อกไม่แตกต่างกัน

$H_1$ : ค่าเฉลี่ยของตัวแปรคงที่ที่ทดสอบของผู้ป่วยที่มีภาวะซื้อและไม่ซื้อกแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ ตัวแปรคงที่ต่อภาวะซื้อและไม่ซื้อกของผู้ป่วย มีค่าเฉลี่ยแตกต่างกัน

และในกรณี Mann Whitney U Test จะมีสมมติฐานการทดสอบ ดังนี้

$H_0$ : มัธยฐานของตัวแปรคงที่ที่ทดสอบของผู้ป่วยที่มีภาวะซื้อและไม่ซื้อกไม่แตกต่างกัน

$H_1$ : มัธยฐานของตัวแปรคงที่ที่ทดสอบของผู้ป่วยที่มีภาวะซื้อและไม่ซื้อกแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ ตัวแปรคงที่ต่อผู้ป่วยที่มีภาวะซื้อและไม่มีภาวะซื้อก มีค่ามัธยฐานแตกต่างกัน

### 3) เปรียบเทียบข้อมูลเชิงคุณภาพ

ใช้การทดสอบความกลมกลืน (Test of homogeneity) เปรียบเทียบความเท่ากันของสัดส่วนข้อมูลเชิงคุณภาพ ได้แก่ เพศ (Sex), ภาวะไตวาย (aki), ภาวะไตเรื้อรัง (ckd), การเข้ารับการล้างไต (rrt) โดยมีสมมติฐานการทดสอบ ดังนี้

สมมติฐานที่ 1

$H_0$ : สัดส่วนของเพศกับการเกิดภาวะซื้อกของผู้ป่วยไม่แตกต่างกัน

$H_1$ : สัดส่วนของเพศกับการเกิดภาวะซื้อกของผู้ป่วยแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ สัดส่วนของเพศกับภาวะซื้อกของผู้ป่วยแตกต่างกัน

สมมติฐานที่ 2

$H_0$ : สัดส่วนของภาวะไตวายกับการเกิดภาวะซื้อกของผู้ป่วยไม่แตกต่างกัน

$H_1$ : สัดส่วนของภาวะไตวายกับการเกิดภาวะซื้อกของผู้ป่วยแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ สัดส่วนของภาวะไตวายกับภาวะซื้อกของผู้ป่วยแตกต่างกัน

สมมติฐานที่ 3

$H_0$ : สัดส่วนของภาวะไตเรื้อรังกับการเกิดภาวะซื้อกล่วงหน้าของผู้ป่วยไม่แตกต่างกัน

$H_1$ : สัดส่วนของภาวะไตรีอังกับการเกิดภาวะซึ่อกล่วงหน้าของผู้ป่วยแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ สัดส่วนของภาวะไตรีอังกับของผู้ป่วยแตกต่างกัน

สมมติฐานที่ 4

$H_0$ : สัดส่วนการล้างไตรีอังกับการเกิดภาวะซึ่อกล่วงหน้าของผู้ป่วยไม่แตกต่างกัน

$H_1$ : สัดส่วนการล้างไตรีอังกับการเกิดภาวะซึ่อกล่วงหน้าของผู้ป่วยแตกต่างกัน

ปฏิเสธ  $H_0$  เมื่อค่า p-value น้อยกว่าหรือเท่ากับระดับนัยสำคัญ ( $\alpha$ ) นั้นคือ สัดส่วนการล้างไตรีอังกับของผู้ป่วยแตกต่างกัน

### 3.3 การเตรียมข้อมูล (Data Preparation)

การเตรียมข้อมูล (Data Preparation) เป็นการปรับปรุงข้อมูลให้อยู่ในรูปแบบที่เหมาะสม ก่อนที่จะนำไปวิเคราะห์เพื่อสร้างแบบจำลองต่อไป มีการดำเนินการดังนี้

#### 3.3.1 รวมข้อมูลผู้ป่วย

1) ก่อนจะทำการรวมข้อมูลผู้ป่วยจากหลาย ๆ ตาราง ให้เป็นตารางเดียว ผู้วิจัยได้ทำการจัดการกับค่าสูญหาย ก่อน หากตัวแปรใดมีค่าสูญหายที่มากกว่าร้อยละ 70 จะทำการลบตัวแปรนั้นออก เนื่องจากหากรวมเป็นตารางเดียว จะทำให้ข้อมูลมีค่าสูญหายที่เพิ่มมากขึ้น

2) ทำการรวมข้อมูลทั้ง 5 ชนิด โดยมีขั้นตอนดังนี้

2.1) คัดกรองโดยการเลือกการเข้ามาในห้องผู้ป่วยวิกฤติครั้งแรกของผู้ป่วยแต่ละคนด้วย AdmissionID โดยอิงตามรหัส HN ของผู้ป่วย

2.2) รวมตารางด้วย AdmissionID, ICUDate และ ICUTime แบบ Left join โดยใช้ตารางบันทึกสัญญาณชีพเป็นตารางหลักในการรวมตารางข้อมูลผู้ป่วย เนื่องจากเป็นข้อมูลที่มีระดับความละเอียดทางเวลาที่ยุ่งที่สุด เพราะถูกเก็บเป็นรายนาที

#### 3.3.2 เลือกตัวแปร

ทำการเลือกตัวแปรที่เกี่ยวข้อง โดยการปรึกษาแพทย์ถึงตัวแปรที่มีความสำคัญต่อการเกิดภาวะซึ่อกใน ICU

#### 3.3.3 Feature Engineering

คือการสร้างตัวแปรใหม่จากตัวแปรที่มีอยู่เดิม เพื่อให้แบบจำลองมีประสิทธิภาพในการทำนายที่ดีขึ้น โดยที่สร้างตัวแปรใหม่ด้วยค่าในตัวแปรต่างๆ ดังนี้

1) ดัชนีซึ่อกไดเอสโตริลิก (Diastolic Shock Index; DSI) เป็นอัตราส่วนระหว่างอัตราการเต้นของหัวใจ (HR) ต่อความดันโลหิตขณะหัวใจคลายตัว (BP\_DIA) คำนวณจาก

$$DSI = \frac{HR}{BP\_DIA}$$

2) ดัชนีช็อก (Shock Index; SI) เป็นอัตราส่วนระหว่างอัตราการเต้นของหัวใจ (HR) ต่อความดันโลหิตขณะหัวใจบีบตัว (BP\_SYS) คำนวณจาก

$$SI = \frac{HR}{BP\_SYS}$$

3) ดัชนีช็อกที่ปรับปรุง (Modified Shock Index; MSI) เป็นอัตราส่วนระหว่างอัตราการเต้นของหัวใจ (HR) ต่อความดันเนลลี่ (MAP) คำนวณจาก

$$MSI = \frac{HR}{MAP}$$

4) ดัชนีช็อกที่ปรับตามอายุ (Adjusted Shock Index; ASI) เป็นดัชนีช็อกคูณด้วยอายุของผู้ป่วย คำนวณจาก

$$ASI = \frac{SI}{Age}$$

5) ดัชนีช็อกที่ปรับตามอายุจากค่าได้แอสโตรลิก (Age Modified Shock Index; AMSI) เป็นดัชนีช็อกได้อแอสโตรลิกคูณด้วยอายุของผู้ป่วย คำนวณจาก

$$AMSI = \frac{DSI}{Age}$$

6) ดัชนีช็อกที่ปรับตามการหายใจ (Respiratory Adjusted Shock Index; RASI) เป็นดัชนีช็อกคูณด้วยอัตราส่วนของอัตราการหายใจ (RR) หารด้วย 10 = SI × (RR/10)

$$RASI = \frac{SI \times RR}{10}$$

### 3.3.4 จัดการค่าผิดปกติ และค่านอกเกณฑ์

ผู้วิจัยได้ทำการสังเกตค่าในตัวแปรต่าง ๆ ด้วย Boxplot จากนั้นทำการปรึกษาแพทย์ถึงค่าที่สามารถเป็นไปได้และหาค่าที่เป็นไปได้ในตัวแปรต่าง ๆ จากงานวิจัยที่เกี่ยวข้อง เนื่องจากผู้ป่วยมีค่าที่ต่างจากคนปกติ และทำการจัดการค่าผิดปกติดังนี้

1) ทำการกรองข้อมูลเพื่อดูประเภทของตัวแปร ว่าแต่ละตัวแปรมีประเภทของข้อมูลเป็นจำนวนเต็ม (int) หรือทศนิยม (float) หรือไม่ หากข้อมูล มีค่าเป็นตัวหนังสือ (string) หรือวัตถุ (object) จะทำการแปลงค่านั้นให้เป็น int หรือ float หากข้อมูลนั้นเป็นค่าที่เป็น string ที่ไม่ใช่ตัวเลข หรือมี 2 ค่าในจุดข้อมูลเดียวจะทำการแทนที่ด้วยค่าสูญหาย และทำการเติมข้อมูลส่วนนั้นในภายหลัง

2) ทำการแทนค่าที่สูงมากผิดปกติ และต่ำมากผิดปกติที่คาดว่าจะเกิดจากความผิดพลาดในการวัดหรือนำเข้าข้อมูล โดยแทนค่าเป็นค่าสูญหาย และจะทำการเติมข้อมูลส่วนนั้นในภายหลัง โดยมีการปรึกษาช่วงค่าของตัวแปรต่างๆ ที่สามารถเป็นไปได้ในมนุษย์ร่วมกับแพทย์

3) ทำการศึกษางานวิจัยที่เกี่ยวข้องถึงค่าที่เป็นไปได้ในแต่ละตัวแปร โดยผู้วิจัยได้อ้างอิงค่าที่เป็นไปได้ตามงานวิจัยที่เกี่ยวข้อง Luo et al, (2023) ได้ใช้ตัวแปรสัญญาณชีพ 4 ตัวแปร ได้แก่ อัตราการเต้นของหัวใจ (HR) ในช่วง 30-260 ครั้งต่อนาที, อัตราการหายใจ (RR) ในช่วง 5-70 ครั้งต่อนาที, ค่าความอิ่มตัวของออกซิเจนในเลือด (O2SAT) ในช่วง 0-100%, และความดันเลือดเฉลี่ย (MAP) ในช่วง 10-200 มิลลิเมตรปรอท หากมีค่าที่เกินช่วงดังกล่าวผู้วิจัยจะทำการลบค่าเหล่านั้นออกจากแล้วแทนด้วยค่าสูญหาย

4) จัดการค่าที่สูญหายหรือค่าผิดปกติในตัวแปร Tidal Volume และ  $\text{FiO}_2$  เพื่อความถูกต้องและสอดคล้องกับหลักการทำงานการแพทย์ จะดำเนินการโดยอ้างอิงจากตัวแปรอื่นที่เกี่ยวข้อง ตามแนวทางที่แพทย์ผู้เชี่ยวชาญกำหนดซึ่งเป็นแนวทางที่มีพื้นฐานจากหลักการทำงานของ เครื่องช่วยหายใจ (Mechanical Ventilator) และข้อมูลทางสรีรวิทยาของผู้ป่วย

4.1) Tidal Volume คือ ปริมาตรของอากาศที่เคลื่อนเข้าและออกจากปอดในแต่ละรอบของการหายใจ และเป็นค่าที่สำคัญในการประเมินระบบทางเดินหายใจ ดังนั้น เมื่อพบค่าสูญหาย หรือมีค่าผิดปกติ จำเป็นต้องมีการดำเนินการแก้ไขโดยใช้ตัวแปรอื่นที่เกี่ยวข้อง หลักเกณฑ์ในการตรวจสอบค่าผิดปกติของ Tidal Volume มีดังนี้

1. หากผู้ป่วยคนใดไม่มีค่า ๆ นี้ในทุกช่วงเวลาเลย นั่นหมายความว่าผู้ป่วยรายนั้นไม่ได้ใส่เครื่องช่วยหายใจ จะกำหนดค่าเป็น 0 ทั้งหมด
2. หากผู้ป่วยนั้นใส่เครื่องช่วยหายใจแต่ไม่ได้อยู่ในโหมดเครื่องช่วยหายใจที่เหมาะสม ค่า Tidal Volume จะถือว่าไม่สามารถใช้ได้ และจะกำหนดให้เป็นค่าสูญหาย

3. ตรวจสอบว่า Tidal Volume มีค่าต่ำผิดปกติ ( $<100 \text{ mL}$ ) หรือไม่ ซึ่งหากค่าต่ำกว่าเกณฑ์นี้จะถือว่าไม่สมเหตุสมผลสำหรับผู้ป่วย และค่า Tidal Volume จะคงเดิม

4. คำนวณค่ารวมของการหายใจเข้าออก (Tidal Volume  $\times$  Respiratory Rate; RR) โดยค่านี้ใช้เพื่อเปรียบเทียบกับ Minute Ventilation (MV) ซึ่งเป็นปริมาตรของอากาศที่เข้าสู่ปอดใน 1 นาที

5. ทำการเปรียบเทียบกับ Minute Ventilation (MV) หาก  $\text{Tidal Volume} \times \text{RR} \leq 50\%$  ของ MV แสดงว่าอาจมีค่าที่ผิดปกติ และจำเป็นต้องทำการเติมค่าใหม่

กระบวนการเติมค่า Tidal Volume ที่ขาดหายไป

เมื่อพบว่าค่า Tidal Volume มีค่าผิดปกติหรือสูญหาย เราจะใช้ตัวแปรอื่นที่เกี่ยวข้องในการคำนวณเพื่อเติมค่า โดยใช้สูตร

$$\text{Tidal Volume} = \frac{MV \times 100}{RR}$$

ซึ่งเป็นวิธีที่ช่วยให้สามารถอนุมานค่าที่ใกล้เคียงกับค่าจริงของผู้ป่วยได้มากที่สุด

4.2) SETTING FIO<sub>2</sub> คือ ค่าความเข้มข้นของสัดส่วนของออกซิเจนที่ผู้ป่วยได้รับจากการหายใจ และเป็นตัวแปรสำคัญที่ใช้ประเมินภาวะของระบบทางเดินหายใจ เมื่อพบค่าที่ สูญหาย (Missing Values) หรือผิดปกติ (Outliers) จำเป็นต้องมีการเติมค่าตามเงื่อนไขที่กำหนด การจัดการค่าที่สูญหายหรือผิดปกติใน FIO<sub>2</sub> มีดังนี้

1. ตรวจสอบว่าค่า FIO<sub>2</sub> เป็น NaN หรือไม่ หากไม่มีค่าหรือค่าเป็น NaN จำเป็นต้องเติมค่าโดยอ้างอิงจากโหมดของเครื่องช่วยหายใจ
2. ตรวจสอบโหมดของเครื่องช่วยหายใจ (Ventilation Mode) ถ้าอยู่ในโหมดการช่วยหายใจ ค่า FIO<sub>2</sub> จะถูกกำหนดตามค่าเฉลี่ยที่ใช้ในโหมดนั้น
3. ถ้าอยู่ในโหมดการหายใจปกติ (Spontaneous Breathing) ค่า FIO<sub>2</sub> จะถูกกำหนดเป็น 0.21 หรือ 21%

กระบวนการเติมค่า FIO<sub>2</sub> ที่ขาดหายไป

1. กรณีผู้ป่วยไม่ได้ใช้เครื่องช่วยหายใจ (Spontaneous Breathing) ค่า FIO<sub>2</sub> จะเท่ากับ 0.21 (21%) ตามค่าปกติของอากาศที่หายใจ
2. กรณีผู้ป่วยใช้เครื่องช่วยหายใจ (Mechanical Ventilation) เติมค่าตามโหมดของเครื่องช่วยหายใจ

โดยแต่ละโหมดมีค่าดังนี้

โหมดช่วยหายใจแบบ Volume Control (VCV) ค่าเฉลี่ย FIO<sub>2</sub> ≈ 0.4 - 0.6

โหมดช่วยหายใจแบบ Pressure Control (PCV) ค่าเฉลี่ย FIO<sub>2</sub> ≈ 0.5 - 0.7

โหมด High Flow Oxygen Therapy (HFOT) ค่าเฉลี่ย FIO<sub>2</sub> ≈ 0.6 - 1.0

ทั้งนี้ กระบวนการดังกล่าวมีเป้าหมายเพื่อให้ข้อมูลมีความสมบูรณ์และสามารถนำไปใช้ในกระบวนการแพทย์ได้อย่างแม่นยำมากขึ้น

### 3.3.5 จัดการแกนเวลาให้มีมิติที่เท่ากัน

เนื่องจากข้อมูลถูกบันทึกเป็นรายนาที แต่ในบางกรณีข้อมูลไม่ได้ถูกบันทึกอย่างต่อเนื่อง ผู้วิจัยได้ทำการเติมช่วงเวลาที่ขาดหายไปเพื่อให้ครบตามจำนวน record ที่ความมีในแต่ละช่วงเวลา ตัวอย่างเช่น หากข้อมูลความ 24 ชั่วโมง หรือ 1,440 นาที แต่ข้อมูลผู้ป่วยคนนั้นมีเพียง 1,430 record ผู้วิจัยจะเติมช่วงเวลาที่ขาดหายไปให้ครบจนครบ

1,440 record โดยเติมช่วงเวลาที่ขาดหายไปโดยอิงตามลำดับเวลา เช่น หากมี record บันทึกที่เวลา 00:01:00 แล้วข้ามไปเป็น 00:05:00 ช่วงเวลาที่ขาดหายไปคือ 00:02:00 - 00:04:00 ซึ่งเวลาที่หายไปนั้นจะถูกเพิ่มขึ้นมาให้ครบค่าก่อนหน้าหรือการเติมแบบ forward filling

### 3.3.6 การแยกระดับความละเอียดของเวลา

เนื่องจากการเพิ่มแกนเวลาให้มีมิติที่เท่ากัน ทำให้เกิดค่าสูญหายขึ้นมาในข้อมูล หากจะทำการเติมค่าสูญหายนั้น จะเป็นจะต้องแยกระดับความละเอียดของเวลาออกมากกว่าเดิม เนื่องจากตัวแปรในข้อมูลมีความละเอียดของเวลาตั้งแต่ ข้อมูลคงที่ ข้อมูลรายชั่วโมง และข้อมูลรายนาที หากทำการนำไปเติมค่าสูญหายโดยที่ไม่แยกความละเอียดของเวลาออกจากกัน อาจจะทำให้ข้อมูลเกิดอคติ เช่นข้อมูลตัวแปรรายชั่วโมง ในชั่วโมงนั้นควรจะมีค่า ๆ เดียว แต่ถ้าหากข้อมูลรายชั่วโมงรวมอยู่กับข้อมูลรายนาที จะทำให้ใน 1 ชั่วโมงนั้น มีหลายค่าเป็นต้น

### 3.3.7 จัดการค่าสูญหาย

ขั้นตอนการจัดการกับค่าสูญหาย หลังจากที่แยกข้อมูลออกเป็น ข้อมูลคงที่ ข้อมูลรายชั่วโมง และข้อมูลรายนาทีแล้ว จะดำเนินการจัดการค่าสูญหายดังนี้

1) ข้อมูลเชิงปริมาณในรายงานที่ และรายชั่วโมง จะใช้การเติมค่าที่สูญหายของข้อมูลอนุกรมเวลาด้วยวิธีการ Linear Interpolation

2) ข้อมูลเชิงจำแนกประเภท ข้อมูลเชิงปริมาณที่เหลือ และข้อมูลผู้ป่วยที่ไม่สามารถเติมได้ในขั้นตอนแรก รวมถึงข้อมูลคงที่จะทำการเติมด้วย MissForest

### 3.3.8 ระบุจุดที่เกิดการซื้อกของผู้ป่วย

เมื่อทำการเติมค่าสูญหายในแต่ละระดับเวลาเสร็จ ผู้วิจัยจะทำการรวมตารางโดยการ join อีกครั้ง เพื่อให้ได้เป็นข้อมูลตารางหลัก เพื่อที่ผู้วิจัยจะได้ทำการระบุจุดที่เกิดการซื้อกของผู้ป่วย โดยมีหลักการในการระบุจุดที่ผู้ป่วยมีภาวะซื้อกด้วยเงื่อนไข diastolic shock index อย่างโดยย่างหนึ่งต่อไปนี้

1. MAP < 65
2. Systolic Blood Pressure < 90
3. Diastolic shock index > 2 เมื่อ Diastolic shock index = Heart Rate / Diastolic Blood Pressure

### 3.3.9 คัดเลือกช่วงข้อมูล

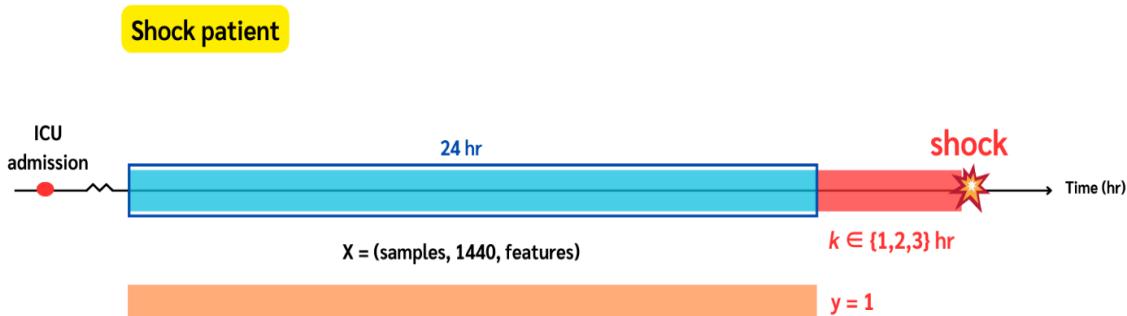
ในการคัดเลือกข้อมูลเพื่อนำมาใช้สร้างข้อมูลนำเข้าและทำนายภาวะซื้อกใน ICU ผู้วิจัยได้ดำเนินการตามขั้นตอนดังนี้

1) ผู้ป่วยที่เกิดภาวะช็อก ผู้วิจัยเลือกข้อมูลของผู้ป่วยที่มีภาวะช็อกโดยจะพิจารณาข้อมูลย้อนหลังจากจุดที่เกิดภาวะช็อกครั้งแรกเป็นระยะเวลา  $K$  ชั่วโมง โดยกำหนดค่า  $K$  เป็น 1, 2 และ 3 ชั่วโมง จากนั้นจะดึงข้อมูลย้อนหลังไปอีก 24 ชั่วโมง ทำให้ในแต่ละกรณีจะได้ข้อมูลที่มีความยาวรวม 1,440 นาทีต่อเหตุการณ์ช็อกของผู้ป่วยหนึ่งราย ซึ่งการกำหนดช่วงเวลาไม่น้อยกว่า 24 ชั่วโมงนั้นจะช่วยให้สามารถวิเคราะห์พฤติกรรมและแนวโน้มของตัวแปรทางสรีรวิทยาและข้อมูลทางการแพทย์ของผู้ป่วยก่อนเกิดภาวะช็อกได้อย่างละเอียด ซึ่งจะช่วยเพิ่มความแม่นยำของแบบจำลองในการตรวจจับการเปลี่ยนแปลงของสัญญาณชีพหรือข้อมูลทางการแพทย์อื่น ๆ ที่อาจบ่งชี้ถึงความเสี่ยงในการเกิดภาวะช็อกได้

2) สำหรับผู้ป่วยที่ไม่มีภาวะช็อก ผู้วิจัยได้เลือกข้อมูลตั้งแต่ช่วงที่ผู้ป่วยเข้ารับการรักษาใน ICU โดยเหตุผลที่ผู้วิจัยเลือกใช้ข้อมูลตั้งแต่ช่วงที่ผู้ป่วยเข้ารับการรักษาที่ ICU เพราะว่าในช่วงนั้น เป็นช่วงที่ผู้ป่วยอยู่ในภาวะวิกฤตมากที่สุด และเสี่ยงต่อการเกิดภาวะช็อก โดยจะเลือกระยะเวลาตั้งแต่ 24 ชั่วโมง แต่ไม่เกิน 26 ชั่วโมง ทั้งนี้เนื่องจากจำนวนผู้ป่วยที่ไม่มีภาวะช็อกมีจำนวนน้อยกว่าผู้ป่วยที่เกิดภาวะช็อกอย่างมาก เพื่อแก้ไขปัญหาความไม่สมดุลของข้อมูล ผู้วิจัยจึงใช้เทคนิค sliding window เพื่อเพิ่มจำนวนข้อมูลนำเข้าของกลุ่มผู้ป่วยที่ไม่มีภาวะช็อกให้เพียงพอสำหรับการสร้างแบบจำลองที่มีประสิทธิภาพ ในขั้นตอนของการทำข้อมูลนำเข้า (Input) ต่อไป

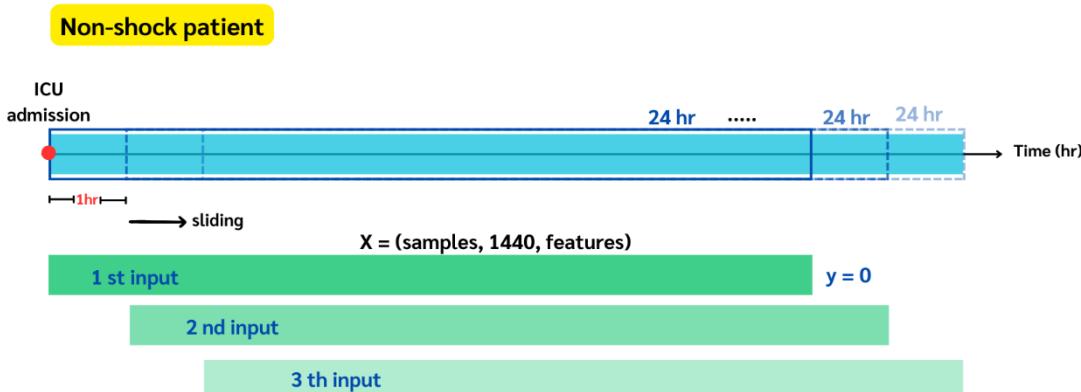
### 3.3.10 สร้าง Labels สำหรับทำนาย

หลังจากที่ทำการเลือกช่วงข้อมูลเรียบร้อยแล้ว ผู้วิจัยดำเนินการสร้างค่า label เพื่อใช้ในการทำนายภาวะช็อกใน ICU ดังนี้



ภาพที่ 3.1 การสร้างข้อมูลนำเข้า และกำหนดค่า label ของข้อมูลผู้ป่วยที่มีภาวะช็อก

1) ผู้ป่วยที่เกิดภาวะช็อก จะกำหนดค่า label โดยระบุจุดที่เกิดภาวะช็อกเป็นจุดเริ่มต้น จากนั้นย้อนหลังกลับไป K ชั่วโมง โดยกำหนดค่า K เป็น 1, 2 และ 3 ชั่วโมง ซึ่งข้อมูลที่อยู่ในจุดที่ K ชั่วโมงก่อนเกิดภาวะช็อกจะถูกกำหนดค่า label เป็น 1 เพื่อระบุว่ามีความเสี่ยงที่จะเกิดภาวะช็อกในอีก K ชั่วโมงข้างหน้า ส่วนข้อมูลที่อยู่ก่อนช่วงเวลา K ชั่วโมงจะถูกกำหนดค่า label เป็น 0 เพื่อระบุว่าไม่มีความเสี่ยงที่จะเกิดภาวะช็อกในช่วงเวลานั้น



ภาพที่ 3.2 การสร้างข้อมูลนำเข้า และกำหนดค่า label ของข้อมูลผู้ป่วยที่ไม่มีภาวะช็อก

2) ผู้ป่วยที่ไม่มีภาวะช็อก จะกำหนดค่า label เป็น 0 ทั้งหมด เพื่อระบุว่าไม่มีความเสี่ยงที่จะเกิดภาวะช็อกในช่วงเวลานั้น

### 3.3.11 การปรับมาตรฐานข้อมูล (Standardization)

ในขั้นตอนการสร้างแบบจำลอง ผู้วิจัยได้ทำการปรับมาตรฐานข้อมูล (Standardization) เพื่อให้ค่าของข้อมูลแต่ละตัวแปรมีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 ( $\text{mean} = 0$ ,  $\text{standard deviation} = 1$ ) การปรับมาตรฐานนี้ช่วยทำให้ข้อมูลมีความสอดคล้องกัน และทำให้แบบจำลอง Deep learning สามารถเรียนรู้ได้อย่างมีประสิทธิภาพ เนื่องจากข้อมูลในช่วงที่เหมาะสมจะส่งผลต่อการบรรจุของกระบวนการฝึกสอนแบบจำลองให้ดีขึ้น

#### การสร้างข้อมูลนำเข้าสำหรับผู้ป่วยที่มีภาวะช็อก

สำหรับผู้ป่วยที่มีภาวะช็อก จะได้ 1 ข้อมูลนำเข้า (input) ต่อเหตุการณ์ช็อก เนื่องจากข้อมูลที่ถูกเลือกมา มีขนาด 1440 นาที (24 ชั่วโมง) โดยแต่ละข้อมูลนำเข้าจะใช้ข้อมูล 24 ชั่วโมงแรก ว่าจะเกิดภาวะช็อกในอีก K ชั่วโมงข้างหน้าหรือไม่ ดังภาพที่ 3.1

## การสร้างข้อมูลนำเข้าสำหรับผู้ป่วยที่ไม่มีภาวะซ้อก

สำหรับผู้ป่วยที่ไม่มีภาวะซ้อก จำนวนข้อมูลนำเข้าที่สร้างได้จะสร้าง 3 ข้อมูลนำเข้าที่แต่ละอันมีขนาดเวลา 24 ชั่วโมง โดยทำการเลื่อนข้อมูลไปข้างหน้า 1 ชั่วโมงอีก 2 ครั้งโดยใช้หลักการเดียวกัน คือ กรอบเวลา 24 ชั่วโมงแรก ถูกใช้เพื่อทำนายว่าในอีก K ชั่วโมงข้างหน้าจะเกิดการซ้อกไหม ทำให้เกิดจำนวนข้อมูลนำเข้าที่แตกต่างกันขึ้นอยู่กับความยาวของข้อมูลที่มี ดังภาพที่ 3.2

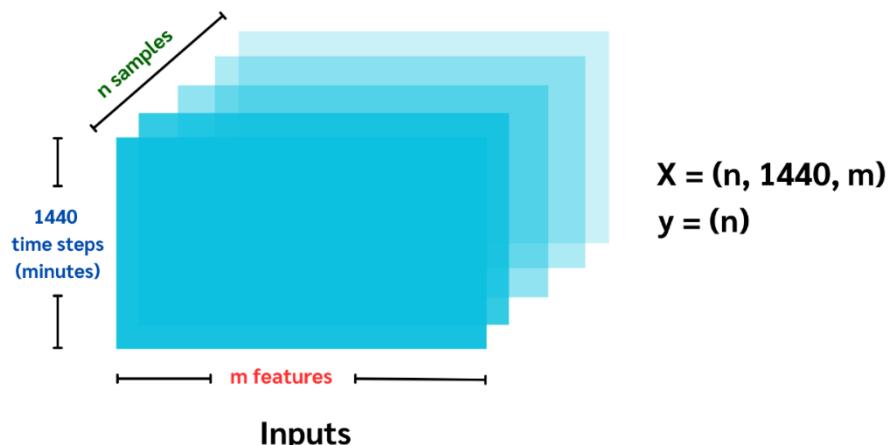
### 1) โครงสร้างของข้อมูลนำเข้า

แต่ละข้อมูลนำเข้า (input) มีลักษณะเป็น ลำดับเวลา (time series) ที่มี 1440 ช่วงเวลา (time steps) หรือ 1440 นาที โดยแต่ละ time step จะมี m ฟีเจอร์ ซึ่งประกอบไปด้วยตัวแปรคงที่ และตัวแปรพลวต (Dynamic features) ที่จะเป็นการรวมตัวแปรรายชั่วโมง และตัวแปรรายนาทีเข้าด้วยกัน เนื่องจากทั้ง 2 มีการเปลี่ยนแปลงตามเวลา ซึ่งข้อมูลทั้งหมดนี้จะถูกป้อนเข้าสู่แบบจำลอง เพื่อใช้ในการทำนาย และในแต่ละ time step จะประกอบด้วยค่าข้อมูลที่เกี่ยวข้องกับสถานะสุขภาพของผู้ป่วยในขณะนั้น เช่น ค่าอัตราการเต้นของหัวใจในช่วงเวลาหนึ่ง โดยข้อมูลเหล่านี้จะถูกใช้เป็น X (input features) ซึ่งเป็นตัวแปรนำเข้าของแบบจำลอง โดยมีโครงสร้างดังนี้

$$X = (n, 1440, m)$$

เมื่อ n คือ จำนวนตัวอย่างของข้อมูลนำเข้าทั้งหมด

m คือ จำนวนตัวแปรที่ใช้เป็นตัวแปรนำเข้า



ภาพที่ 3.3 โครงสร้างของข้อมูลนำเข้า

## 2) การกำหนดค่าเป้าหมาย (target values; y)

สำหรับแต่ละข้อมูลนำเข้า หรือหนึ่งกรอบเวลา จะมีการกำหนดค่าเป้าหมาย หรือ  $y$  ซึ่งจะเป็นค่า 0 หรือ 1 ขึ้นอยู่กับความเสี่ยงในการเกิดภาวะซ้อกในอีก  $k$  ชั่วโมงข้างหน้า

โดย  $y$  เป็น 0 หมายถึง ในช่วงเวลา 24 ชั่วโมงที่ใช้เป็น input นั้น ยังไม่มีความเสี่ยง ต่อการเกิดภาวะซ้อกในอีก  $K$  ชั่วโมงข้างหน้า

$y$  เป็น 1 หมายถึง ในช่วงเวลา 24 ชั่วโมงที่ใช้เป็น input นั้น มีความเสี่ยง ต่อการเกิดภาวะซ้อกในอีก  $K$  ชั่วโมงข้างหน้า

ข้อมูลเป้าหมายนี้มีโครงสร้างดังนี้

$$y = (n)$$

เมื่อ  $n$  คือ จำนวนตัวอย่างข้อมูลทั้งหมดของข้อมูลเป้าหมายที่ใช้สำหรับการฝึกแบบจำลอง

## 3.4 การสร้างแบบจำลอง (Modeling)

งานวิจัยนี้มี วัตถุประสงค์ในการพัฒนาและเลือกแบบจำลองที่ดีที่สุด สำหรับการทำนายภาวะซ้อกของผู้ป่วยใน ICU ซึ่งมีรายละเอียดดังนี้

### 3.4.1 เครื่องมือที่ใช้ในการสร้างแบบจำลอง

- 1) งานวิจัยนี้ใช้ภาษา Python version 3.10.12 ในการพัฒนาฝ่ายโปรแกรม Visual Studio Code สำหรับการทำความสะอาดและจัดเตรียมข้อมูล และรันผ่านการใช้ Google Colab Pro ในการสร้างแบบจำลองทำนาย
- 2) HPC server ของสำนักเทคโนโลยีดิจิทัล มหาวิทยาลัยขอนแก่น ใช้ในการประมวลผลการเติมข้อมูล
- 3) งานวิจัยนี้ใช้ไลบรารี (Library) สำหรับการพัฒนาและฝึกแบบจำลอง ได้แก่ Tensorflow version 2.17.0 และ Keras version 3.4.1

### 3.4.2 การแบ่งชุดข้อมูลด้วย Stratified Group 5-fold Cross Validation

เนื่องจากผู้วิจัยสร้างหลายข้อมูลนำเข้าจากข้อมูล 1 Admission ของผู้ป่วย ผู้วิจัยได้ทำการแบ่งชุดข้อมูลเป็นชุดข้อมูลสำหรับการฝึก (Training set) และชุดข้อมูลสำหรับการตรวจสอบ (Validation set) โดยใช้วิธี Stratified Group K-Fold Cross Validation จากไลบรารี sklearn.model\_selection.StratifiedGroupKFold วิธีการนี้มีคุณสมบัติสำคัญ 2 ประการ

- 1) รักษาสัดส่วนของคลาสเป้าหมาย (target class) หรือการมีหรือไม่มีภาวะซ้อก ให้สมดุลระหว่างชุดข้อมูลฝึกและชุดข้อมูลตรวจสอบในแต่ละ fold
- 2) รักษาความเป็นกลุ่มของข้อมูลโดยจัดให้ข้อมูลทั้งหมดของผู้ป่วยแต่ละรายอยู่ในชุดเดียวกัน นั่นคือ ผู้ป่วย 1 ราย จะไม่ถูกแยกระหว่างชุดฝึกและชุดตรวจสอบ

ในการจัดแบ่งข้อมูล ผู้วิจัยได้ทำการตั้งค่า Seed เพื่อให้ผลการทดลองสามารถทำซ้ำได้ และตรวจสอบการกระจายของคลาสในแต่ละ fold เพื่อให้มั่นใจว่าการแบ่งข้อมูลมีความสมดุล โดยในแต่ละ fold จะมีการตรวจสอบว่า ไม่มี ID ของผู้ป่วยซ้ำกันระหว่างชุดฝึกและชุดตรวจสอบ เพื่อป้องกันการรั่วไหลของข้อมูล (data leakage)

สำหรับการทดสอบแบบจำลอง ผู้วิจัยจะใช้ข้อมูลอีกชุดหนึ่งจากระบบฐานข้อมูล Smart-ICU ของแผนกผู้ป่วย วิกฤตโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น ที่ถูกแยกเอาไว้ ซึ่งเป็นชุดข้อมูลที่ไม่ได้นำมาใช้ในการฝึกแบบจำลอง เพื่อประเมินประสิทธิภาพของแบบจำลองกับข้อมูลใหม่ที่ไม่เคยเห็นมาก่อน

### 3.4.3 การสร้างแบบจำลองสำหรับการทำนายการเกิดภาวะซื้อกลับด้วย Deep Learning

งานวิจัยนี้มีการสร้างแบบจำลองการจำแนกประเภทแบบใบหน้า สำหรับการทำนายการเกิดภาวะซื้อกลับของผู้ป่วยล่วงหน้า ว่ามีความเสี่ยงที่จะเกิดภาวะซื้อก หรือไม่เกิดภาวะซื้อก โดยใช้เทคนิค Deep Learning หลายรูปแบบ ได้แก่แบบจำลองแบบเดียว เช่น CNN, LSTM, Transformer และแบบจำลองแบบผสม เช่น CNN + LSTM, CNN + Transformer, LSTM + Transformer เพื่อให้สามารถประมวลผลข้อมูลนำเข้าได้อย่างละเอียดมากขึ้นจากข้อมูลนำเข้าที่มีขนาด 1440 นาที จึงจำเป็นต้องมีการแยกย่อยภายในข้อมูลนำเข้าอีกซึ่งได้จัดให้อยู่ในรูปแบบ Time Windows โดยใช้ 10 นาทีต่อ 1 window โดยแบบจำลองทั้งหมดได้นำการแจกแจงเวลา (Time Distributed) มาใช้ในการประมวลผลแต่ละช่วงเวลาในลักษณะแยกย่อยก่อนส่งข้อมูลเข้าสู่แบบจำลองหลัก

#### 1) โครงสร้างพื้นฐานของแบบจำลอง

ในการนำข้อมูลนำเข้า เข้าไปประมวลผลในแบบจำลอง ผู้วิจัยได้ทำการแยกข้อมูลคงที่ออกจากข้อมูลนำเข้าหลัก เพื่อต้องการเน้นย้ำหลังจากผ่านแบบจำลอง เพื่อในขั้นตอนก่อนการทำนาย ข้อมูลคงที่ จะไม่สูญเสียค่า หรือหายไปในขณะประมวลผลผ่านแบบจำลอง เนื่องจากในกระบวนการเรียนรู้ของแบบจำลอง Deep Learning มักเกิดการสูญเสียข้อมูลหรือการเปลี่ยนแปลงค่าข้อมูลเมื่อผ่านการประมวลผลในแต่ละชั้นของเครือข่าย โดยเฉพาะข้อมูลคงที่ซึ่งมีความสำคัญในการวินิจฉัยทางการแพทย์ เช่น ข้อมูลประชากรศาสตร์ของผู้ป่วย อายุ เพศ หรือโรคประจำตัว การใช้เทคนิคการเชื่อมต่อแบบข้ามชั้น (skip connection) ช่วยรักษาข้อมูลคงที่ให้คงอยู่จนถึงขั้นตอนสุดท้ายของการทำนาย ทำให้แบบจำลองสามารถใช้ประโยชน์จากปัจจัยเสี่ยงที่ไม่เปลี่ยนแปลงตามเวลาเหล่านี้ในการคาดการณ์การเกิดภาวะซื้อกลับได้อย่างแม่นยำมากขึ้น

แบบจำลองที่ใช้ในงานวิจัยนี้มีโครงสร้างพื้นฐานเดียวกัน โดยมีข้อมูลนำเข้า ที่ถูกจัดการในรูปแบบ Time Windows (10 นาทีต่อ 1 window) ข้อมูลถูกแปลงเป็นขนาดดังนี้

$$X = (n, 144, 10, m)$$

เมื่อ  $n$  คือ จำนวนตัวอย่างของข้อมูลนำเข้าทั้งหมด

144 คือ จำนวนกรอบเวลา ที่ถูกคำนวณจากจำนวนนาทีทั้งหมดใน 1 input หารด้วยจำนวนนาทีใน 1 time window

10 คือ จำนวนนาทีใน 1 time window

$m$  คือ จำนวนตัวแปรทั้งหมด

## 2) การใช้ Time Distributed ในแบบจำลอง

เมื่อข้อมูลนำเข้าถูกจัดให้อยู่ในขนาดที่เหมาะสมสมแล้ว แบบจำลองทั้งหมดจะทำการแยกเวลา (Time Distributed) มาใช้เพื่อให้สามารถประมวลผลข้อมูลแต่ละช่วงเวลาได้อย่างพร้อมกันก่อนส่งเข้าสู่แบบจำลองหลัก ซึ่งช่วยให้แบบจำลองสามารถประมวลผลข้อมูลได้ในระดับ Time Windows โดยไม่สูญเสียลำดับเวลา เพิ่มความสามารถในการเรียนรู้โครงสร้างของข้อมูลในแต่ละช่วงเวลา และรองรับโครงสร้างของแบบจำลองการเรียนรู้เชิงลึกได้ ซึ่งในแต่ละแบบจำลองจะมีวิธีการใช้ Time Distributed ดังนี้

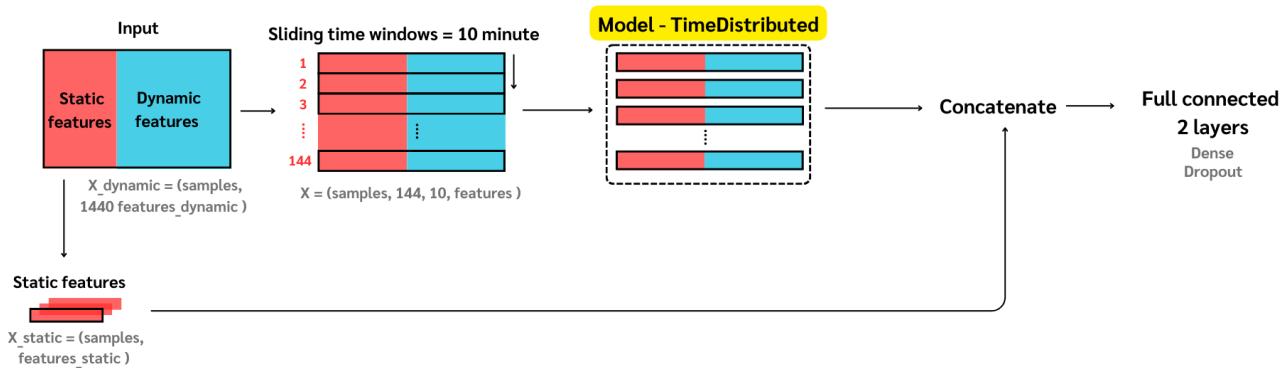
แบบจำลองแบบเดียว (Single Models) ใช้สถาปัตยกรรมแบบจำลองแบบเดียวสำหรับการประมวลผลข้อมูล Time-Series โดย Time Distributed จะถูกใช้เพื่อช่วยให้แบบจำลองเรียนรู้จากแต่ละ Time Window ได้อย่างมีประสิทธิภาพ ได้แก่

CNN ถูกใช้เพื่อดึงคุณลักษณะเชิงพื้นที่ (Spatial Features) จากข้อมูล Time-Series โดยใช้ 1 Conv1D ภายใน Time Distributed เพื่อสกัดคุณลักษณะจากแต่ละ Time Window โดยที่ CNN จะทำการสกัดคุณลักษณะจากข้อมูลภายในแต่ละ Time Window จากนั้นใช้ Max Pooling เพื่อลดขนาดของข้อมูลให้เหลือเฉพาะคุณลักษณะที่สำคัญ หลังจากนั้นใช้ Flatten เพื่อเปลี่ยนข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการป้อนเข้า Fully Connected Layers และ Static Features จะถูกเพิ่มเข้ามาผ่าน Dense Layers จากนั้นข้อมูล Static และ CNN Output จะถูก Concatenate ผ่าน Fully Connected Layers และสร้างผลลัพธ์

LSTM ถูกใช้เพื่อเพื่อดึง ความสัมพันธ์เชิงลำดับ (sequential patterns) ใน Time-Series 2) โดยใช้ LSTM ผ่าน Time Distributed เพื่อช่วยให้แบบจำลองสามารถวิเคราะห์แต่ละ Time Window จากนั้นใช้ LSTM ชั้นที่สอง ที่อยู่นอก Time Distributed เพื่อเรียนรู้ความสัมพันธ์ระหว่าง Time Windows ได้ และ Static Features จะถูกเพิ่มเข้ามาผ่าน Dense Layers ก่อนรวมข้อมูลเข้าด้วยกัน จากนั้นข้อมูล Static และ LSTM Output จะถูก Concatenate ผ่าน Fully Connected Layers และสร้างผลลัพธ์

Transformer ใช้ Self-Attention Mechanism เพื่อจับความสัมพันธ์ระยะไกลระหว่าง 3) ข้อมูลภายใน Time-Series โดย Time Distributed ถูกใช้เพื่อช่วยให้ Multi Head Attention ทำงานกับแต่ละ Time Window ได้อย่างรวดเร็ว จากนั้นใช้ Layer Normalization และ Residual Connection เพื่อช่วยให้แบบจำลองเรียนรู้ได้ดี

ขึ้น และ Static Features จะถูกเพิ่มเข้ามาผ่าน Dense Layers ก่อนรวมข้อมูลเข้าด้วยกัน จากนั้นข้อมูล Static และ Transformer Output จะถูก Concatenate ผ่าน Fully Connected Layers และสร้างผลลัพธ์



ภาพที่ 3.4 โครงสร้างทั่วไปของแบบจำลองแบบเดี่ยว

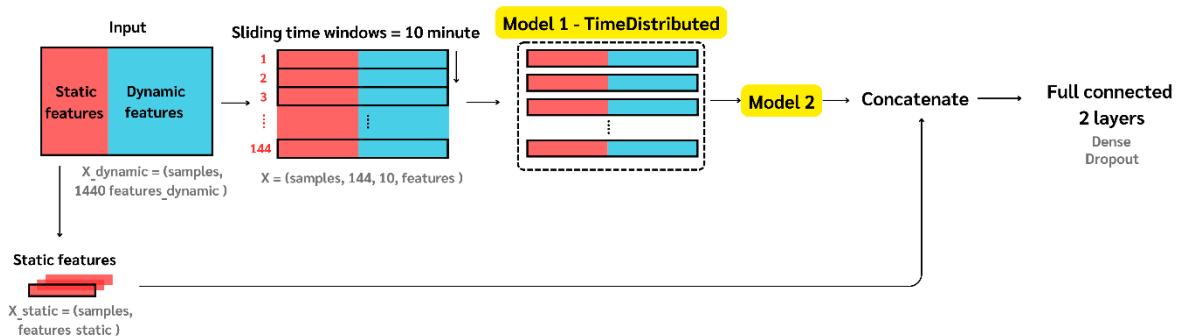
แบบจำลองแบบผสม (Hybrid Models) ใช้การรวมสถาปัตยกรรมของแบบจำลองหลายประเภทเข้าด้วยกัน เพื่อให้สามารถเรียนรู้ทั้ง ลักษณะเฉพาะเชิงพื้นที่ (Spatial Features) และ ลำดับของข้อมูล (Temporal Features) ได้อย่างแม่นยำ ได้แก่

CNN + LSTM ผสมผสาน CNN ในการสกัดคุณลักษณะเชิงพื้นที่จากข้อมูล Time-Series และ LSTM เพื่อเรียนรู้ความสัมพันธ์ของข้อมูลตามลำดับเวลา โดย Conv1D ภายใน Time Distributed จะสกัดคุณลักษณะจากแต่ละ Time Window โดยที่ CNN จะทำการ สกัดคุณลักษณะจากข้อมูลภายในแต่ละ Time Window จากนั้นใช้ Max Pooling เพื่อลดขนาดของข้อมูลให้เหลือเฉพาะคุณลักษณะที่สำคัญ หลังจากนั้นใช้ Flatten เพื่อเปลี่ยนข้อมูลให้อยู่ในรูปแบบที่เหมาะสม และเป็นลำดับเพื่อเข้าสู่ LSTM เพื่อวิเคราะห์ความสัมพันธ์เชิงลำดับของ Time Windows และ Static Features จะถูกเพิ่มเข้ามาผ่าน Dense Layers ก่อนรวมข้อมูลเข้าด้วยกัน จากนั้นข้อมูล Static และ LSTM Output จะถูก Concatenate ผ่าน Fully Connected Layers และสร้างผลลัพธ์

CNN + Transformer ผสมผสาน CNN ในการสกัดคุณลักษณะพื้นที่จากข้อมูล Time-Series และ Transformer เพื่อเรียนรู้ความสัมพันธ์ของข้อมูลในช่วงเวลาต่าง ๆ โดย Conv1D ภายใน Time Distributed จะสกัดคุณลักษณะจากแต่ละ Time Window โดยที่ CNN จะทำการ สกัดคุณลักษณะจากข้อมูลภายในแต่ละ Time Window จากนั้นใช้ Max Pooling เพื่อลดขนาดของข้อมูลให้เหลือเฉพาะคุณลักษณะที่สำคัญ หลังจากนั้นลำดับจะเข้าสู่ Transformer เพื่อใช้คุณสมบัติของ Multi Head Attention และ Residual Connection เพื่อเรียนรู้ความสัมพันธ์ระยะไกลของข้อมูล จากนั้นจะใช้ Layer Normalization เพื่อเพิ่มความเสถียรของแบบจำลอง โดย

Static Features จะถูกเพิ่มเข้ามาผ่าน Dense Layers ก่อนรวมข้อมูลเข้าด้วยกัน จากนั้นข้อมูล Static และ Transformer Output จะถูก Concatenate ผ่าน Fully Connected Layers และสร้างผลลัพธ์

LSTM + Transformer โดย LSTM จะใช้เพื่อวิเคราะห์ความสัมพันธ์เชิงลำดับ (Sequential Patterns) ในข้อมูล Time-Series ในขณะที่ Transformer ช่วยเรียนรู้ความสัมพันธ์ระยะไกล (Long-range Dependencies) ระหว่างข้อมูล การทำงานเริ่มจาก Time Distributed LSTM ที่จะประมวลผลข้อมูลในแต่ละ Time Window โดย LSTM ชั้นแรกจะมีการคืนค่าลำดับข้อมูลไปยัง LSTM ชั้นที่สอง ซึ่งจะสกัดคุณลักษณะเชิงลำดับของข้อมูลภายในแต่ละ Time Window หลังจากนั้น ผลลัพธ์จะถูกส่งเข้าสู่โมดูล Transformer ที่ใช้ Multi-Head Attention เพื่อเรียนรู้ความสัมพันธ์ระหว่าง Time Windows ต่างๆ พร้อมด้วย Residual Connection และ Layer Normalization เพื่อเพิ่มความเสถียรของแบบจำลอง ในขณะเดียวกัน Static Features จะถูกประมวลผลผ่าน Dense Layers เพื่อสกัดคุณลักษณะที่สำคัญ จากนั้นข้อมูล Static และผลลัพธ์จาก Transformer จะถูกรวมเข้าด้วยกัน (Concatenate) และส่งไปยัง Fully Connected Layers ก่อนที่จะสร้างผลลัพธ์สุดท้ายผ่าน Dense Layer



ภาพที่ 3.5 โครงสร้างทั่วไปของแบบจำลองแบบผสม

#### 3.4.4 การใช้ Loss ในการปรับปรุงแบบจำลอง

ในการสร้างและฝึกสอนแบบจำลอง Deep learning ผู้วิจัยได้ใช้ Loss Function เป็นตัวชี้วัดความผิดพลาดระหว่างค่าที่คำนวณโดยแบบจำลองกับค่าจริง (ground truth) Loss Function นี้จะถูกใช้เพื่อปรับปรุงน้ำหนักของแบบจำลองระหว่างการฝึกสอน โดยในงานวิจัยนี้ใช้ Binary Cross-Entropy Loss ซึ่งเป็น Loss Function ที่เหมาะสมกับปัญหาการทำนายจำแนกประเภทแบบใบหน้า

#### 3.4.5 การปรับแต่งและเพิ่มประสิทธิภาพของแบบจำลอง

ในการพัฒนาแบบจำลองให้มีประสิทธิภาพสูงสุดและป้องกันปัญหา overfitting ผู้วิจัยได้ใช้เทคนิคต่าง ๆ ดังนี้

- 1) การปรับอัตราการเรียนรู้แบบปรับตัวได้ (Adaptive Learning Rate)

ผู้วิจัยใช้ Reduce learning rate จากไลบรารี ReduceLROnPlateau ที่เป็นพารามิเตอร์ที่จะช่วยลดอัตราการเรียนรู้ลงเมื่อค่า validation loss ไม่มีการปรับปรุงติดต่อกันหลายรอบ ช่วยให้แบบจำลองสามารถเรียนรู้ได้ละเอียดมากขึ้นในช่วงท้ายของการฝึกสอน เพื่อป้องกันการติดอยู่ใน local minimum หรือจุดต่ำสุดเฉพาะที่ในพื้นที่ของค่าความผิดพลาด (error surface)

## 2) การควบคุมความซับซ้อนของแบบจำลอง (Regularization)

ผู้วิจัยใช้ L1 Regularization หรือ Lasso regression จากไลบรารี keras.regularizers เพื่อลดความซับซ้อนของแบบจำลองและป้องกัน overfitting ช่วยให้แบบจำลองเลือกใช้เฉพาะตัวแปรที่สำคัญจริงๆ โดยทำให้ค่าน้ำหนักที่ไม่จำเป็นมีค่าเป็นศูนย์

## 3) การหยุดการเรียนรู้แต่เนื่อง (Early Stopping)

ผู้วิจัยใช้ Early Stopping จากไลบรารี tensorflow.keras.callbacks เพื่อติดตามค่า validation loss และหยุดการฝึกสอนเมื่อไม่มีการปรับปรุงติดต่อกันเป็นระยะเวลาหนึ่ง เพื่อป้องกันปัญหา overfitting ที่อาจเกิดจากการฝึกสอนนานเกินไป ช่วยประหยัดเวลาและทรัพยากรในการฝึกสอน

## 4) Dropout

เป็นเทคนิคที่สุ่มปิดการทำงานของ neuron บางตัวในระหว่างการฝึกสอน ทำให้แบบจำลองไม่พึ่งพา neuron ตัวใดตัวหนึ่งมากเกินไป จากไลบรารี tensorflow.keras.layers ที่มีชื่อว่า Dropout ช่วยให้แบบจำลองเรียนรู้ feature ที่หลากหลายและทนทานต่อ noise ในข้อมูลเหมาะสมสำหรับแบบจำลองที่มีขนาดใหญ่และมีความซับซ้อนสูง

## 5) Batch Normalization

จะเป็นการปรับค่าข้อมูลในแต่ละ batch ให้มีการกระจายตัวที่เหมาะสม จากไลบรารี tensorflow.keras.layers ช่วยให้แบบจำลองเรียนรู้ได้เร็วขึ้นและเสถียรมากขึ้นลดปัญหา internal covariate shift ที่เกิดจากการเปลี่ยนแปลงของการกระจายตัวของข้อมูล เหมาะสำหรับแบบจำลองที่ต้องการความเร็วในการเรียนรู้และความเสถียร

เนื่องจาก Dropout และ Batch Normalization เป็นเทคนิคที่ทำงานกับการส่งผ่านข้อมูลระหว่างชั้นของโครงข่ายประสาทเทียม (layer) การใช้ทั้งสองเทคนิคพร้อมกันอาจรบกวนการเรียนรู้ซึ่งกันและกัน และส่งผลต่อเสถียรภาพของแบบจำลอง ผู้วิจัยจึงเลือกใช้เพียงเทคนิคใดเทคนิคหนึ่ง ในการฝึกสอน และทดสอบแบบจำลองในแต่ละครั้ง และคุณประสิทธิภาพของแบบจำลองประกอบในการตัดสินใจ ว่าเทคนิคใดให้ผลลัพธ์ที่ดีที่สุดในแต่ละแบบจำลอง

### 3.5 การประเมินประสิทธิภาพของแบบจำลอง (Evaluation)

การวัดประสิทธิภาพของการทำนายภาวะซื้อกลับจากการติดเชื้อล่วงหน้ามีขั้นตอนดังนี้

#### 3.5.1 เครื่องมือที่ใช้ในการประเมินแบบจำลอง

ในการประเมินประสิทธิภาพของแบบจำลองการทำนายภาวะซื้อกลับจากการติดเชื้อล่วงหน้า ใช้ภาษา Python ผ่านแพลตฟอร์ม Google Colaboratory เพื่อรันการทดสอบและวิเคราะห์ข้อมูล

#### 3.5.2 ข้อมูลที่ใช้ในการประเมินประสิทธิภาพแบบจำลอง

ข้อมูลที่ใช้ประเมินประสิทธิภาพของแบบจำลองคือ ข้อมูลจากชุดทดสอบ

#### 3.5.3 เกณฑ์ในการประเมินประสิทธิภาพแบบจำลอง

1) ค่าความถูกต้อง (Accuracy) เป็นสัดส่วนของการทำนายที่ถูกต้องต่อการทำนายทั้งหมด ซึ่งใช้วัดประสิทธิภาพเบื้องต้นของแบบจำลองในการแยกแยะระหว่างผู้ป่วยที่มีภาวะซื้อกลับและผู้ที่ไม่มีภาวะซื้อกลับ

2) กราฟ AUC-ROC ใช้เพื่อประเมินความสามารถของแบบจำลองในการจำแนกความเสี่ยง โดยแสดงความสัมพันธ์ระหว่าง True Positive Rate (Sensitivity) และ False Positive Rate (1 - Specificity) โดยค่า AUC (Area Under Curve) ช่วยให้เห็นประสิทธิภาพโดยรวมของแบบจำลองในการทำนายภาวะซื้อกลับ ค่า AUC ที่เข้าใกล้ 1 บ่งบอกว่าแบบจำลองมีความแม่นยำสูงในการแยกแยะระหว่างกลุ่มเป้าหมาย

3) AUC-PR (Area Under the Precision-Recall Curve) ใช้ประเมินประสิทธิภาพของแบบจำลองในกรณีที่ข้อมูลมีความไม่สมดุลระหว่างคลาส โดยแสดงความสัมพันธ์ระหว่างค่า Precision และ Recall ซึ่งเป็นเกณฑ์ที่มีประโยชน์อย่างยิ่งในการประเมินแบบจำลองสำหรับกรณีที่มีจำนวนผู้ป่วยภาวะซื้อกลับน้อยกว่าผู้ป่วยปกติมาก

4) F1 Score เป็นค่าเฉลี่ย harmonic ของ Precision และ Recall ซึ่งให้ความมองที่สมดุลระหว่างความสามารถในการระบุผู้ป่วยที่มีภาวะซื้อกลับได้ถูกต้อง และความสามารถในการไม่ระบุผู้ป่วยปกติว่าเป็นผู้ป่วยภาวะซื้อกลับ F1 Score มีค่าสูงสุดที่ 1 และต่ำสุดที่ 0 โดยค่าที่สูงแสดงถึงประสิทธิภาพที่ดีของแบบจำลอง

การเลือกแบบจำลองที่ดีที่สุดสามารถทำได้โดยพิจารณาจากเกณฑ์ข้างต้น หากแบบจำลองได้มีค่าเหล่านี้ในระดับสูง และสามารถแยกแยะความเสี่ยงได้ทั้งในกลุ่มที่มีและไม่มีภาวะซื้อกลับอย่างสมดุล เป็นการบ่งบอกว่าแบบจำลองนั้นมีประสิทธิภาพในการทำนายสูงสุด

### 3.6 การนำไปใช้จริง (Deployment)

#### 3.6.1 การแสดงผลบนเว็บแอปพลิเคชัน (Web Application)

##### 1. การออกแบบเว็บแอปพลิเคชัน

ผู้วิจัยได้พัฒนาเว็บแอปพลิเคชัน สำหรับทำนายภาวะซื้อคล่วงหน้า สำหรับผู้ป่วยใน ICU โดยเว็บแอปพลิเคชันนี้สามารถทำนายภาวะซื้อคล่วงหน้าได้ ด้วยการนำข้อมูลจากระบบฐานข้อมูล Smart-ICU ที่จะถูกอัปโหลดโดยแพทย์ โดยแพทย์จำเป็นต้องอัปโหลดข้อมูลที่เป็นไฟล์ .CSV ทั้งหมดจำนวน 5 ไฟล์ด้วยกัน ได้แก่

- 1) ข้อมูลผู้ป่วย
- 2) ข้อมูลประวัติการรักษา
- 3) ข้อมูลผลตรวจทางห้องปฏิบัติการ
- 4) ข้อมูลบันทึกสมุดสารน้ำ
- 5) ข้อมูลบันทึกสัญญาณชีพ

เพื่อทำนายภาวะซื้อคล่วงหน้าจากข้อมูลที่ได้รับในขณะนั้น โดยมีเงื่อนไขคือ AdmissionID ของผู้ป่วยทุกคนที่จะถูกทำนาย จะต้องมีอยู่ในไฟล์ และผู้ป่วยต้องมีเวลามากกว่า 24 ชั่วโมง จึงจะสามารถทำนายได้ โดยเว็บแอปพลิเคชันแบ่งออกเป็น 4 ส่วน ได้แก่ หน้าหลัก (Home) สำหรับภาพรวมของระบบ, หน้าสำหรับการทำนาย (Prediction) ที่ใช้อัปโหลดข้อมูลและเริ่มกระบวนการทำนาย, หน้าผลลัพธ์ (Result) ที่แสดงตารางผลการทำนายความเสี่ยงเป็นเปอร์เซ็นต์พร้อมระบุสถานะ Shock หรือ Non-shock และหน้าประวัติ (History) ซึ่งแสดงประวัติการทำนายทั้งหมดพร้อมระดับความเสี่ยง (Risk Level) ว่าอยู่ในระดับใด ซึ่งมี 4 ระดับคือ ไม่มีความเสี่ยง (0-20%), ความเสี่ยงต่ำ (21-50%), ความเสี่ยงปานกลาง (51-70%) และ ความเสี่ยงสูง (71-100%) ซึ่งหน้านี้จะสามารถเปรียบเทียบผลเมื่อก่อนหน้าได้ ว่าคนไข้ เมื่อเวลาผ่านไป มีความเสี่ยงเพิ่มขึ้นหรือลดลงเท่าใด โดยจะมีการแสดงผลเป็นตารางเปรียบเทียบ และกราฟพล็อตแสดงการเปลี่ยนแปลงของค่าความเสี่ยง ซึ่งสามารถบันทึกผลออกเป็นรายงานแบบไฟล์ PDF ได้

##### 2. เครื่องมือที่ใช้ในการพัฒนาเว็บแอปพลิเคชัน

- 1) Visual Studio Code (VS Code) เป็นโปรแกรมที่ใช้ในการพัฒนาโค้ด
- 2) Flask เป็น Web Framework ของภาษา Python ที่ใช้เป็นตัวกลางในการเชื่อมต่อระหว่างแบบจำลอง กับหน้าเว็บ
- 3) HTML, CSS, JavaScript ใช้ในการพัฒนาส่วนของ User Interface
- 4) Python ใช้สำหรับพัฒนาแบบจำลอง และประมวลผลข้อมูล
- 5) GitHub ใช้สำหรับเผยแพร่โค้ดและการจัดการเวอร์ชัน

## บทที่ 4

### ผลการวิจัย

งานวิจัยนี้มีวัตถุประสงค์ เพื่อวิเคราะห์ตัวแปรที่ส่งผลต่อการเกิดภาวะซ้อกของผู้ป่วยใน ICU เพื่อสร้างแบบจำลองสำหรับการทำนายภาวะซ้อกของผู้ป่วยใน ICU ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา ของโรงพยาบาล ศรีนครินทร์ จังหวัดขอนแก่น ซึ่งมีผลการวิจัยดังนี้

#### 4.1 ผลการศึกษาทำความเข้าใจข้อมูล

##### 4.1.1 ข้อมูลที่ใช้วิเคราะห์

งานวิจัยนี้ ผู้วิจัยได้ใช้ข้อมูลทุติยภูมิจากระบบฐานข้อมูล Smart-ICU ของแผนกผู้ป่วยวิกฤตโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ตั้งแต่วันที่ 15 ตุลาคม 2565 – 3 กุมภาพันธ์ 2568 ประกอบด้วยข้อมูลจำนวน 5 ชนิด 3 ประเภทที่แบ่งตามระดับความละเอียดทางเวลา ได้แก่ ข้อมูลคงที่ ข้อมูลรายชั่วโมง และข้อมูลรายนาที ที่ถูกคัดเลือกผู้ป่วยที่มีอายุมากกว่า 18 ปี มีเวลาอยู่ในแผนกผู้ป่วยวิกฤต อย่างน้อย 24 ชั่วโมง และมี AdmissionID หรือ HN อยู่ในทุกตาราง และทำการลบตัวแปรที่มีค่าสูญหายเกินร้อยละ 70 และเนื่องจากงานวิจัยได้ทดลองทำนายช่วงเวลาล่วงหน้า 1,2 และ 3 ชั่วโมง ก่อนเกิดภาวะซ้อก ทำให้มีข้อมูลผู้ป่วยที่ถูกใช้ทั้งหมดจะแตกต่างกันในแต่ละช่วงเวลาล่วงหน้าก่อนเกิดภาวะซ้อก โดยจำนวนผู้ป่วยในช่วงเวลา ก่อนเกิดภาวะซ้อกที่ 1, 2 และ 3 ชั่วโมงมีจำนวนทั้งสิ้น 530, 527 และ 525 รายตามลำดับ ดังตารางที่ 4.1

**ตารางที่ 4.1** แสดงจำนวนข้อมูลผู้ป่วยในแต่ละชุดข้อมูลและในแต่ละช่วงเวลาการทำนายล่วงหน้า

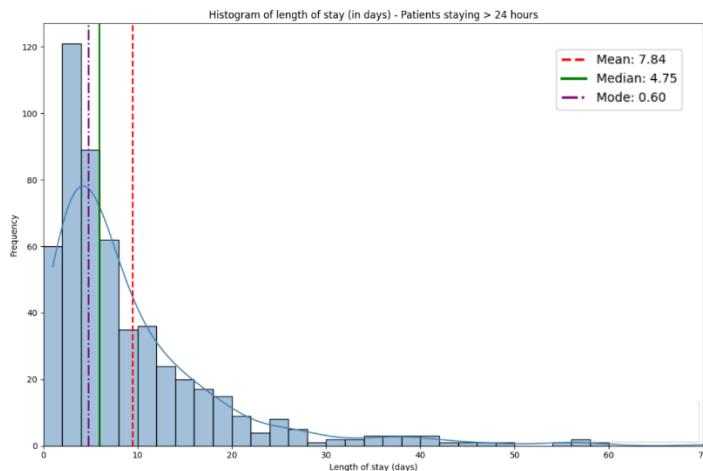
ช่วงเวลาการ ทำนาย ล่วงหน้า (ชั่วโมง)	ประเภทข้อมูล	จำนวนผู้ป่วยที่มีภาวะซ้อก (ราย) (%)	จำนวนผู้ป่วยที่ไม่มีภาวะซ้อก (ราย) (%)	จำนวนผู้ป่วยทั้งหมด (ราย) (%)
1	ชุดฝึกสอน และ ตรวจสอบ	400 (96.39%)	100 (86.96%)	500 (94.34%)
	ชุดทดสอบ	15 (3.61%)	15 (13.04%)	30 (5.66%)
	รวม	415 (100%)	115 (100%)	530 (100%)
2	ชุดฝึกสอน และ ตรวจสอบ	396 (96.35%)	101 (87.50%)	497 (94.31%)
	ชุดทดสอบ	15 (3.65%)	15 (12.50%)	30 (5.69%)
	รวม	411 (100%)	116 (100%)	527 (100%)

ช่วงเวลาการ ทำงาน ล่วงหน้า (ชั่วโมง)	ประเภทชุดข้อมูล	จำนวนผู้ป่วยที่มีภาวะซื้อกลับ (ราย) (%)	จำนวนผู้ป่วยที่ไม่มีภาวะซื้อกลับ (ราย) (%)	จำนวนผู้ป่วยทั้งหมด (ราย) (%)
3	ชุดฝึกสอน และ ตรวจสอบ	394 (96.33%)	101 (87.07%)	495 (94.29%)
	ชุดทดสอบ	15 (3.67%)	15 (12.93%)	30 (5.71%)
	รวม	409 (100%)	116 (100%)	525 (100%)

โดยในแต่ละช่วงเวลา ก่อนเกิดภาวะซื้อกลับ จะได้ผลการคัดเลือกของตัวแปรทั้งหมด 35 ตัวแปร เป็นตัวแปรคงที่ 18 ตัวแปร ตัวแปรรายชั่วโมงจำนวน 4 ตัวแปร และตัวแปรรายนาที 13 ตัวแปร ดังตาราง 3.2 - 3.6

#### 4.1.2 ผลการสำรวจ และวิเคราะห์ข้อมูล

##### 1) ระยะเวลาในการเข้ารับการรักษาของผู้ป่วยใน ICU



ภาพที่ 4.1 Histogram ระยะเวลาในการเข้ารับการรักษาใน ICU ของผู้ป่วย

ตารางที่ 4.2 แสดงค่าสถิติของระยะเวลาที่เข้ารับการรักษาใน ICU

ค่าสถิติ	ระยะเวลาที่เข้ารับการรักษาใน ICU
ค่าเฉลี่ย	9 วัน 10 ชั่วโมง
ค่ามัธยฐาน	5 วัน 22 ชั่วโมง
ค่าฐานนิยม	4 วัน 19 ชั่วโมง
ค่าน้อยสุด	1 วัน
ค่ามากสุด	74 วัน 14 ชั่วโมง

ค่าสถิติ	ระยะเวลาที่เข้ารับการรักษาใน ICU
ส่วนเปี่ยงเบนมาตรฐาน	10 วัน 2 ชั่วโมง
จำนวนผู้ป่วยทั้งหมด (ราย)	532

จากตารางที่ 4.2 แสดงระยะเวลาการเข้ารับการรักษาของผู้ป่วยใน ICU ที่มีระยะเวลาการเข้ารับการรักษาใน ICU มาากกว่า 24 ชั่วโมงขึ้นไป พบร่วมกับผู้ป่วยจำนวน 532 รายมีค่าเฉลี่ยการเข้ารับการรักษาใน ICU อยู่ที่ 9 วัน 10 ชั่วโมง โดยมีค่ามัธยฐาน 5 วัน 22 ชั่วโมง และค่าฐานนิยม 4 วัน 19 ชั่วโมง แสดงให้เห็นถึงการกระจายตัวแบบเบื้องตัวของข้อมูล เนื่องจากค่าเฉลี่ยสูงกว่าค่ามัธยฐาน และจากการที่ 4.1 แสดงชิสโตแกรมระยะเวลาในการเข้ารับการรักษาใน ICU ของผู้ป่วย แสดงให้เห็นว่าผู้ป่วยส่วนใหญ่มีระยะเวลาอยู่ในโรงพยาบาลนานอยกว่า 10 วัน แต่มีผู้ป่วยบางรายที่ต้องเข้ารับการรักษาตัวนานถึง 74 วัน 14 ชั่วโมง ซึ่งเป็นค่าสูงสุดที่พบ นอกจากนี้ ส่วนเปี่ยงเบนมาตรฐานที่สูงถึง 10 วัน 2 ชั่วโมง ยังบ่งชี้ถึงความแปรปรวนสูงในระยะเวลาการเข้ารับการรักษาใน ICU ของผู้ป่วยแต่ละราย ลักษณะการกระจายตัวเช่นนี้สอดคล้องกับรูปแบบที่ไว้ใจของข้อมูลทางการแพทย์ โดยเฉพาะผู้ป่วยใน ICU ที่มากพบว่าผู้ป่วยส่วนใหญ่มีระยะเวลาการรักษาไม่นานนัก แต่มีผู้ป่วยที่มีภาวะแทรกซ้อนหรือมีความรุนแรงของโรคสูงจำนวนหนึ่งที่ต้องอยู่ในหน่วยวิกฤตเป็นระยะเวลาภายนอก ส่งผลให้ค่าเฉลี่ยสูงกว่าค่ามัธยฐานและทำให้การกระจายตัวของข้อมูลเบื้องตัว

## 2) ผลการเปรียบเทียบความแตกต่างของตัวแปรคงที่ต่อภาวะช็อกและไม่ช็อก

ตารางที่ 4.3 ผลการเปรียบเทียบความแตกต่างของตัวแปรคงที่ใช้ปริมาณต่อภาวะช็อกและไม่ช็อก

ตัวแปร	ภาวะช็อก						p-value	
	ไม่มีภาวะช็อก (n = 115)			มีภาวะช็อก (n = 415)				
	ค่ามัธยฐาน	ค่าต่ำสุด	ค่าสูงสุด	ค่ามัธยฐาน	ค่าต่ำสุด	ค่าสูงสุด		
Age	64	19	88	67.5	18	98	0.013*	
SAP II	34	12	76	46	16	117	<0.001*	
CCI Total	5	0	11	5	0	16	0.12	
Lactate	20.6	4.3	202.6	31.05	3	286.9	<0.001*	
Apache III	60	17	108	85.80	26	190	<0.001*	
Height	163.60	140	191.00	163.00	136.00	187.00	0.21	

ตัวแปร	ภาวะชี้ออก						p-value	
	ไม่มีภาวะชี้ออก (n = 115)			มีภาวะชี้ออก (n = 415)				
	ค่ามัธยฐาน	ค่าต่ำสุด	ค่าสูงสุด	ค่ามัธยฐาน	ค่าต่ำสุด	ค่าสูงสุด		
BMI	22.86	15.79	37.47	21.93	11.36	41.72	0.05	
SOFA	4	0	11	7	0	22	<0.001*	
Weight	61.03	35	115	58.84	27	145.9	0.02*	
IO 24hr	199.23	-3408.95	3185.15	763.62	-3491.25	7853.25	<0.001*	
Total Intake 24hr	1820.85	325.00	6540.15	2319.07	520.40	9053.15	<0.001*	
Total Output 24hr	1755.00	0	5330.00	1464.25	25.00	6462.50	0.02*	
Total Intake ORAL	545.00	0	1940.00	423.75	-1.47	2940.00	0.01*	
Total Intake IV	1185.45	0	6540.15	1871.86	0	9053.15	<0.001*	

จากตารางที่ 4.3 แสดงผลการเปรียบเทียบความแตกต่างของตัวแปรคงที่ต่อภาวะชี้ออกและไม่ชี้ออก สามารถสรุปการวิเคราะห์ผลได้ดังนี้

จากการเปรียบเทียบกลุ่มที่มีภาวะชี้ออก (n = 415) กับกลุ่มที่ไม่มีภาวะชี้ออก (n = 115) โดยวิธี Mann Whitney U Test เนื่องจากข้อมูลไม่มีการแจกแจงแบบปกติ พบร่วตัวแปรคงที่ส่วนใหญ่มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ( $p\text{-value} \leq 0.05$ ) ผู้ป่วยที่มีภาวะชี้ออกมีอายุเฉลี่ยที่สูงกว่า แสดงให้เห็นว่าผู้สูงอายุมีความเสี่ยงต่อภาวะชี้ออกมากกว่า นอกเหนือไปยังค่า SAP II ในกลุ่มที่มีภาวะชี้ออกสูงกว่าอย่างชัดเจน เมื่อเทียบมัธยฐานของผู้ป่วยที่ไม่มีภาวะชี้ออก ซึ่งแสดงถึงความรุนแรงของโรคที่มากกว่า ในระดับ Lactate ของกลุ่มที่มีภาวะชี้ออก เป็นตัวบ่งชี้สำคัญของภาวะเนื้อเยื่อขาดออกซิเจน นอกจากนี้ค่า Apache III และ SOFA ที่เป็นตัวแปรประเมินความล้มเหลวของอวัยวะ โดยในกลุ่มที่มีภาวะชี้ออกมีค่ามัธยฐานสูงกว่ากลุ่มที่ไม่มีภาวะชี้ออก แสดงให้เห็นว่ากลุ่มที่มีภาวะชี้ออกมีความเสี่ยงต่อการเสียชีวิตและความรุนแรงของการทำงานของอวัยวะล้มเหลวที่สูงกว่า

ในตัวแปรสมดุลสารน้ำ พบร่วตัวแปรกลุ่มที่มีภาวะชี้ออกมีค่า IO 24hr สูงกว่ามาก สังเกตได้จากค่ามัธยฐานในกลุ่มที่มีภาวะชี้ออก 763.62 เทียบกับ 199.23 ( $p < 0.001$ ) แสดงถึงความไม่สมดุลของสารน้ำที่รุนแรงกว่า และกลุ่มชี้ออกได้รับสารน้ำรวมใน 24 ชั่วโมงมากกว่ากลุ่มที่ไม่มีภาวะชี้ออก สอดคล้องกับแนวทางการรักษาภาวะชี้ออกที่ต้องการการให้สารน้ำอย่างเพียงพอ นอกจากนี้ปริมาณการขับถ่ายใน 24 ชั่วโมงแตกต่างกันโดยกลุ่มชี้ออกมีการขับถ่ายน้อยกว่า ซึ่งอาจสะท้อนถึงการทำงานของไตที่ลดลงหรือการกักเก็บน้ำในร่างกายมากขึ้น การได้รับสารน้ำทางปาก (Total Intake

ORAL) ในกลุ่มซึอกต่ำกว่า อาจเป็น เพราะผู้ป่วยซึอกมีอาการหนักไม่สามารถรับประทานอาหารหรือน้ำได้ตามปกติ ในขณะที่การได้รับสารน้ำทางหลอดเลือดดำ (Total Intake IV) ในกลุ่มซึอกมีค่าสูงกว่า ซึ่งเป็นไปตามแนวทางการรักษาเพื่อรักษาสมดุลของสารน้ำในรักษาภาวะซึอก

นอกจากนี้ดัชนีมวลกาย (BMI), ส่วนสูง (Height) และ CCI Total ซึ่งเป็นดัชนีรวม ไม่มีความแตกต่างอย่างมีนัยสำคัญ ( $p > 0.05$ ) แสดงให้เห็นว่าผู้ป่วยที่มีภาวะซึอกมีความรุนแรงของโรคที่มากกว่า มีการเปลี่ยนแปลงทางสรีรวิทยาที่บ่งชี้ถึงการขาดเลือดของเนื้อเยื่อ และต้องการการจัดการสารน้ำที่แตกต่างจากผู้ป่วยที่ไม่มีภาวะซึอก ต่างจากตัวแปรเชิงกายภาพ ซึ่งข้อมูลเหล่านี้มีความสำคัญในการพัฒนาแนวทางการดูแลผู้ป่วยและการประเมินความเสี่ยงในผู้ป่วยิกฤต

ตารางที่ 4.4 ผลการเปรียบเทียบสัดส่วนความแตกต่างของตัวแปรคงที่เชิงคุณภาพต่อภาวะซึอกและไม่ซึอก

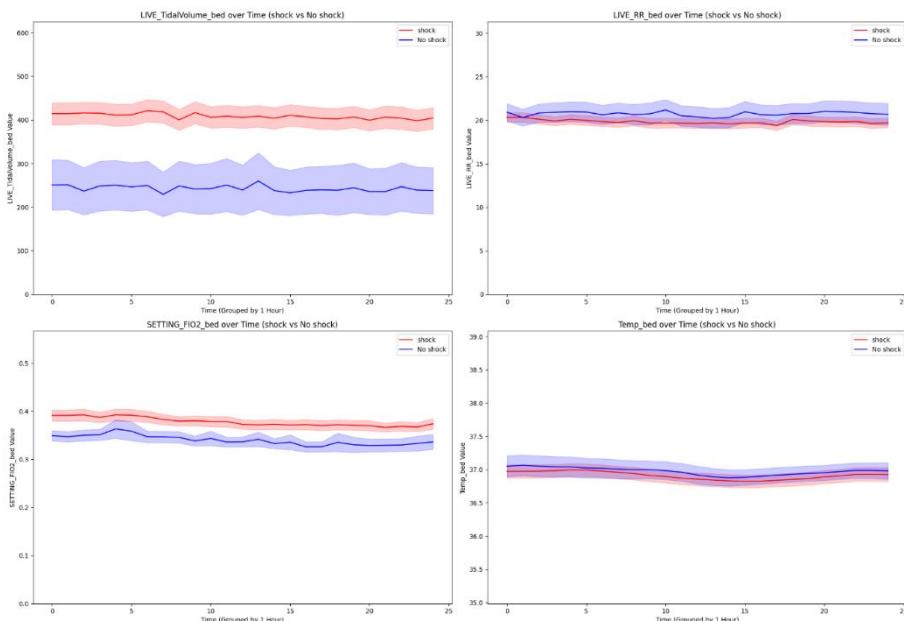
ตัวแปร	ภาวะซึอก				<i>p</i> -value	
	ไม่มีภาวะซึอก (n = 115)		มีภาวะซึอก (n = 415)			
	n	ร้อยละ	n	ร้อยละ		
<b>Sex</b>						
เพศหญิง	52	45.217	182	43.855	0.795	
	63	54.783	233	56.145		
<b>AKI</b>						
ไม่มีภาวะไตวายเฉียบพลัน	71	61.739	94	22.651	<0.001*	
มีภาวะไตวายเฉียบพลัน	44	38.261	321	77.349		
<b>CKD</b>						
ไม่มีภาวะไตเรื้อรัง	78	67.826	318	76.627	<0.001*	
มีภาวะไตเรื้อรัง	37	32.174	97	23.373		
<b>RRT</b>						
ไม่ได้รับการล้างไต	98	85.217	225	54.217	<0.001*	
ได้รับการล้างไต	17	14.783	190	45.783		

จากตารางที่ 4.4 แสดงผลการเปรียบเทียบสัดส่วนความแตกต่างของตัวแปรคงที่เชิงคุณภาพต่อภาวะช็อกและไม่ช็อกสามารถสรุปการวิเคราะห์ผลได้ดังนี้

ผู้ป่วยที่มีภาวะไตวายเฉียบพลัน และผู้ป่วยที่ได้รับการบำบัดด้วยการล้างไต มีแนวโน้มที่จะมีภาวะช็อกมากกว่าผู้ป่วยที่ไม่มีภาวะไตวายเฉียบพลันหรือไม่ได้รับการบำบัดด้วยการล้างไต โดยเฉพาะผู้ป่วยที่มีภาวะไตวายเฉียบพลันมีสัดส่วนภาวะช็อกสูงถึง 77.35% ขณะที่ผู้ป่วยที่ไม่มีภาวะไตวายเฉียบพลันมีสัดส่วนภาวะช็อกเพียง 22.65% ซึ่งแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ( $p < 0.001$ ) ในขณะเดียวกัน ผู้ป่วยที่ได้รับการบำบัดด้วยการล้างไต มีสัดส่วนภาวะช็อก 45.78% เทียบกับผู้ป่วยที่ไม่ได้รับการบำบัดด้วยการล้างไตที่มีสัดส่วนภาวะช็อก 54.22% ซึ่งแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ( $p < 0.001$ ) ในผู้ป่วยที่มีภาวะไตเรื้อรัง (CKD = 1) มีสัดส่วนภาวะช็อกที่ 23.37% เทียบกับผู้ป่วยที่ไม่มีภาวะไตเรื้อรังที่มีสัดส่วนภาวะช็อกถึง 76.627% ซึ่งแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ระหว่างเพศกับการเกิดภาวะช็อก ( $p = 0.795$ )

ดังนั้นตัวแปรด้านภาวะไตวายเฉียบพลัน ภาวะไตเรื้อรัง และการบำบัดทดแทนไตมีความสัมพันธ์อย่างมีนัยสำคัญกับการเกิดภาวะช็อก ในขณะที่เพศและไม่มีความสัมพันธ์ที่ชัดเจน ข้อมูลนี้สะท้อนให้เห็นว่าภาวะช็อกมีผลกระทบอย่างมากต่อการทำงานของไตและความจำเป็นในการได้รับการบำบัดทดแทนไต

### 3) ผลการสำรวจข้อมูลรายชั่วโมง

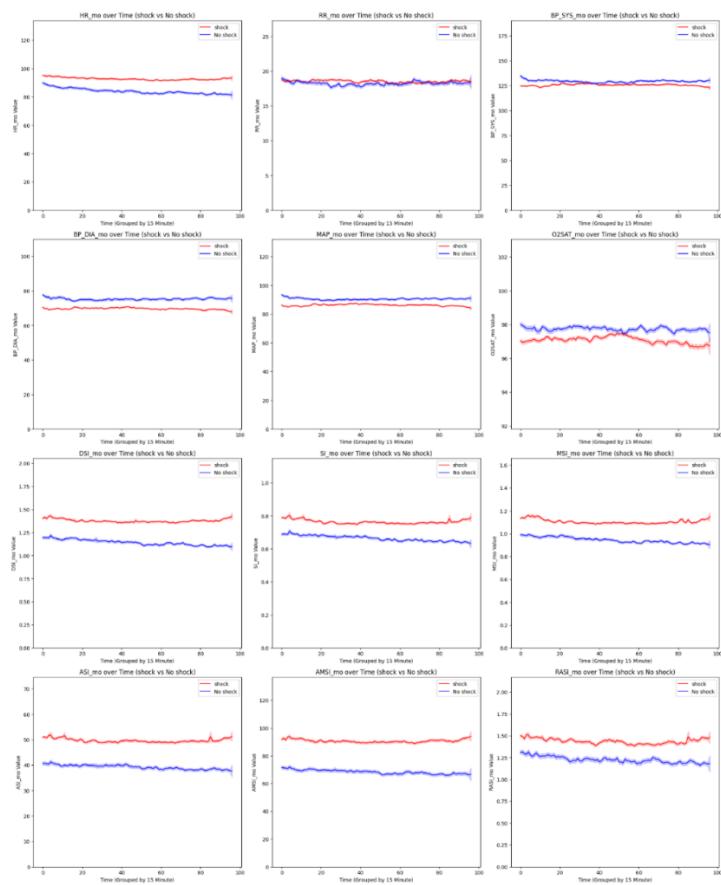


ภาพที่ 4.2 แสดงค่าเฉลี่ยตัวแปรรายชั่วโมงเชิงปริมาณในแต่ละชั่วโมง

จากภาพที่ 4.2 แสดงการเพล็อกตัวแปรรายชั่วโมงในแต่ละชั่วโมง ระหว่างผู้ป่วยที่มีภาวะช็อก (สีแดง) และไม่มีภาวะช็อก (สีน้ำเงิน) ในแต่ละชั่วโมงตลอด 24 ชั่วโมง โดยแสดงค่าเฉลี่ย (เส้นทึบ) และช่วงความเชื่อมั่น (พื้นที่โปร่งแสง) พบว่า LIVE\_TidalVolume หรือปริมาณอากาศที่เคลื่อนที่เข้าและออกจากปอดในแต่ละรอบการหายใจหนึ่งครั้ง ในผู้ป่วยที่มีภาวะช็อก อยู่ในระดับที่สูงกว่าเมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อก โดยกลุ่มมีภาวะช็อกมีค่าประมาณ 400 มล. ขณะที่กลุ่มนี้ไม่มีภาวะช็อกมีค่าประมาณ 250 มล. ส่วนค่า FiO2 หรืออัตราส่วนของออกซิเจนที่ผู้ป่วยได้รับเมื่อหายใจเข้าก็มีแนวโน้มเช่นเดียวกัน โดยกลุ่มนี้ภาวะช็อกใช้ค่าออกซิเจนขั้นสูงกว่ากลุ่มนี้ไม่มีภาวะช็อกเล็กน้อยประมาณ 0.37-0.40 เทียบกับ 0.32-0.35 สำหรับอัตราการหายใจ (LIVE\_RR) และอุณหภูมิร่างกาย (Temp) พบว่ามีความแตกต่างเพียงเล็กน้อยระหว่างสองกลุ่ม โดยอัตราการหายใจของผู้ป่วยทั้งสองกลุ่มอยู่ในช่วง 19 - 21 ครั้งต่อนาที และอุณหภูมิร่างกายอยู่ประมาณ 36.8 - 37 องศาเซลเซียส

ดังนั้นผลการวิเคราะห์แสดงให้เห็นว่าผู้ป่วยที่มีภาวะช็อกต้องการการสนับสนุนการหายใจหรือใส่เครื่องช่วยหายใจมากกว่า เนื่องจากปริมาตรลมหายใจและความเข้มข้นของออกซิเจนสูงกว่า เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อก แม้ว่าอัตราการหายใจและอุณหภูมิร่างกายจะไม่แตกต่างกันมาก

#### 4) ผลการสำรวจข้อมูลรายนาที



ภาพที่ 4.3 แสดงค่าเฉลี่ยตัวแปรรายนาทีเชิงปริมาณในทุก ๆ 15 นาที

จากภาพที่ 4.3 แสดงค่าเฉลี่ยตัวแปรรายนาทีเชิงปริมาณในทุก ๆ 15 นาที สามารถสังเกตความแตกต่างระหว่างผู้ป่วยที่มีภาวะช็อก (เส้นสีแดง) และผู้ป่วยที่ไม่มีภาวะช็อก (เส้นสีน้ำเงิน) ได้ดังนี้

อัตราการเต้นของหัวใจ (HR) ในผู้ป่วยที่มีภาวะช็อกสูงกว่าผู้ป่วยที่ไม่มีภาวะช็อกอย่างชัดเจนและคงที่ตลอดช่วงเวลาที่ติดตาม ในอัตราการหายใจ (RR) มีค่าใกล้เคียงกันระหว่างทั้งสองกลุ่ม โดยเส้นกราฟทั้งสองเส้นมีการทับซ้อนกันในหลายช่วงเวลา ขณะที่ความดันโลหิตขณะหัวใจบีบตัว (BP\_SYS) มีค่าค่อนข้างใกล้เคียงกันระหว่างทั้งสองกลุ่ม แต่ความดันโลหิตขณะหัวใจคลายตัว (BP\_DIA) ในผู้ป่วยที่มีภาวะช็อกมีค่าต่ำกว่าผู้ป่วยที่ไม่มีภาวะช็อกอย่างชัดเจน ส่งผลให้ความดันเฉลี่ย (MAP) ในกลุ่มผู้ป่วยที่มีภาวะช็อกต่ำกว่าด้วย และค่าความอิ่มตัวของออกซิเจนในเลือด (O2SAT) ในผู้ป่วยที่มีภาวะช็อกมีค่าต่ำกว่าผู้ป่วยที่ไม่มีภาวะช็อกเล็กน้อย ในส่วนของดัชนีอักเสบต่ำทุกประเภท ได้แก่ DS, SI, MSI, ASI, AMSI และ RASI มีค่าสูงกว่าในผู้ป่วยที่มีภาวะช็อกเมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อก โดยเฉพาะ ASI และ AMSI ที่แสดงความแตกต่างที่ชัดเจนมากที่สุด

เมื่อพิจารณาแนวโน้มการเปลี่ยนแปลงตามเวลา พบร่วมกันว่าความแตกต่างของตัวแปรระหว่างกลุ่มมีความคงที่ตลอดช่วงเวลาการติดตาม โดยไม่มีการเปลี่ยนแปลงอย่างมีนัยสำคัญในแนวโน้มของตัวแปรใดๆ ระหว่างทั้งสองกลุ่ม

## 4.2 ผลการเตรียมข้อมูล

### 4.2.1 การจัดการค่าผิดปกติ และค่านอกเกณฑ์

#### 1) การจัดการค่าผิดปกติ

จากการสำรวจค่าผิดปกติ พบทั่วไปที่มีค่าผิดปกติคือ ตัวแปร Age, Sex, Temp และ BP\_TYPE ซึ่งตัวแปรดังกล่าวเป็นตัวแปรที่เป็นข้อมูลประเภท string จากนั้นผู้วิจัยได้ทำการจัดการค่าเหล่านั้น ได้ผลดังนี้

ก่อนจัดการค่าผิดปกติ				ก่อนจัดการค่าผิดปกติ			
Age	Sex	Temp_bed	BP_TYPE_mo	Age	Sex	Temp_bed	BP_TYPE_mo
53 ปี	หญิง	NaN	ABP	53	0	NaN	0
53 ปี	หญิง	36.0	ABP	53	0	36.0	0
37 ปี	หญิง	NaN	NBP	37	0	NaN	1
37 ปี	หญิง	37.0	NBP	37	0	37.0	1
37 ปี	หญิง	NaN	ABP	37	0	NaN	0
...	...	...	...	...	...	...	...
65 ปี	หญิง	37.3	NBP	65	0	38.2	0
65 ปี	หญิง	36.6	NBP	65	0	37.3	1
65 ปี	หญิง	36.0	NBP	65	0	36.6	1
65 ปี	หญิง	38.7	NBP	65	0	36.0	1
65 ปี	หญิง	37.5	NBP	65	0	38.7	1

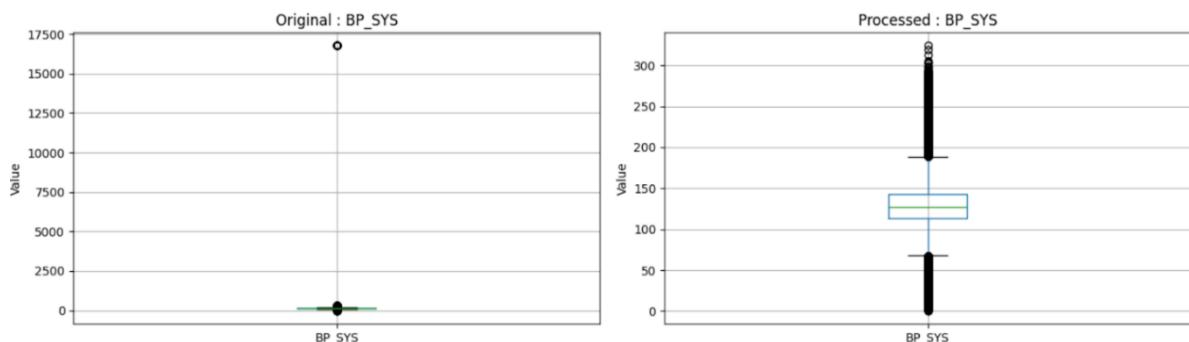


ภาพที่ 4.4 ผลก่อนและหลังการจัดการค่าผิดปกติ

## 2) การจัดการค่า outliers

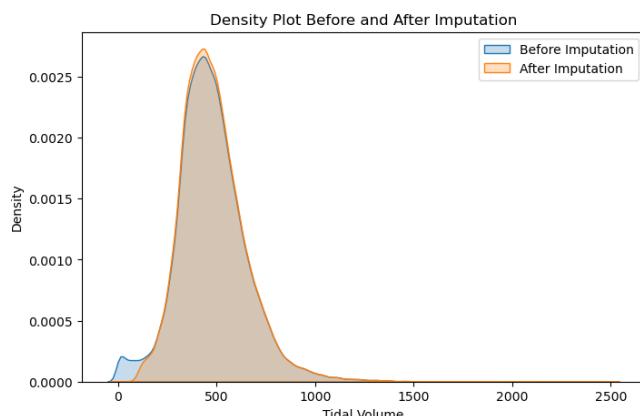
จากการสำรวจค่า outliers ในชุดข้อมูลผู้ป่วยวิกฤตโดยใช้ Box plot ได้ผลหลังการจัดการดังนี้ ข้อมูลคงที่ พบค่า outlier ในแพรสมดุลสารน้ำ ในตัวแปรเกี่ยวกับปริมาณสารน้ำเข้า-ออก (IO\_24hr, TotalIntake\_24hr, TotalOutput\_24hr) ทั้งในค่าบวกและค่าลบที่สูง โดยผู้วิจัยได้สอบถามแพทย์ถึงค่าที่เป็นไปได้โดยแพทย์แนะนำว่าถึงแม้ตัวแปรเหล่านี้จะมีค่าที่สูง แต่ก็สามารถบ่งบอกได้ถึงการเกิดภาวะซึ่อก จึงไม่ทำการจัดการค่าเหล่านี้

ในข้อมูลรายช่วงโมงก็ไม่ได้จัดการค่า outliers เช่นเดียวกันกับตัวแปรคงที่ แต่ในตัวแปรรายนาที ผู้วิจัยได้อ้างอิงค่าที่เป็นไปได้ตามงานวิจัยที่เกี่ยวข้อง Luo et al, (2023) ได้ใช้ตัวแปรสัญญาณชีพ (vital signs) 4 ตัวแปร ได้แก่ อัตราการเต้นของหัวใจ (HR) ในช่วง 30-260 ครั้งต่อนาที, อัตราการหายใจ (RR) ในช่วง 5-70 ครั้งต่อนาที, ค่าความอิ่มตัวของออกซิเจนในเลือด (O2SAT) ในช่วง 0-100%, และความดันเลือดเฉลี่ย (MAP) ในช่วง 10-200 มิลลิเมตรปรอท ผู้วิจัยจึงใช้ค่าในช่วงตามนี้เช่นเดียวกัน ในขณะเดียวกัน ตัวแปร BP\_SYS มีค่าที่สูงผิดปกติ ผู้วิจัยจึงทำการลบค่าดังกล่าวออกแล้วแทนด้วยค่าสูญหาย ได้ผลดังภาพที่ 4.5



ภาพที่ 4.5 Boxplot แสดงค่าสูงผิดปกติ และ การแทนที่ให้เป็นค่าสูญหายในตัวแปร BP\_SYS

## 3) ผลจัดการค่าที่สูญหายหรือค่าผิดปกติในตัวแปร Tidal Volume และ FIO2



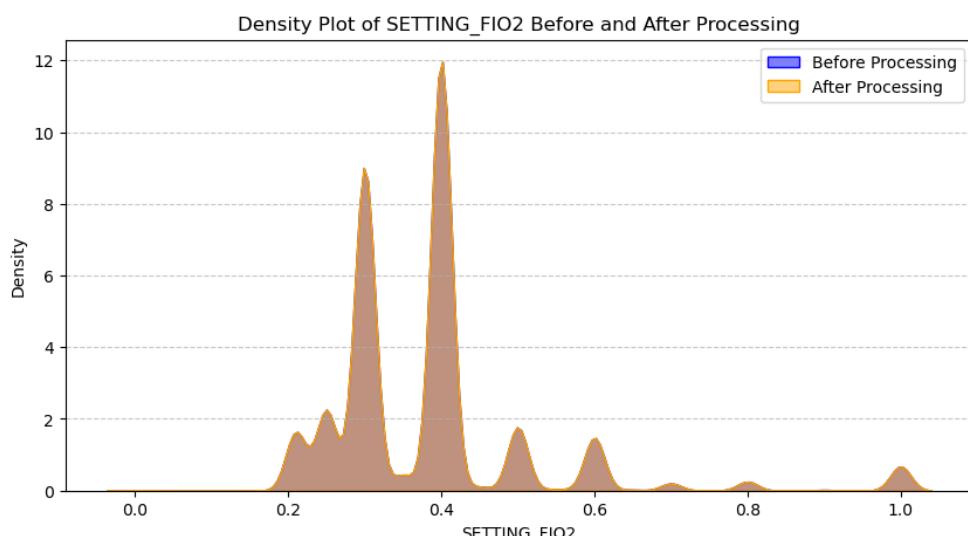
ภาพที่ 4.6 กราฟความหนาแน่นแสดงผลก่อนและการเติมค่า Tidal Volume ด้วยตัวแปรอื่น

ตารางที่ 4.5 แสดงการเปรียบเทียบก่อนและหลังการเติมค่า Tidal Volume ด้วยตัวแปรอื่น

การเติมค่า	ค่าเฉลี่ย	ค่ามัธยฐาน	จำนวนข้อมูลที่มีค่า < 100 (ແກ່)
ก่อนการเติมค่า	474.77	459	2,224
หลังการเติมค่า	483.75	462	32
การเปลี่ยนแปลง	+8.98 (+1.89%)	+3.0 (+0.65%)	-2,192 (-98.56%)

จากภาพที่ 4.6 และตารางที่ 4.5 แสดงกราฟความหนาแน่นและตารางแสดงผลก่อนและการเติมค่า Tidal Volume ด้วยตัวแปรอื่น พบร่วมกับก่อนการเติมค่า มีการกระจายตัวของข้อมูลในช่วงค่าต่ำ ซึ่งแสดงถึงข้อมูลที่อาจมีค่าผิดปกติ โดยมีข้อมูลที่มีค่า Tidal Volume ต่ำกว่า 100 จำนวนถึง 2,224 รายการ คิดเป็น 1.28% ของข้อมูลทั้งหมด 173,094 รายการ ค่าเฉลี่ยก่อนการเติมค่าอยู่ที่ 474.77 และค่ามัธยฐานอยู่ที่ 459.0 หลังการเติมค่าด้วยสูตร  $Tidal\ Volume = (MV \times 100) / RR$  พบร่วมกับการกระจายตัวของข้อมูลมีความสมมาตรมากขึ้น โดยค่าส่วนใหญ่อยู่ในช่วง 300-700 ค่าเฉลี่ยเพิ่มขึ้นเป็น 483.75 ซึ่งเพิ่มขึ้น 8.98 หรือ 1.89% และค่ามัธยฐานเพิ่มขึ้นเป็น 462.0 ซึ่งเพิ่มขึ้น 3.0 หรือ 0.65% การเติมค่าช่วยลดจำนวนข้อมูลที่มีค่าต่ำผิดปกติได้อย่างมีประสิทธิภาพ โดยเหลือข้อมูลที่มีค่า Tidal Volume ต่ำกว่า 100 เพียง 32 รายการเท่านั้น ซึ่งลดลง 2,192 รายการ หรือลดลง 98.56% แสดงให้เห็นว่ากระบวนการเติมค่าดังกล่าวสามารถปรับปรุงคุณภาพของข้อมูลให้มีความเหมาะสมสำหรับการวิเคราะห์ทางการแพทย์มากขึ้น

#### 4) ผลจัดการค่าที่สูญหายหรือค่าผิดปกติในตัวแปร FIO<sub>2</sub>



ภาพที่ 4.7 กราฟความหนาแน่นแสดงผลก่อนและการเติมค่า FIO<sub>2</sub> ด้วยตัวแปรอื่น

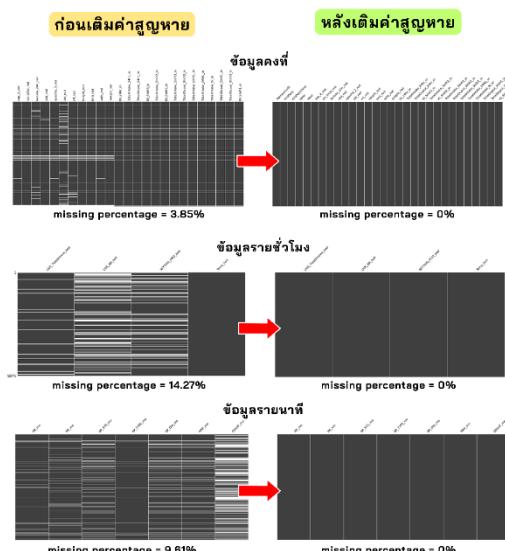
ตารางที่ 4.6 แสดงการเปรียบเทียบก่อนและหลังการเติมค่า FIO<sub>2</sub>

การเติมค่า	ค่าเฉลี่ย	ค่ามัธยฐาน	ความสมบูรณ์ของข้อมูล (ແຕງ)
ก่อนการเติมค่า	0.3833	0.4	127,467 (73.64%)
หลังการเติมค่า	0.3832	0.4	169,905 (92.55%)
การเปลี่ยนแปลง	ไม่มีการเปลี่ยนแปลง	ไม่มีการเปลี่ยนแปลง	18.91%

จากภาพที่ 4.7 และตารางที่ 4.6 แสดงกราฟความหนาแน่นและตารางแสดงผลก่อนและการเติมค่า FIO<sub>2</sub> พบร้าข้อมูลเติมค่าสูญหาย ถึง 26.36% ของข้อมูลทั้งหมด 173,094 รายการ ค่าเฉลี่ยก่อนการเติมค่าอยู่ที่ 0.3833 หรือ 38.33% ของปริมาณออกซิเจน และค่ามัธยฐานอยู่ที่ 0.4000 ซึ่งสอดคล้องกับการตั้งค่าทั่วไปในผู้ป่วยที่ต้องการออกซิเจนในระดับปานกลาง

หลังการเติมค่าโดยอาศัยข้อมูลใหม่การซ่วยหายใจเป็นตัวกำหนด สามารถเติมค่าได้ถึง 73.64% ของข้อมูลที่เป็นค่าสูญหายทั้งหมด ส่งผลให้จำนวนข้อมูลที่สามารถนำໄປวิเคราะห์เพิ่มขึ้นจาก 127,467 เป็น 169,905 ซึ่งเพิ่มขึ้น 42,438 แม้จะเติมค่าข้อมูลในปริมาณมาก แต่ค่าเฉลี่ยและค่ามัธยฐานไม่มีการเปลี่ยนแปลง โดยค่าเฉลี่ยลดลง 0.03% และค่ามัธยฐานมีค่า 0.4000 เท่าเดิม โดยกราฟความหนาแน่นยังคงรูปแบบเดิมหลังจากการเติมค่าแล้ว แสดงให้เห็นถึงวิธีการเติมค่าจากข้อมูลใหม่เครื่องซ่วยหายใจสามารถรักษาลักษณะเฉพาะของข้อมูลได้ ทำให้ข้อมูลหลังการประมวลผลมีทั้งปริมาณที่เพิ่มขึ้นและไม่สูญเสียลักษณะสำคัญของข้อมูล

#### 4.2.2 ผลการจัดการค่าสูญหาย



ภาพที่ 4.8 ข้อมูลในแต่ละระดับความลະເອີຍດ່ວລາກ່ອນແລະหลังการเติมค่าสูญหาย

จากภาพที่ 4.8 แสดงการเติมค่าสูญหายในแต่ละระดับความลະเอียดเวลา พบร้า ก่อนการเติมค่าสูญหาย ข้อมูลคงที่มีค่าสูญหายร้อยละ 3.85 ข้อมูลรายชั่วโมงมีค่าสูญหายร้อยละ 14.27 และข้อมูลรายงานที่มีค่าสูญหายร้อยละ 9.61 การเติมค่าสูญหายได้ดำเนินการโดยใช้วิธี Linear Interpolation สำหรับข้อมูลเชิงปริมาณในชุดข้อมูลรายชั่วโมง และรายงานที่ ซึ่งเป็นข้อมูลที่มีลักษณะต่อเนื่องตามเวลา และใช้วิธี MissForest สำหรับข้อมูลคงที่และข้อมูลเชิงปริมาณจากชุดข้อมูลรายงานที่และรายชั่วโมงที่ไม่เหมาะสมกับการใช้ Linear Interpolation หลังจากการเติมค่าสูญหายด้วยวิธีการดังกล่าว พบร้าข้อมูลทุกรดับความลະเอียดเวลาไม่ค่าสูญหายลดลงเหลือร้อยละ 0

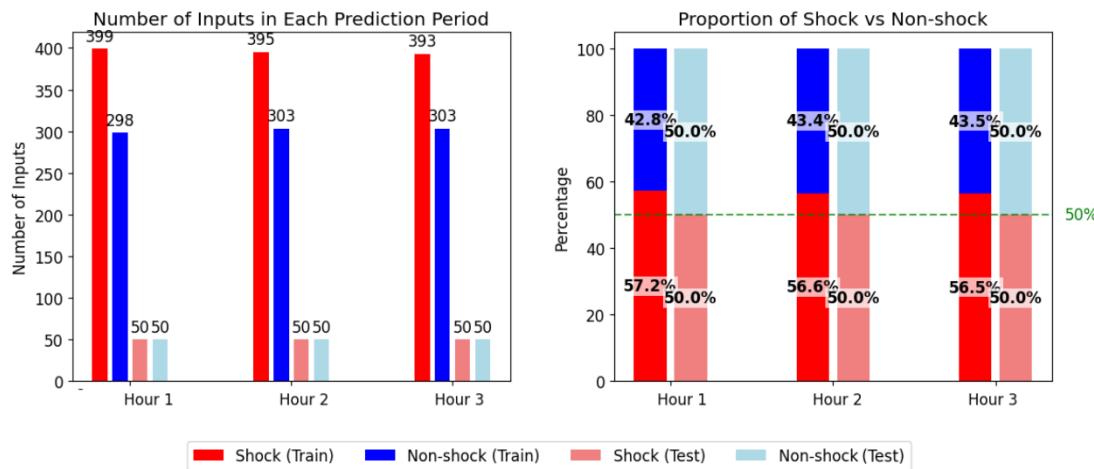
ดังนั้น การใช้วิธีสมมผานระหว่าง Linear Interpolation และ MissForest สามารถเติมค่าสูญหายในชุดข้อมูลได้อย่างมีประสิทธิภาพ โดยสามารถทำจำจัดค่าสูญหายทั้งหมดในทุกรดับความลະเอียดของข้อมูล ทั้งข้อมูลคงที่ ข้อมูลรายชั่วโมง และข้อมูลรายงานที่ วิธีการนี้มีความเหมาะสมเนื่องจากคำนึงถึงลักษณะของข้อมูลที่แตกต่างกัน โดยใช้ Linear Interpolation กับข้อมูลเชิงปริมาณที่มีความต่อเนื่องตามเวลา และใช้ MissForest กับข้อมูลที่มีลักษณะอื่นๆ ส่งผลให้ได้ชุดข้อมูลที่สมบูรณ์และพร้อมสำหรับการนำไปพัฒนาแบบจำลองอย่างเหมาะสม

#### 4.2.3 ผลการสร้างข้อมูลนำเข้า

เมื่อทำการสร้างข้อมูลนำเข้าเรียบร้อยแล้ว ได้จำนวนข้อมูลนำเข้าดัง ตารางที่ 4.6

ตารางที่ 4.7 จำนวนข้อมูลนำเข้าที่ถูกแบ่งตามประเภทชุดข้อมูลของแต่ละช่วงเวลาการทํางาน

ช่วงเวลาการทํางานล่วงหน้า (ชั่วโมง)	ประเภทชุดข้อมูล	มีภาวะช็อก (y=1)	ไม่มีภาวะช็อก (y=0)	จำนวนข้อมูลนำเข้าทั้งหมด
1	ชุดฝึกสอน	399 (57.25%)	298 (42.75%)	697 (100.00%)
	ชุดทดสอบ	15 (50.00%)	15 (50.00%)	30 (100.00%)
2	ชุดฝึกสอน	395 (56.59%)	303 (43.41%)	698 (100.00%)
	ชุดทดสอบ	15 (50.00%)	15 (50.00%)	30 (100.00%)
3	ชุดฝึกสอน	393 (56.47%)	303 (43.53%)	696 (100.00%)
	ชุดทดสอบ	15 (50.00%)	15 (50.00%)	30 (100.00%)



ภาพที่ 4.9 แผนภูมิแท่งแสดงการเปรียบเทียบจำนวนข้อมูลนำเข้าของผู้ป่วยในแต่ละช่วงเวลาการทำนายล่วงหน้า

จากการวิเคราะห์ผลของการสร้างข้อมูลนำเข้าสำหรับการทำนายภาวะซึ่กกล่วงหน้า พบว่าชุดข้อมูลฝึกสอนมีการกระจายที่มีความโน้มเอียงเล็กน้อยไปทางข้อมูลที่มีภาวะซึ่กกล โดยในการทำนายล่วงหน้า 1 ชั่วโมง มีข้อมูลภาวะซึ่ก 57.25% และไม่มีภาวะซึ่ก 42.75% จากข้อมูลนำเข้าทั้งหมด 697 รายการ สำหรับการทำนายล่วงหน้า 2 ชั่วโมง มีสัดส่วนภาวะซึ่ก 56.59% และไม่มีภาวะซึ่ก 43.41% จากข้อมูลนำเข้า 698 รายการ และในการทำนายล่วงหน้า 3 ชั่วโมง มีสัดส่วนภาวะซึ่ก 56.47% และไม่มีภาวะซึ่ก 43.53% จากข้อมูลนำเข้า 696 รายการ ในขณะที่ชุดข้อมูลทดสอบมีการกระจายที่สมดุลอย่างสมบูรณ์ที่ 50:50 ในทุกช่วงเวลาการทำนาย จากข้อมูลทดสอบทั้งหมด 30 รายการ

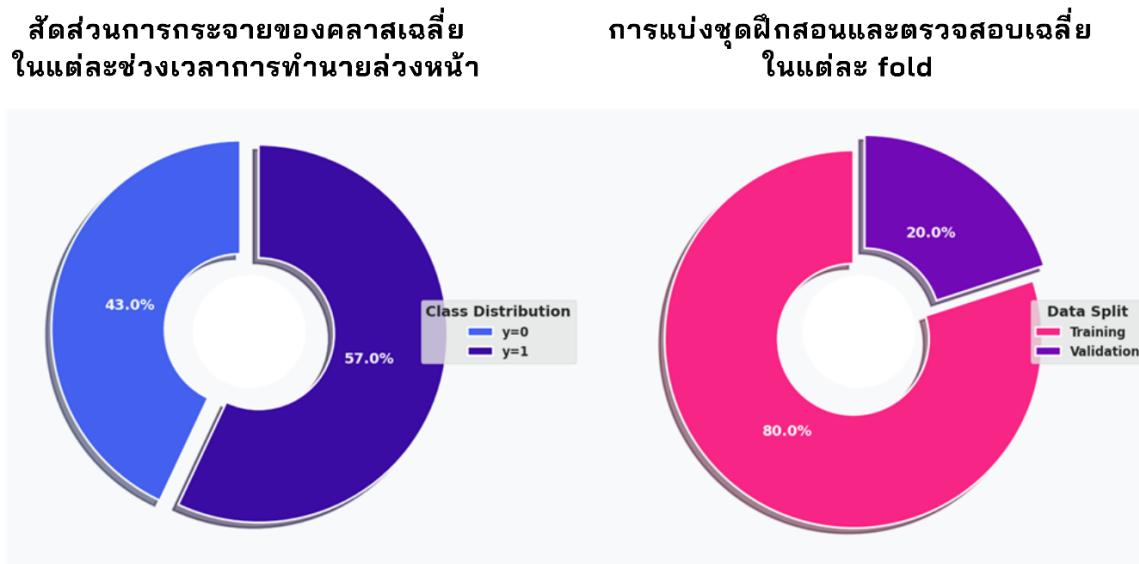
ถึงแม้ว่าข้อมูลฝึกสอนจะมีความไม่สมดุลระหว่างคลาส แต่ลักษณะการกระจายตัวนี้ถือว่าอยู่ในระดับที่ยอมรับได้และเป็นประโยชน์ต่อการพัฒนาแบบจำลอง เนื่องจากความต่างระหว่างคลาสไม่ได้สูงมากจนเกินไป ห่างกันเพียงประมาณ 14% ทำให้แบบจำลองสามารถเรียนรู้ลักษณะเฉพาะของแต่ละคลาสได้อย่างเพียงพอ นอกจากนี้ การมีสัดส่วนของข้อมูลภาวะซึ่กที่มากกว่าเล็กน้อยอาจเป็นข้อดีในบริบทของการแพทย์ที่ต้องการความไวสูงในการตรวจจับภาวะซึ่ก โดยสัดส่วนที่ค่อนข้างคงที่ในทุกช่วงเวลาการทำนายยังแสดงให้เห็นถึงความสม่ำเสมอของข้อมูลที่จะช่วยให้การเปรียบเทียบประสิทธิภาพของแบบจำลองระหว่างการทำนายในช่วงเวลาต่างๆ มีความน่าเชื่อถือมากขึ้น

### 4.3 ผลการสร้างแบบจำลอง

#### 4.3.1 ผลการแบ่งชุดข้อมูลด้วย Stratified Group 5-Fold Cross Validation

ตารางที่ 4.8 ผลการแบ่งข้อมูลชุดฝึกสอนและตรวจสอบในแต่ละช่วงเวลาการทำนายล่วงหน้าของการแบ่งข้อมูลแบบ Stratified Group 5-Fold Cross Validation

โฟลด์ (fold)	คลาส y (0 = ไม่ซื้อก, 1 = ซื้อก)	ช่วงเวลาการทำนายล่วงหน้า (ชั่วโมง)					
		1		2		3	
		ชุดฝึกสอน	ชุดตรวจสอบ	ชุดฝึกสอน	ชุดตรวจสอบ	ชุดฝึกสอน	ชุดตรวจสอบ
1	0	238	60	243	60	243	60
	1	319	80	316	79	314	79
2	0	238	60	243	60	243	60
	1	319	80	316	79	314	79
3	0	238	60	243	60	243	60
	1	320	79	316	79	314	79
4	0	239	59	243	60	243	60
	1	319	80	316	79	315	78
5	0	239	59	240	63	240	63
	1	319	80	316	79	315	78



ภาพที่ 4.10 สัดส่วนการกระจายของคลาสเฉลี่ยในแต่ละช่วงเวลาการท่านายล่วงหน้า และการแบ่งชุดฝึกสอนและตรวจสอบเฉลี่ยในแต่ละโฟลเดอร์

จากตารางที่ 4.8 และภาพที่ 4.10 พบร่วมกันว่าการกระจายตัวของคลาสมีสัดส่วนที่เหมาะสม โดยมีข้อมูลภาวะซื้อก (y=1) คิดเป็น 57.0% และไม่มีภาวะซื้อก (y=0) คิดเป็น 43.0% ซึ่งแม้จะมีความไม่สมดุลระหว่างคลาสอยู่บ้าง แต่ก็อยู่ในระดับที่ยอมรับได้และเป็นประโยชน์ต่อการฝึกแบบจำลอง สำหรับสัดส่วนการแบ่งข้อมูลระหว่างชุดฝึกสอนและชุดตรวจสอบเฉลี่ยในแต่ละโฟลเดอร์อยู่ที่ 80:20 นั้นเป็นไปตามมาตรฐานทั่วไปในการพัฒนาแบบจำลองทางการแพทย์ ซึ่งการใช้ Stratified Group 5-Fold Cross Validation ช่วยให้ทุกโฟลเดอร์มีการกระจายตัวของข้อมูลที่สม่ำเสมอทั้งในและของสัดส่วนระหว่างคลาสและช่วงเวลาการท่านายที่ 1, 2 และ 3 ช่วงโมงล่วงหน้า ซึ่งวิธีการแบ่งข้อมูลแบบนี้มีประสิทธิภาพในการป้องกันการรั่วไหลของข้อมูล (Data leakage) ด้วยการแบ่งข้อมูลแบบจัดกลุ่มตาม AdmissionId ทำให้ข้อมูลของผู้ป่วยรายเดียวเก็บถูกจัดอยู่ในกลุ่มเดียวกัน ไม่ว่าจะเป็นชุดฝึกสอนหรือชุดตรวจสอบ ซึ่งเป็นการรักษาความเป็นอิสระของข้อมูลและเพิ่มความน่าเชื่อถือในการประเมินประสิทธิภาพของแบบจำลอง

#### 4.3.2 ผลการหาค่าพารามิเตอร์ที่ดีที่สุดในแต่ละแบบจำลอง

การตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับแบบจำลอง ผู้วิจัยได้ปรับพารามิเตอร์ต่าง ๆ ตามความเหมาะสม ที่จะทำให้แบบจำลองมีประสิทธิภาพมากที่สุด โดยใช้ค่า AUC-ROC ในการวัดประสิทธิภาพแบบจำลอง

ตารางที่ 4.9 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN

แบบจำลอง	ขั้นของแบบจำลอง	ไฮเปอร์พารามิเตอร์	Activation Function
CNN	<b>Time-Series Branch</b>		
	1. Window_Input	input_shape=(num_windows, window_size, num_features)	-
	2. TimeDistributed(Conv1D)	filters = 64	ReLU
		kernel_size = 3	
		padding = "same"	
	3. TimeDistributed(BatchNormalization)	( default )	-
	4. TimeDistributed(MaxPooling1D)	pool_size = 2	-
	5. TimeDistributed(Flatten)		-
	6. GlobalAveragePooling1D		-
	<b>Static branch</b>		
	7. Static_Input (Static Branch)	input_shape=(static_dim,)	-
	8. Dense (static branch)	units = 64	ReLU
	9. BatchNormalization (static branch)		-
<b>Fully Connected Layers</b>			
10. Concatenate (Static Branch + Time-Series )			
11. Dense (combined)	units = 128	ReLU	
12. Dropout (final)	dropout_rate = 0.5	-	
13. Dense (output)	units = 1	Sigmoid	
	kernel_regularizer = l1(0.3)		

Epoch = 30, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

ตารางที่ 4.10 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ LSTM

แบบจำลอง	ขั้นของแบบจำลอง	Hyperparameter	Activation function
LSTM	<b>Time-series branch</b>		
	1. Window_Input (Input TimeSeries Data)	input_shape=(num_windows, window_size, num_features)	
	2. TimeDistributed(LSTM)	units = 32	tanh, Hard_sigmoid
		return_sequences = False	
		dropout = 0.2	
	3. TimeDistributed(BatchNormalization)	default	
	4. Reshape	shape = (num_windows, 32)	
	5. GlobalAveragePooling1D		
	<b>static branch</b>		
	6. Static_Input	input_shape = (static_dim,)	
	7. Dense (Static Branch)	units = 32	ReLU
	8. BatchNormalization (Static Branch)	default	
	<b>Fully Connected Layers</b>		
	9. Concatenate (Static Branch + Time-Series )		
	10. Dense	units = 128	ReLU
	11. BatchNormalization	default	
	12. Dense	units = 64	ReLU
	13. Dropout	dropout rate = 0.3	
	14. Dense (Output)	units = 1	Sigmoid
		kernel_regularizer = l1(L_REG = 0.3)	

Epoch = 30, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

ตารางที่ 4.11 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ Transformer

แบบจำลอง	ชื่นของแบบจำลอง	Hyperparameter	Activation function
Transformer	<b>Time-Series Branch</b>		
	1. Window_Input	input_shape=(num_windows, window_size, num_features)	
	2. TimeDistributed(Dense)	filter = 64	ReLU
	3. TimeDistributed(LayerNormalization)	default	
	4. Reshape	embedding_dim = window_size * 64	
	5. Add Positional Encoding	shape = (num_windows, window_size×64)	
	6. Transformer Encoder Stack	head_size = 64	
		num_heads = 8	
		ff_dim = 128	
		dropout = 0.5	
		num_layers = 4	
	7. Attention Pooling		
	Dense layer	units = 1	tanh
	Flatten		
	Activation softmax		softmax
	RepeatVector & Permute		
	Multiply and Lambda (reduce_sum) (embedding_dim)		
	<b>Static Branch</b>		
	8. Static_Input	input_shape = (static_dim,)	
	9. Dense	units = 64	ReLU
	<b>Fully Connected Layers</b>		
	10. Concatenate (Static Branch + Time-Series )		
	11. Dense	units = 128	ReLU
	12. BatchNormalization	default	
	13. Dense	units = 64	ReLU
	14. Dropout	dropout rate = 0.3	
	15. Dense (Output)	units = 1	
		kernel_regularizer = l1(L_REG = 0.3)	Sigmoid

Epoch = 30, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

ตารางที่ 4.12 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN + LSTM

แบบจำลอง	ขั้นของแบบจำลอง	Hyperparameter	Activation function
CNN + LSTM	<b>Time-Series Branch</b>		
	1. Window_Input	input_shape=(num_windows, window_size, num_features)	-
	2. TimeDistributed(Conv1D)	filters = 64	ReLU
		kernel_size = 3	
		padding = "same"	
	3. TimeDistributed(BatchNormalization)	default	-
	4. TimeDistributed(MaxPooling1D)	pool_size = 2	-
	5. TimeDistributed(Flatten)		-
	6. LSTM	units = 64	tanh
		return_sequences = False	
		dropout = 0.2	
	<b>Static Branch</b>		
	7. Static_Input	input_shape = (static_dim,)	-
	8. Dense (Static Branch)	units = 64	ReLU
	9. BatchNormalization (Static Branch)	default	-
	<b>Fully Connected Layers</b>		
	10. Concatenate (Static Branch + Time-Series )		-
	11. Dense (FC1)	units = 128	ReLU
	12. BatchNormalization (FC1)	default	-
	13. Dense (FC2)	units = 64	ReLU
	14. Dropout (FC2)	dropout rate = 0.3	-
	15. Dense (Output)	units = 1	Sigmoid
		kernel_regularizer = l1(L_REG = 0.3)	

Epoch = 30, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

ตารางที่ 4.13 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ CNN + Transformer

แบบจำลอง	ชื่นของแบบจำลอง	Hyperparameter	Activation function
CNN + Transformers	<b>Time-Series Branch</b>		
	1. Window_Input	input_shape=(num_windows, window_size, num_features)	-
	2. TimeDistributed(Conv1D)	filters = 64	ReLU
		kernel_size = 3	
		padding = "same"	
	3. TimeDistributed(BatchNormalization)	default	-
	4. TimeDistributed(MaxPooling1D)	pool_size = 2	-
	5. TimeDistributed(Flatten)		-
	6. MultiHeadAttention	num_heads = 8	-
		key_dim = 64	
	7. Residual Connection & LayerNormalization		-
	8. Dense	units = 128	ReLU
	9. Flatten		-
	<b>Static Branch</b>		
	10. Static_Input	input_shape = (static_dim,)	-
	11. Dense (Static Branch)	units = 64	ReLU
	12. BatchNormalization		-
	<b>Fully Connected Layers</b>		
	13. Concatenate (Static Branch + Time-Series )		-
	14. Dense	units = 128	ReLU
	15. BatchNormalization	default	-
	16. Dense	units = 64	ReLU
	17. Dropout	dropout rate = 0.3	-
	18. Dense (Output)	units = 1	Sigmoid
		kernel_regularizer = l1(L_REG = 0.3)	

Epoch = 20, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

ตารางที่ 4.14 แสดงผลการตั้งค่าพารามิเตอร์ที่ดีที่สุดสำหรับตัวแบบ LSTM + Transformer

แบบจำลอง	ขั้นของแบบจำลอง	Hyperparameter	Activation function
LSTM + Transformers	<b>Time-Series Branch</b>		
	1. Window_Input	input_shape=(num_windows, window_size, num_features)	–
	2. TimeDistributed(LSTM)	units = 32	tanh
		return_sequences = False	
		dropout = 0.2	
	3. TimeDistributed(BatchNormalization)	default	–
	4. Reshape		–
	5. MultiHeadAttention	num_heads = 8	–
		key_dim = 64	
	6. Residual Connection & LayerNormalization	default	–
	7. Dense (Transformer)	units = atten_unit (128)	ReLU
	8. Dropout (Transformer)	dropout rate = atten_dropout (0.3)	–
	9. GlobalAveragePooling1D		–
	<b>Static Branch</b>		
	10. Static_Input	input_shape = (static_dim,)	–
	11. Dense (Static Branch)	units = dense_static (64)	ReLU
	12. BatchNormalization		–
	<b>Fully Connected Layers</b>		
	13. Concatenate (Static Branch + Time-Series )		–
	14. Dense	units = dense_unit1 (128)	ReLU
	15. BatchNormalization	default	–
	16. Dense	units = dense_unit2 (64)	ReLU
	17. Dropout	dropout rate = dropout_full2 (0.3)	–
	18. Dense (Output)	units = 1	Sigmoid
		kernel_regularizer = l1(L_REG = 0.3)	

Epoch = 20, Batch size = 8, Learning rate = 0.001, Loss = Binary Cross-entropy, Optimizer = Adam

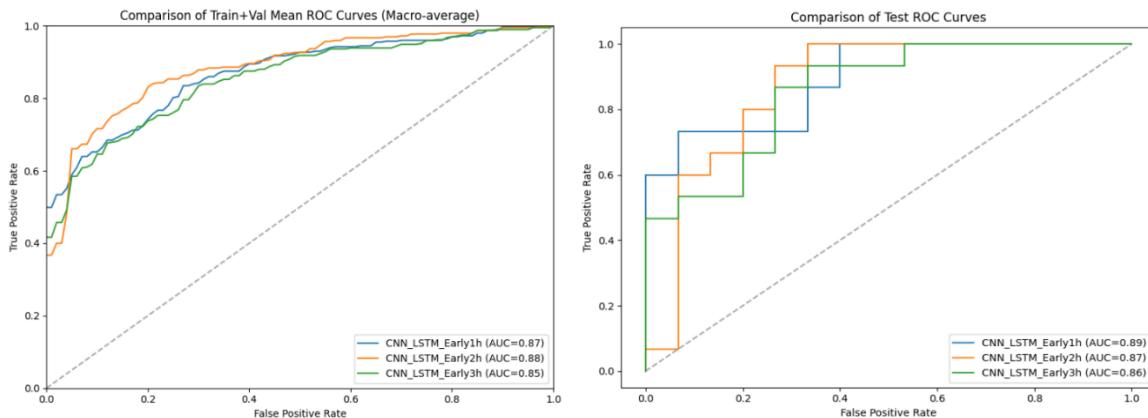
### 4.3.3 ผลการเปรียบเทียบประสิทธิภาพแบบจำลอง ทำนายการเกิดภาวะซื้อกของผู้ป่วยในแผนกผู้ป่วย วิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง

ตารางที่ 4.15 ผลการเปรียบเทียบประสิทธิภาพแบบจำลองทำนายการเกิดภาวะซื้อกของผู้ป่วยในแผนกผู้ป่วยวิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง

ทำนาย ล่วงหน้า (ชั่วโมง)	model	Accuracy		Precision		Recall		F1-score		AUC-ROC		AUC-PR	
		val	test	val	test	val	test	val	test	val	test	val	test
1	CNN	0.74	0.63	0.76	0.58	0.8	1.00	0.78	0.73	0.86	0.85	0.90	0.84
	LSTM	0.75	0.67	0.78	0.67	0.78	0.67	0.78	0.67	0.84	0.79	0.88	0.73
	Transformer	0.74	0.73	0.79	0.77	0.72	0.67	0.75	0.71	0.87	0.76	0.90	0.82
	CNN+LSTM	0.76	0.73	0.84	0.73	0.72	0.73	0.78	0.73	0.87	0.89	0.91	0.91
	CNN+Transformer	0.74	0.77	0.82	0.68	0.69	1.00	0.75	0.81	0.86	0.88	0.90	0.87
	LSTM+Transformer	0.74	0.77	0.84	0.7	0.67	0.93	0.75	0.80	0.84	0.80	0.89	0.76
2	CNN	0.79	0.8	0.87	0.71	0.73	1.00	0.79	0.83	0.86	0.84	0.89	0.85
	LSTM	0.77	0.8	0.86	0.76	0.71	0.87	0.78	0.81	0.86	0.86	0.89	0.79
	Transformer	0.76	0.73	0.77	1.00	0.81	0.47	0.79	0.64	0.86	0.68	0.89	0.77
	CNN+LSTM	0.8	0.8	0.83	0.74	0.81	0.93	0.82	0.82	0.88	0.87	0.91	0.80
	CNN+Transformer	0.77	0.77	0.77	0.72	0.84	0.87	0.80	0.79	0.85	0.79	0.89	0.75
	LSTM+Transformer	0.77	0.73	0.79	0.65	0.8	1.00	0.80	0.79	0.85	0.82	0.89	0.78
3	CNN	0.74	0.73	0.74	0.73	0.84	0.73	0.78	0.73	0.85	0.84	0.88	0.8
	LSTM	0.77	0.8	0.85	0.76	0.73	0.87	0.79	0.81	0.85	0.84	0.88	0.74
	Transformer	0.64	0.73	0.66	0.65	0.74	1.00	0.70	0.79	0.83	0.84	0.87	0.83
	CNN+LSTM	0.74	0.73	0.86	0.73	0.65	0.73	0.74	0.73	0.85	0.86	0.89	0.87
	CNN+Transformer	0.75	0.77	0.83	0.75	0.7	0.8	0.76	0.77	0.84	0.75	0.87	0.68
	LSTM+Transformer	0.74	0.73	0.76	0.65	0.8	1.00	0.78	0.79	0.84	0.84	0.89	0.82

จากตารางที่ 4.15 แสดงผลการเปรียบเทียบประสิทธิภาพแบบจำลองทำนายการเกิดภาวะซื้อกของผู้ป่วยในแผนกผู้ป่วยวิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง พบร่วมแบบจำลอง CNN+LSTM ให้ประสิทธิภาพดีที่สุดในทุกช่วงเวลา การทำนาย รองลงมาคือแบบจำลอง CNN ซึ่งให้ค่า AUC-ROC ในชุดทดสอบสูงถึง 0.85 ที่การทำนายล่วงหน้า 1 ชั่วโมง และมีค่า AUC-PR ที่ 0.84 นอกจากนี้ CNN ยังมีค่า Accuracy และ F1-score ที่ดีในชุดทดสอบที่การทำนายล่วงหน้า 2 ชั่วโมง (Accuracy = 0.80, F1-score = 0.83) แบบจำลอง LSTM มีประสิทธิภาพดีในการทำนายล่วงหน้า

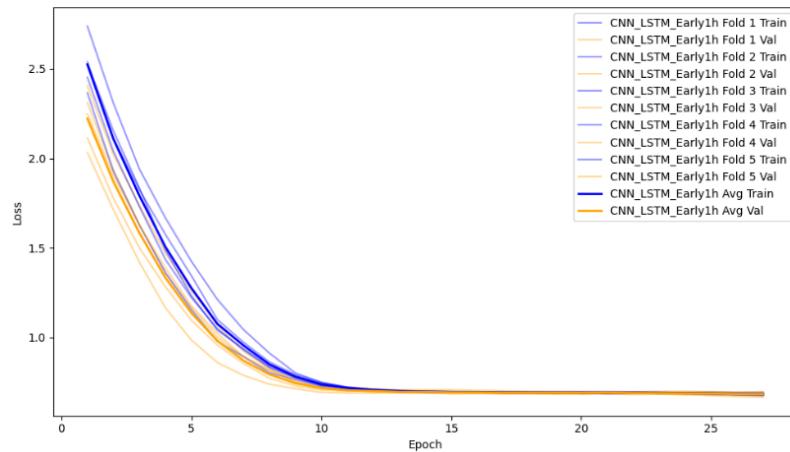
3 ชั่วโมง โดยมีค่า AUC-ROC = 0.84 และ F1-score = 0.81 แต่โดยรวมแล้วประสิทธิภาพยังต่ำกว่า CNN ในหลาย เมตริก ส่วนแบบจำลอง Transformer และแบบจำลองผสมอื่นๆ เช่น CNN+Transformer และ LSTM+Transformer มีประสิทธิภาพต่ำกว่าเมื่อเทียบกับ CNN+LSTM และ CNN โดยเฉพาะในชุดข้อมูลทดสอบ



ภาพที่ 4.11 ผลการวัดประสิทธิภาพแบบจำลอง CNN+LSTM ในแต่ละช่วงเวลา ด้วย AUC-ROC

เมื่อวิเคราะห์ประสิทธิภาพของแบบจำลอง CNN+LSTM ในแต่ละช่วงเวลาการทำนายดังภาพที่ 4.11 พบร่วมกัน การทำนายล่วงหน้า 1 ชั่วโมงให้ประสิทธิภาพโดยรวมดีที่สุด โดยเฉพาะค่า AUC-ROC ในชุดทดสอบที่ 0.89 ซึ่งสูงกว่า ช่วงเวลาอื่นและสูงกว่าทุกแบบจำลอง นอกจากนี้ในตารางที่ 4.16 ค่า AUC-PR ในช่วงการทำนายล่วงหน้า 1 ชั่วโมงยัง สูงถึง 0.91 แสดงถึงความสามารถของแบบจำลองในการระบุผู้ป่วยที่มีความเสี่ยงได้อย่างถูกต้องและการแจ้งเตือนที่ ผิดพลาด เมื่อระยะเวลาการทำนายเพิ่มขึ้นเป็น 2 ชั่วโมงและ 3 ชั่วโมง ประสิทธิภาพของแบบจำลองลดลงตามลำดับ ถึงแม้ว่าประสิทธิภาพจะลดลงเล็กน้อยเมื่อระยะเวลาการทำนายนานขึ้น แต่ค่า AUC-ROC ยังคงมากกว่า 0.85 ในทุก ช่วงเวลา แสดงถึงความสามารถในการระบุผู้ป่วยในช่วงการทำนาย 2 ชั่วโมง (AUC-ROC: 0.85, F1-score: 0.72, AUC-PR: 0.86) จะดีกว่าการทำนายล่วงหน้า 3 ชั่วโมง (AUC-ROC: 0.86, F1-score: 0.74, AUC-PR: 0.89) เล็กน้อย แสดงให้เห็นถึงความสามารถในการทำนายเหตุการณ์ล่วงหน้าที่ใกล้ออกไป เนื่องจากข้อมูลทางสรีริวิทยาอาจมีการเปลี่ยนแปลงได้อย่างรวดเร็วใน ผู้ป่วยวิกฤต

นอกจากนี้กราฟ Learning Curve ในภาพที่ 4.12 แสดงให้เห็นว่า Train loss ค่อยๆลดลงเมื่อแบบจำลองเรียนรู้มากขึ้น และ Validation loss ลดลงตาม Train loss แสดงให้เห็นว่าแบบจำลองมีความเหมาะสมกับข้อมูลที่ใช้ในการฝึกและทดสอบ

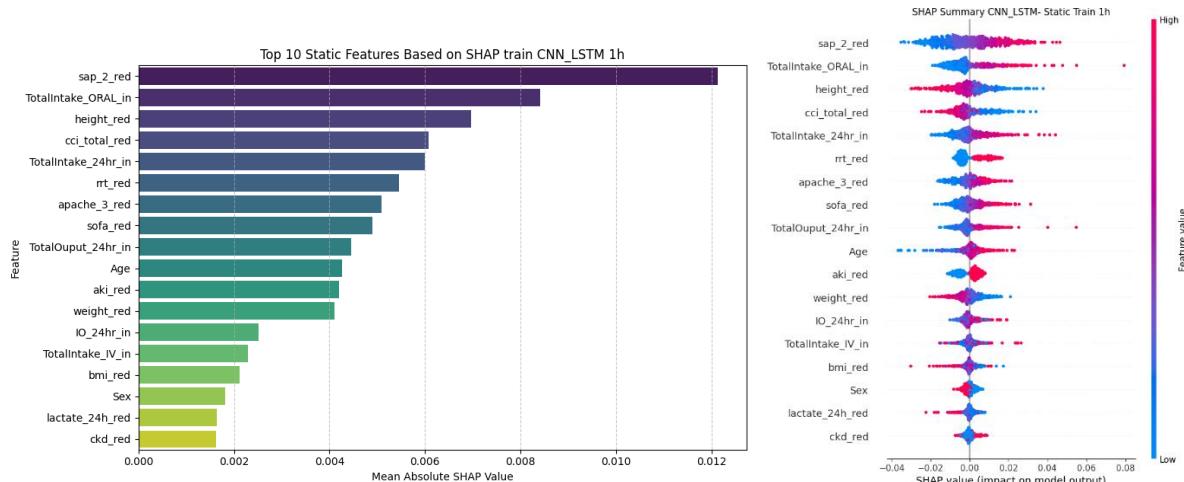


ภาพที่ 4.12 Learning Curve ของแบบจำลอง CNN+LSTM ในช่วงเวลาการทำงานล่วงหน้า 1 ชั่วโมง

#### 4.3.4 การทำความเข้าใจแบบจำลองโดยใช้เทคนิค SHAP

ผลการใช้ SHAP ในการอธิบายและตีความกับแบบจำลองที่มีประสิทธิภาพสูงที่สุดคือ CNN+LSTM ที่ช่วงเวลาการทำงานล่วงหน้า 1 ชั่วโมง เพื่ออธิบายว่าตัวแปรอิสระแต่ละตัวมีอิทธิพลต่อการตัดสินใจของตัวแบบอย่างไร โดยทดสอบกับตัวแปรคงที่ และตัวแปรพลวัต (ตัวแปรรายชั่วโมงและรายนาที)

##### 1.) SHAP Value ของตัวแปรคงที่ที่ส่งผลต่อการทำงานภาวะซื้อก

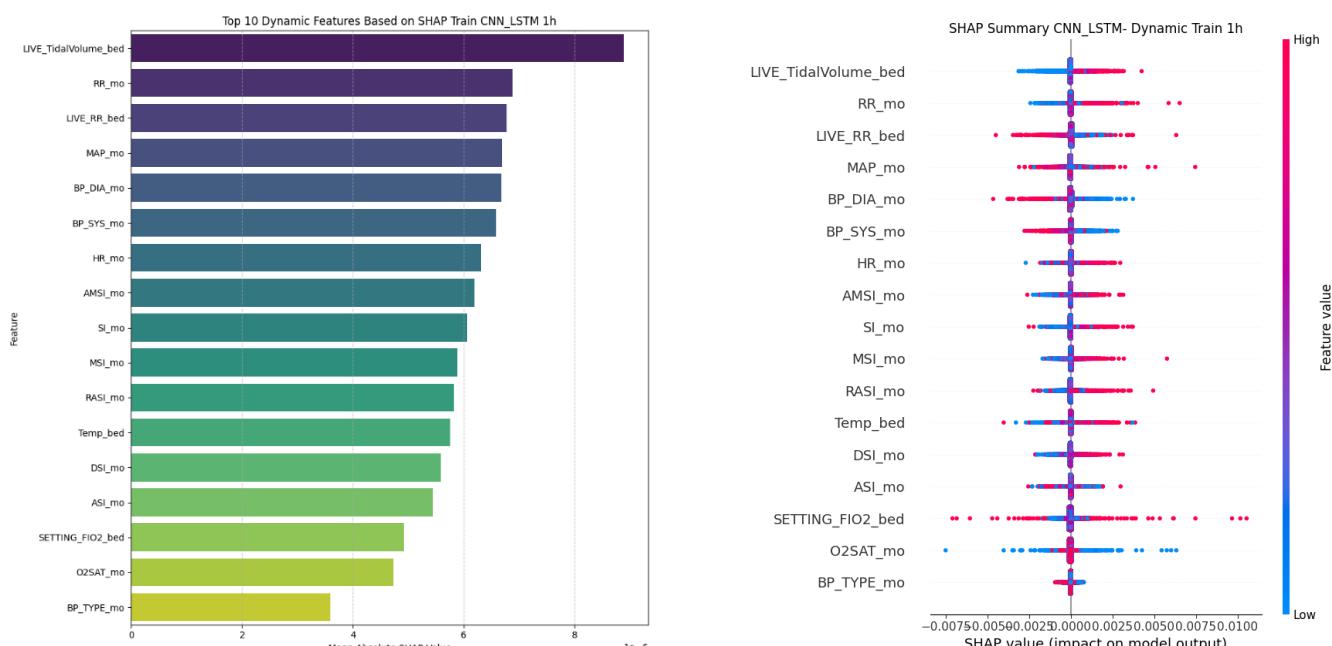


ภาพที่ 4.13 อิทธิพลของตัวแปรคงที่ที่มีผลต่อการทำงานภาวะซื้อก

จากภาพที่ 4.13 ทางขวาแสดงถึงอิทธิพลของตัวแปรคงที่ที่มีผลต่อการทำงานภาวะซื้อก ทางซ้ายแสดงลำดับความสำคัญของแต่ละตัวแปร เรียงจากค่าสูงไปต่ำ ดังนี้ SAP II, Total Intake ORAL, Height, CCI total, Total Intake 24hr, RRT, Apache III, SOFA, Total Output 24hr, Age, AKI, Weight, IO 24hr, Total Intake IV, BMI, Sex, Lactate 24h และ CKD และกราฟทางขวาแสดงความสัมพันธ์ระหว่างค่าของตัวแปรคงที่และผลการทำงานของ

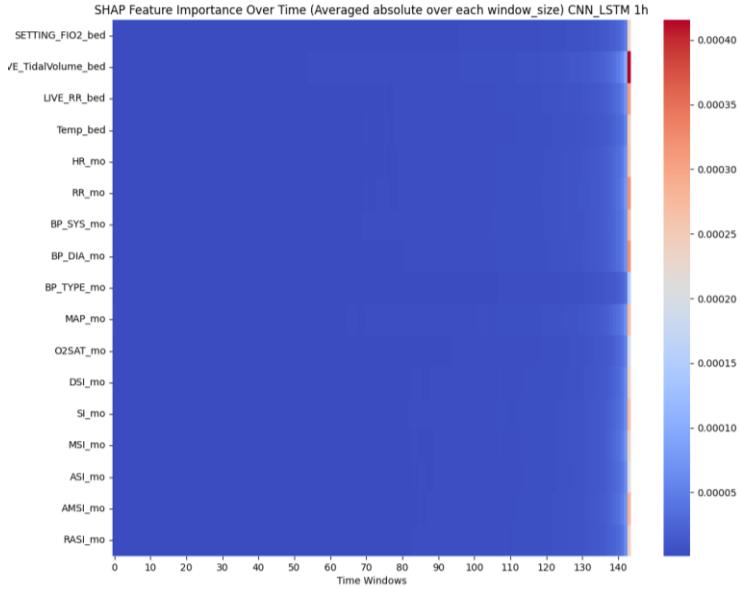
แบบจำลอง โดยค่าทำนายจากแบบจำลองพบว่าตัวแปรคงที่ที่เมื่อมีค่าสูงจะส่งผลกระทบทางบวกกับการทำนายภาวะช็อกได้แก่ Total Intake ORAL, Total Intake 24 hr, Apache III, SOFA, Total Output 24 hr, Age, IO 24 hr และ Total Intake IV และยังพบว่ามีตัวแปรคงที่เมื่อมีค่าน้อยจะส่งผลกระทบทางบวกในการทำนายภาวะช็อก ได้แก่ SAP II, Height, CCI total, RRT, AKI, Weight และ BMI เมื่อนำการอธิบายนี้ไปปรึกษาผู้เชี่ยวชาญพบว่า ความสัมพันธ์ดังกล่าวสนับสนุนโดยความเป็นจริงในทางการแพทย์

## 2.) SHAP Value ของตัวแปรผลวัดที่ส่งผลต่อการทำนายภาวะช็อก



ภาพที่ 4.14 อิทธิพลของตัวแปรผลวัดที่มีผลต่อการทำนายภาวะช็อก

จากการที่ 4.14 แสดงถึงอิทธิพลของตัวแปรผลวัดที่มีผลต่อการทำนายภาวะช็อก และลำดับความสำคัญของแต่ละตัวแปร เรียงจากค่าสูงไปต่ำ ดังนี้ LIVE Tidal Volume, RR, LIVE RR, MAP, BP DIA, BP SYS, HR, AMSI, SI, MSI, RASI, Temp, DSI, ASI, SETTING FIO2, O2SAT และ BP TYPE และกราฟทางขวาแสดงความสัมพันธ์ระหว่างค่าของตัวแปรผลวัดและผลการทำนายของแบบจำลอง โดยค่าทำนายจากแบบจำลองพบว่าตัวแปรผลวัดที่เมื่อมีค่าสูงจะส่งผลกระทบทางบวกกับการทำนายภาวะช็อก ได้แก่ LIVE Tidal Volume, RR, HR, AMSI, SI, MSI, RASI, Temp, DSI และ SETTING FIO2 และยังพบว่ามีตัวแปรผลวัดเมื่อมีค่าน้อยจะส่งผลกระทบทางบวกในการทำนายภาวะช็อก ได้แก่ LIVE RR, MAP, BP DIA, BP SYS, ASI และ O2SAT



ภาพที่ 4.15 Heatmap แสดงอิทธิพลของตัวแปรผลวัตที่มีต่อการทำนายภาวะซื้อกินแต่ละ Time windows

หากพิจารณาจากภาพที่ 4.15 Heatmap แสดงอิทธิพลของตัวแปรผลวัตที่มีต่อการทำนายภาวะซื้อกินแต่ละ Time windows โดยเฉพาะในตัวแปรปริมาตรอากาศที่เคลื่อนที่เข้าออกปอด LIVE Tidal Volume และความเข้มข้นของออกซิเจน SETTING FIO2 ที่มีความสำคัญสูงที่สุดในช่วงเวลาใกล้กับการเกิดภาวะซื้อกิน ซึ่งแสดงให้เห็นเป็นจุดสีแดงในช่วง time windows ที่ 140 ขณะที่ตัวแปรอื่นๆ เช่น อัตราการหายใจ (LIVE RR), อัตราการเต้นของหัวใจ HR และความดันโลหิตต่างๆ (BP SYS, BP DIA, MAP) แสดงความสำคัญในระดับต่ำกว่า

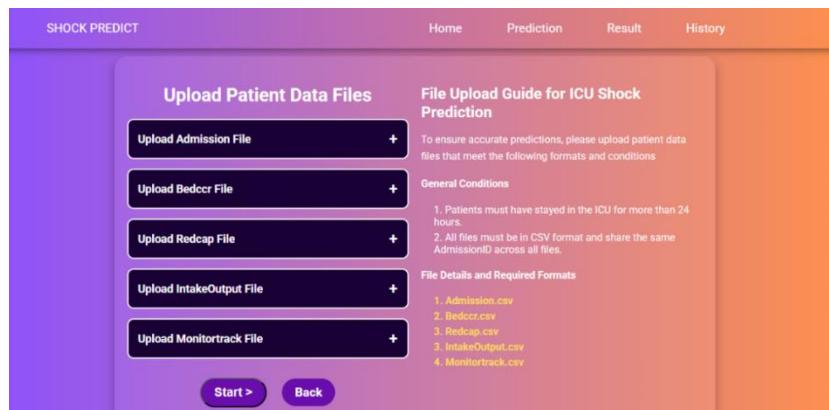
ลักษณะของ Heatmap นี้แสดงให้เห็นว่าอิทธิพลของตัวแปรส่วนใหญ่มีความเข้มข้นมากขึ้นในช่วงเวลาสุดท้าย ซึ่งสอดคล้องกับหลักการทำงานการแพทย์ที่ว่าสัญญาณการเปลี่ยนแปลงทางสรีรวิทยามักจะชัดเจนมากขึ้นเมื่อใกล้เวลาที่จะเกิดภาวะซื้อก และเมื่อนำการอธิบายนี้ไปปรึกษาผู้เชี่ยวชาญพบว่า ความสัมพันธ์ดังกล่าววนนั้นสอดคล้องกับความเป็นจริงในทางการแพทย์

#### 4.4 ผลการพัฒนาเว็บแอปพลิเคชัน

ผลการพัฒนาเว็บแอปพลิเคชันสำหรับการทำนายภาวะซื้อกินแผนกผู้ป่วยวิกฤต มีหน้าต่างแสดงดังภาพที่ 4.15 หน้าหลักของเว็บแอปพลิเคชัน, 4.16 หน้าต่างเว็บแอปพลิเคชันสำหรับอัปโหลดไฟล์ข้อมูลผู้ป่วยที่ต้องการทำนาย, 4.17 หน้าต่างเว็บแอปพลิเคชันหน้าผลลัพธ์การทำนาย, 4.18 หน้าต่างเว็บแอปพลิเคชันหน้าประวัติการทำนาย และ 4.19 QR code สำหรับเว็บแอปพลิเคชัน



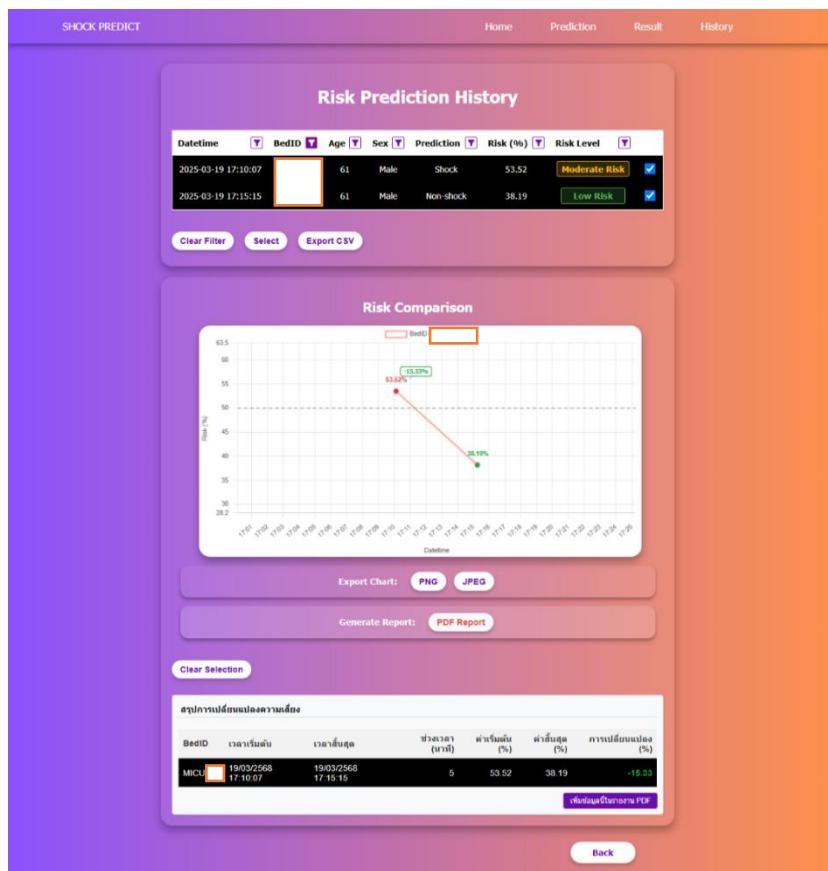
ภาพที่ 4.16 หน้าหลักของเว็บแอปพลิเคชัน



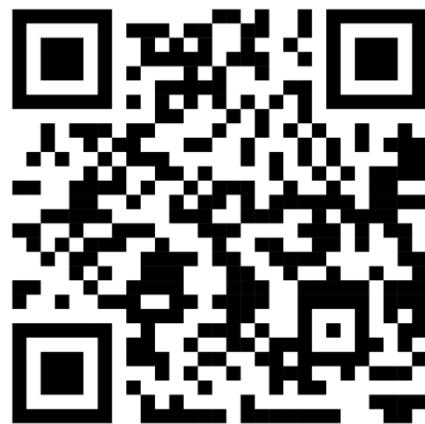
ภาพที่ 4.17 หน้าต่างเว็บแอปพลิเคชันสำหรับอัปโหลดไฟล์ข้อมูลผู้ป่วยที่ต้องการทำนาย

Datetime	BedID	Age	Sex	Prediction	Risk (%)
2025-03-19 17:10:07		80	Female	Shock	59.11
2025-03-19 17:10:07		20	Female	Shock	53.52
2025-03-19 17:10:07		78	Male	Shock	71.33
2025-03-19 17:10:07		72	Male	Shock	67.46
2025-03-19 17:10:07		57	Female	Shock	53.52
2025-03-19 17:10:07		74	Female	Shock	54.87
2025-03-19 17:10:07		67	Female	Shock	53.52
2025-03-19 17:10:07		87	Female	Shock	57.03
2025-03-19 17:10:07		34	Female	Shock	61.41

ภาพที่ 4.18 หน้าต่างเว็บแอปพลิเคชันหน้าผลลัพธ์การทำนาย



ภาพที่ 4.19 หน้าต่างเว็บแอปพลิเคชันหน้าประวัติการทำนาย



ภาพที่ 4.20 QR code สำหรับเว็บแอปพลิเคชัน

## บทที่ 5

### สรุปผลการวิจัย

งานวิจัย เรื่องการพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนายภาวะซื้อกินแผนกผู้ป่วย วิกฤตโรงพยาบาลศринครินทร์ จังหวัดขอนแก่น มีวัตถุประสงค์เพื่อวิเคราะห์ตัวแปรที่ส่งผลต่อการเกิดภาวะซื้อกินของผู้ป่วยใน ICU เพื่อสร้างแบบจำลองสำหรับการทำนายภาวะซื้อกินของผู้ป่วยใน ICU ล่วงหน้า 1,2 และ 3 ชั่วโมงก่อนเกิดภาวะซื้อกิน ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลาจากข้อมูลผู้ป่วยในระบบ Smart-ICU ของโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ได้ดำเนินการพัฒนาแบบจำลองการทำนายภาวะซื้อกิน ในแผนกผู้ป่วยวิกฤตจากการวิจัยสามารถสรุปผลได้ดังนี้

#### 5.1 สรุปผลการวิจัย

การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลา เพื่อทำนายภาวะซื้อกินแผนกผู้ป่วยวิกฤต โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ใช้ข้อมูลทุติยภูมิจากระบบฐานข้อมูล Smart-ICU ตั้งแต่วันที่ 15 ตุลาคม 2565 – 3 กุมภาพันธ์ 2568 โดยคัดเลือกผู้ป่วยที่มีอายุมากกว่า 18 ปี และมีระยะเวลาอยู่ในแผนกผู้ป่วยวิกฤตไม่ต่ำกว่า 24 ชั่วโมง ประกอบด้วยข้อมูลจำนวน 5 ชนิด ได้แก่ ข้อมูลผู้ป่วย ข้อมูลประวัติการรักษา ข้อมูลบันทึกสมุดสารน้ำ ข้อมูลผลกระทบทางห้องปฏิบัติการ และข้อมูลบันทึกสัญญาณชีพ รวมทั้งสิ้น 35 ตัวแปร ซึ่งรวมเป็นข้อมูลคงที่ และข้อมูลแบบพลวัต (ข้อมูลรายชั่วโมง และรายนาที) จากนั้นแบ่งข้อมูลเป็นชุดฝึกสอนและตรวจสอบกับชุดทดสอบ ในอัตราส่วน 94:6 โดยมีจำนวนผู้ป่วยในการทำนายภาวะซื้อกินล่วงหน้า 1, 2 และ 3 ชั่วโมง จำนวน 530, 527 และ 525 ราย ตามลำดับ ก่อนนำมาสร้างข้อมูลนำเข้าจำนวน 697, 698 และ 696 ข้อมูลนำเข้า ตามลำดับ ด้วยเทคนิค Sliding window ทำให้ได้ข้อมูลนำเข้าที่มีความสมดุลระหว่างคลาสในสัดส่วนที่เหมาะสม

ผลการเปรียบเทียบประสิทธิภาพแบบจำลองทำนายการเกิดภาวะซื้อกินของผู้ป่วยในแผนกผู้ป่วยวิกฤต ล่วงหน้า 1, 2 และ 3 ชั่วโมง พบร่วมแบบจำลอง CNN+LSTM ให้ประสิทธิภาพดีที่สุดในทุกช่วงเวลาการทำนาย โดยในการทำนายล่วงหน้า 1 ชั่วโมง มีค่า AUC-ROC ในชุดข้อมูลทดสอบที่ 0.890 ค่า AUC-PR ที่ 0.91 และค่า F1-score ที่ 0.78 ซึ่งสูงกว่าแบบจำลองอื่นๆ การทำนายล่วงหน้า 2 ชั่วโมง มีค่า AUC-ROC ที่ 0.85 ค่า AUC-PR ที่ 0.85 และค่า F1-score ที่ 0.72 และการทำนายล่วงหน้า 3 ชั่วโมง มีค่า AUC-ROC ที่ 0.86 ค่า AUC-PR ที่ 0.87 และค่า F1-score ที่ 0.76 โดยประสิทธิภาพโดยรวมของการทำนายล่วงหน้า 1 ชั่วโมงดีที่สุด รองลงมาคือแบบจำลอง CNN ซึ่งให้ค่า AUC-ROC ในชุดทดสอบสูงถึง 0.85 ที่การทำนายล่วงหน้า 1 ชั่วโมง และมีค่า AUC-PR ที่ 0.84 นอกจากนี้ CNN ยังมีค่า Accuracy และ F1-score ที่ดีในชุดทดสอบที่การทำนายล่วงหน้า 2 ชั่วโมง ( $\text{Accuracy} = 0.80$ ,  $\text{F1-score} = 0.72$ ) และการทำนายล่วงหน้า 3 ชั่วโมง ( $\text{Accuracy} = 0.76$ ,  $\text{F1-score} = 0.70$ )

0.83) แบบจำลอง LSTM มีประสิทธิภาพดีในการทำนายล่วงหน้า 3 ชั่วโมง โดยมีค่า AUC-ROC = 0.84 และ F1-score = 0.81 แต่โดยรวมแล้วประสิทธิภาพยังต่ำกว่า CNN ในหลายเมตริก ส่วนแบบจำลอง Transformer และแบบจำลองผสมอื่นๆ เช่น CNN+Transformer และ LSTM+Transformer มีประสิทธิภาพต่ำกว่าเมื่อเทียบกับ CNN+LSTM และ CNN โดยเฉพาะในชุดข้อมูลทดสอบ

การใช้เทคนิค SHAP เพื่ออธิบายแบบจำลอง CNN+LSTM ที่ช่วงเวลาการทำนายล่วงหน้า 1 ชั่วโมงพบว่า ตัวแปรคงที่ที่มีความสำคัญสูงสุด 5 อันดับแรกได้แก่ SAP II, Total Intake ORAL, Height, CCI total และ Total Intake 24hr ส่วนตัวแปรผลวัดที่มีความสำคัญสูงสุด 5 อันดับแรกได้แก่ LIVE Tidal Volume, RR, LIVE RR, MAP และ BP DIA ความสัมพันธ์ของตัวแปรกับการทำนายภาวะซื้อกพรบว่า ตัวแปรคงที่ที่มีค่าสูงและส่งผลกระทบบวกต่อการทำนายภาวะซื้อกพรบ ได้แก่ Total Intake ORAL, Total Intake 24hr, Apache III และ SOFA ซึ่งตัวแปรเหล่านี้เกี่ยวข้องกับภาวะซื้อกพรบมากกว่าตัวแปรคงที่ที่มีค่าสูงกว่าชัดเจนในระดับนัยสำคัญทางสถิติ ( $p < 0.05$ ) โดยเฉพาะในตัวแปร SOFA และ Apache III สะท้อนความรุนแรงของโรคและความเสี่ยงต่อการเสียชีวิตที่สูงกว่า ส่วนตัวแปรผลวัดที่มีค่าสูงและส่งผลกระทบบวกต่อการทำนายภาวะซื้อกพรบ ได้แก่ LIVE Tidal Volume, RR, HR และดัชนีซื้อกประกันภัยต่างๆ เช่น AMSI, SI และ MSI ในขณะที่ตัวแปรผลวัดที่มีค่าน้อยและส่งผลกระทบบวกต่อการทำนายภาวะซื้อกพรบ ได้แก่ MAP, BP DIA และ BP SYS ซึ่งผลลัพธ์ความสัมพันธ์เหล่านี้สอดคล้องกับความเป็นจริงในทางการแพทย์ตามการยืนยันจากผู้เชี่ยวชาญ

## 5.2 อภิปรายผลการวิจัย

งานวิจัยนี้ได้พัฒนาแบบจำลองสำหรับการทำนายภาวะซื้อกพรบของผู้ป่วยใน ICU ล่วงหน้า 1, 2 และ 3 ชั่วโมง ด้วยเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา พบว่าแบบจำลอง CNN+LSTM ให้ประสิทธิภาพดีที่สุดในทุกช่วงเวลา การทำนาย โดยเฉพาะในการทำนายล่วงหน้า 1 ชั่วโมง ซึ่งมีค่า AUC-ROC 0.89 และค่า AUC-PR 0.91 สูงกว่าแบบจำลองอื่นๆ อย่างมีนัยสำคัญ โดยประสิทธิภาพที่โดดเด่นของแบบจำลอง CNN+LSTM สอดคล้องกับงานวิจัยของ Lin et al. (2018) ที่พบว่าการผสมผสานแบบจำลอง CNN และ LSTM เข้าด้วยกันสามารถทำนายภาวะซื้อกพรบ ติดเชื้อได้ดีที่สุด โดยมีค่า AUC-ROC 94.08% และ F1 score 85.79% ที่ 4.5 ชั่วโมงก่อนการเกิดภาวะซื้อกพรบ ซึ่งแบบจำลองดังกล่าวสามารถเรียนรู้ทั้งลักษณะเฉพาะเชิงพื้นที่ (Spatial Features) จาก CNN และความสัมพันธ์เชิงลำดับ (Sequential Patterns) จาก LSTM ได้พร้อมกัน ทำให้มีความสามารถในการจับความซับซ้อนของข้อมูลอนุกรมเวลาทางการแพทย์ได้ดียิ่งขึ้น ในขณะที่ผลการวิจัยของ Tang et al. (2024) แสดงให้เห็นว่าแบบจำลอง LSTM+Transformer ให้ประสิทธิภาพดีที่สุดในการทำนายการเกิดภาวะติดเชื้อในกระแสเลือดระยะแรก ด้วยค่า AUC-ROC 0.99 และ Accuracy 96.4% ที่ 4 ชั่วโมงก่อนการเกิดภาวะซื้อกพรบ แต่ในงานวิจัยนี้พบว่าแบบจำลอง LSTM+Transformer ให้ประสิทธิภาพต่ำกว่า CNN+LSTM โดยมีค่า AUC-ROC 0.80 และ F1-score 0.80 ในการ

ทำนายล่วงหน้า 1 ชั่วโมง ความแตกต่างนี้อาจเกิดจากลักษณะเฉพาะของข้อมูลและความแตกต่างของการเกิดภาวะซื้อกับการเกิดภาวะติดเชื้อในกระแสเลือด ซึ่งมีกลไกทางพยาธิสรีริวิทยาที่แตกต่างกัน

นอกจากนี้ งานวิจัยของ Luo et al. (2023) ที่พัฒนาแบบจำลอง Pre-trained Triplet-loss Time-aware Transformer (PT3) สำหรับการทำนายความเสี่ยงในการเสียชีวิตของผู้ป่วยติดเชื้อในกระแสเลือด ให้ค่า AUC-ROC 0.9067 บนชุดข้อมูลจาก MIMIC-IV แม้ว่าแบบจำลอง Transformer จะมีประสิทธิภาพดีในงานวิจัยของ Luo แต่ในงานวิจัยนี้พบว่าแบบจำลอง Transformer เดี่ยว มีประสิทธิภาพต่ำกว่าแบบจำลองผสม CNN+LSTM อย่างมีนัยสำคัญ อาจเนื่องมาจากการที่ Transformer ต้องการข้อมูลฝึกสอนในปริมาณมากหรือข้อมูลที่ผ่านการ Pre-training ในข้อมูลขนาดใหญ่เพื่อให้สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนได้อย่างมีประสิทธิภาพ เมื่อพิจารณาผลการทำนายในแต่ละช่วงเวลา พบร่วมกับประสิทธิภาพของแบบจำลอง CNN+LSTM มีแนวโน้มลดลงเล็กน้อยเมื่อระยะเวลาทำนายนานขึ้นเป็น 2 และ 3 ชั่วโมง แต่ค่า AUC-ROC ยังคงมากกว่า 0.85 ในทุกช่วงเวลา ซึ่งสอดคล้องกับงานวิจัยของ Lin et al. (2018) และงานวิจัยของ Luo et al. (2023) ที่พบว่าประสิทธิภาพของแบบจำลองจะลดลงตามระยะเวลาที่ห่างจากจุดเกิดภาวะซื้อก แต่ยังคงมีประสิทธิภาพที่ดีในการทำนายล่วงหน้า 24 ชั่วโมง นั่นแสดงให้เห็นว่าแบบจำลอง CNN+LSTM มีความเสถียรและความแม่นยำสูงในการทำนายภาวะซื้อกล่วงหน้าแม้ในระยะเวลาที่ยาวนานขึ้น

ในด้านของผลการวิเคราะห์ SHAP พบร่วมกับตัวแปรที่มีอิทธิพลสูงต่อการทำนายภาวะซื้อกได้แก่ SAP II, Total Intake ORAL, Height, CCI total สำหรับตัวแปรคงที่ และ LIVE Tidal Volume, RR, LIVE RR, MAP สำหรับตัวแปรพลวัต ซึ่งสอดคล้องกับงานวิจัยของ Tang et al. (2024) ที่พบว่าอัตราการเต้นของหัวใจ, อัตราการหายใจ, ความอิ่มตัวของออกซิเจนในเลือด และค่า MAP เป็นปัจจัยสำคัญในการทำนายภาวะติดเชื้อในกระแสเลือด ความสามารถของแบบจำลองผสม CNN+LSTM ในการประมวลผลข้อมูลหลายมิติและหลายระดับเวลาพร้อมกัน เป็นจุดเด่นที่ทำให้แบบจำลองนี้สามารถจับรูปแบบที่ซับซ้อนและเปลี่ยนแปลงตามเวลาของข้อมูลสัญญาณชีพในผู้ป่วย ICU ได้ดีกว่าแบบจำลองอื่นๆ CNN สามารถสกัดคุณลักษณะสำคัญในแต่ละช่วงเวลาอย่าง (Time Window) ในขณะที่ LSTM สามารถเข้ามายังคุณลักษณะเหล่านั้นตามลำดับเวลาเพื่อหารูปแบบที่บ่งชี้ถึงแนวโน้มการเกิดภาวะซื้อกในอนาคต การที่แบบจำลอง CNN+LSTM มีค่า Recall สูงถึง 0.93 ในการทำนายล่วงหน้า 2 ชั่วโมง แสดงให้เห็นถึงความสามารถในการตรวจจับผู้ป่วยที่มีความเสี่ยงต่อการเกิดภาวะซื้อกได้เกือบทั้งหมด ซึ่งมีความสำคัญอย่างยิ่งในทางการแพทย์ เนื่องจากหากไม่สามารถตรวจจับผู้ป่วยที่มีภาวะซื้อกได้ทันเวลา อาจนำไปสู่ภาวะแทรกซ้อนที่รุนแรงและการเสียชีวิตได้ ดังที่ Kumar et al. (2006) ได้รายงานว่าทุกๆ ชั่วโมงที่ล่าช้าในการให้ยาปฏิชีวนะในช่วง 6 ชั่วโมงแรกของการเกิดภาวะซื้อกจากการติดเชื้อ จะเพิ่มความเสี่ยงต่อการเสียชีวิตถึง 7.6% ต่อชั่วโมง

นอกจากนี้ การเปรียบเทียบตัวแปรระหว่างผู้ป่วยที่มีภาวะช็อกและไม่มีภาวะช็อก พบรความแตกต่างอย่างมีนัยสำคัญในหลายตัวแปร โดยเฉพาะค่า SAP II, Apache III, SOFA, Lactate และตัวแปรเกี่ยวกับสมดุลสารน้ำ (IO 24hr, Total Intake 24hr) สอดคล้องกับงานวิจัยของ Sakr et al. (2018) ที่พบว่าผู้ป่วยที่มีภาวะช็อกมักมีค่าแนวการประเมินความรุนแรงของโรคที่สูงกว่า และมีความผิดปกติในการทำงานของอวัยวะหลายระบบมากกว่าผู้ป่วยที่ไม่มีภาวะช็อก ดังนั้นแบบจำลอง CNN+LSTM ที่พัฒนาขึ้นในงานวิจัยนี้แสดงให้เห็นถึงประสิทธิภาพที่ดีกว่าแบบจำลองอื่นๆ ในการทำนายภาวะช็อกล่วงหน้า โดยเฉพาะอย่างยิ่งในช่วงเวลา 1 ชั่วโมงก่อนเกิดภาวะช็อก ซึ่งมีความสำคัญอย่างมากในการช่วยให้บุคลากรทางการแพทย์สามารถวางแผนการรักษาและป้องกันได้อย่างทันท่วงที ลดความเสี่ยงต่อการเกิดภาวะแทรกซ้อนและการเสียชีวิตของผู้ป่วยในหอผู้ป่วยวิกฤตให้อย่างมีประสิทธิภาพ

### 5.3 ประโยชน์ของสถิติหรือสารสนเทศสถิติที่ใช้ในการวิจัย

5.3.1 ได้ความรู้ที่ได้จากวิชา Data Preparation and Data Mining ที่เป็นการใช้ความรู้พื้นฐานในการเตรียมข้อมูล ทำเหมือนข้อมูล เพื่อใช้ในการรวบรวมข้อมูล การทำความสะอาดข้อมูล ไปจนถึงการใช้ความรู้พื้นฐานในการพัฒนาแบบจำลอง นำไปพัฒนาแบบจำลองที่มีความซับซ้อนมากขึ้น

5.3.2 ได้ความรู้ทางสถิติที่ได้จากการวิชา Statistical Analysis I และ Statistical Analysis II ในการทดสอบเปรียบเทียบค่ามัธยฐานของตัวแปรคงที่ เพื่อความแตกต่างระหว่างกลุ่มที่มีภาวะช็อกและไม่มีภาวะช็อก ว่ามีความต่างกันระดับนัยสำคัญหรือไม่

5.3.3 ได้ความรู้ในรายวิชา Prototyping for Artificial Intelligence and Machine Learning System นำมาใช้พัฒนาในส่วนของ Front-end และ Back-end โดยใช้ภาษา HTML, CSS, JavaScript รวมถึง Python Flask ในการพัฒนาการนำไปใช้ของแบบจำลอง

### 5.4 ข้อเสนอแนะ

#### 5.4.1 ข้อเสนอแนะจากการนำผลการวิจัยไปใช้

พัฒนาแบบจำลองให้สามารถประมวลผลข้อมูลและทำนายความเสี่ยงแบบเรียลไทม์ โดยการออกแบบระบบที่สามารถดึงข้อมูลจากเครื่องติดตามสัญญาณชีพและประมวลผลอัตโนมัติ

#### 5.4.2 ข้อเสนอแนะในทำงานวิจัยครั้งต่อไป

- ทำการเลือกตัวแปรที่สำคัญและมีผลกระทบโดยตรงต่อการเกิดภาวะช็อกโดยเลือกจากผล Shap และทดสอบว่าแบบจำลองที่มีตัวแปรน้อยลงยังคงสามารถให้ผลลัพธ์ที่มีประสิทธิภาพใกล้เคียงกับแบบจำลองที่ใช้ตัวแปรมากกว่าได้หรือไม่

2. ทำการทดลองกับข้อมูลที่มีระยะเวลาอย่างกว่า 24 ชั่วโมง เพื่อให้ได้ผลลัพธ์ที่ตรงกับลักษณะของข้อมูลจริง ในสถานการณ์ฉุกเฉิน โดยการทดลองใช้ข้อมูลที่มีระยะเวลาไม่เกิน 24 ชั่วโมงจะช่วยให้แบบจำลองสามารถตอบสนอง และทำนายได้ทันท่วงที

เอกสารอ้างอิง

ชิตพงษ์ กิตตินราดร. (2563). Convolutional Neural Network. ค้นเมื่อ 12 กันยายน 2567, จาก <https://guopai.github.io/ml-blog19.html>

พัชนา สุวรรณเสน. (2562). การจัดการข้อมูลสัญญาณ: วิธีเครเนียร์เรสนเนเบอร์. วารสารวิทยาศาสตร์ และเทคโนโลยีมหาวิทยาลัยราชภัฏนครราชสีมา, 4(1), 1-12. <https://scientechn.nrru.ac.th/journal/images/file/1-62/1.pdf>

สันทัด พรประเสริฐมานิต. (2562). การจัดการข้อมูลสูญหาย (Missing Data Handling). ค้นเมื่อ 30 กันยายน 2567, จาก [https://www.sunthud.com/media/Teaching/MLM/Fall19/Lecture10\\_MissingData.pdf](https://www.sunthud.com/media/Teaching/MLM/Fall19/Lecture10_MissingData.pdf)

Asfar, P., Meziani, F., Hamel, J. F., Grelon, F., Megarbane, B., Anguel, N., Mira, J. P., Dequin, P. F., Gergaud, S., Weiss, N., Legay, F., Le Tulzo, Y., Conrad, M., Robert, R., Gonzalez, F., Guitton, C., Tamion, F., Tonnelier, J. M., Guezenne, P., Van Der Linden, T., ... SEPSISPAM Investigators. (2014). **High versus low blood-pressure target in patients with septic shock**. The New England Journal of Medicine, 370(17), 1583–1593. <https://doi.org/10.1056/NEJMoa1312173>

Bakator, M., & Radosav, D. (2018). Deep Learning and Medical Diagnosis: A Review of Literature. *Multimodal Technologies and Interaction*, 2(3), 47. <https://doi.org/10.3390/mti2030047>

Bengio, Y. (2012). Practical Recommendations for Gradient-Based Training of Deep Architectures. Lecture Notes in Computer Science, 7700, 437–478. [https://doi.org/10.1007/978-3-642-35289-8\\_26](https://doi.org/10.1007/978-3-642-35289-8_26)

BYJUS. (2024). Linear Interpolation Formula with Solved Examples. ค้นเมื่อ 30 กันยายน 2567, จาก <https://byjus.com/linear-interpolation-formula/>

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). **CRISP-DM 1.0: Step-by-step data mining guide**. SPSS Inc.

Chengz. (2019). วัดประสิทธิภาพ Model จาก Confusion Matrix. ค้นเมื่อ 3 ตุลาคม 2567, จาก <https://medium.com/@cheng3374/วัดประสิทธิภาพ-model-จาก-confusion-matrix-69d391bcd48>

- Cho, T., Sunarya, U., Yeo, M., Hwang, B., Koo, Y. S., & Park, C. (2019). Deep-ACTINet: End-to-End Deep Learning Architecture for Automatic Sleep-Wake Detection Using Wrist Actigraphy. *Electronics*, 8(12), 1461. <https://doi.org/10.3390/electronics8121461>
- Deng, H. F., Sun, M. W., Wang, Y., Zeng, J., Yuan, T., Li, T., Li, D. H., Chen, W., Zhou, P., Wang, Q., & Jiang, H. (2022). Evaluating machine learning models for sepsis prediction: A systematic review of methodologies. *iScience*, 25(1), 103651. <https://doi.org/10.1016/j.isci.2021.103651>
- Drumond, D., Rodrigues, Á. L., Felipe, & Lemos, M. G. (2021, October 1). Models for analysing the economic impact of ore sorting, using ROC curves. <https://doi.org/10.13140/RG.2.2.17668.45441>
- Edelman, D. A., White, M. T., Tyburski, J. G., & Wilson, R. F. (2007). POST-TRAUMATIC HYPOTENSION. *Shock*, 27(2), 134–138. <https://doi.org/10.1097/01.shk.0000239772.18151.18>
- GeeksforGeeks. (2023). Long ShortTerm Memory Networks Explanation. ค้นเมื่อ 29 กันยายน 2567, จาก <https://www.geeksforgeeks.org/long-short-term-memory-networks-explanation/>
- GIS.D.A. (2024). Field Server ตอนที่ 5: การ Interpolation และ การ Smooth กราฟชีพลักษณ์พีซพรอน. ค้นเมื่อ 30 กันยายน 2567, จาก [https://www.giS.D.a.or.th/news\\_view.php?n\\_id=2394&lang=TH](https://www.giS.D.a.or.th/news_view.php?n_id=2394&lang=TH)
- Groenwold, R. H. H., Donders, A. R. T., van der Heijden, G. J., Hoes, A. W., & Rovers, M. M. (2012). Missing covariate data in clinical research: when and when not to use the missing-indicator method for analysis. *CMAJ*, 184(11), 1265-1269. <https://doi.org/10.1503/cmaj.110977>
- Gu, J., Wang, Z., Kuen, J., Ma, L., Shahroudy, A., Shuai, B., Liu, T., Wang, X., Wang, G., Cai, J., & Chen, T. (2018). Recent advances in convolutional neural networks. *Pattern Recognition*, 77, 354–377. <https://doi.org/10.1016/j.patcog.2017.10.013>
- Han, K., Wang, Y., Chen, H., Chen, X., Guo, J., Liu, Z., Tang, Y., Xiao, A., Xu, C., Xu, Y., Yang, Z., Zhang, Y., & Tao, D. (2022). A Survey on Vision Transformer. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(1), 1–1. <https://doi.org/10.1109/tpami.2022.3152247>
- He, K., Zhang, X., Ren, S., & Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. Proceedings of the IEEE International Conference on Computer Vision, 1026-1034.

- Hochreiter, S., & Schmidhuber, J. (1997). **Long short-term memory**. Neural Computation, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Huang, G. (2021). **Missing data filling method based on linear interpolation and lightgbm**. Journal of Physics: Conference Series, 1754(1), 012187. <https://doi.org/10.1088/1742-6596/1754/1/012187>
- Kalman, B. L., & Kwasny, S. C. (1992). **Why tanh: choosing a sigmoidal function**. International Joint Conference on Neural Networks.
- Kanyawee Pornsawangdee. (2021). **ทำความเข้าใจ Transformer Architecture แบบง่ายๆกันเถอะ**. ค้นเมื่อ 29 กันยายน 2567, จาก <https://kamkanyawee.medium.com/transformer-architecture-39cce176a2d6>
- Khandelwal, R. (2019). **Neural Networks -Activation functions**. ค้นเมื่อ 29 กันยายน 2567, จาก <https://arshren.medium.com/neural-networks-activation-functions-e371202b56ff>
- Kiranyaz, S., Avci, O., Abdeljaber, O., Ince, T., Gabbouj, M., & Inman, D. J. (2021). **1D convolutional neural networks and applications: A survey**. Mechanical Systems and Signal Processing, 151, 107398. <https://doi.org/10.1016/j.ymssp.2020.107398>
- Kumar, A., Roberts, D., Wood, K. E., Light, B., Parrillo, J. E., Sharma, S., Suppes, R., Feinstein, D., Zanotti, S., Taiberg, L., Gurka, D., Kumar, A., & Cheang, M. (2006). **Duration of hypotension before initiation of effective antimicrobial therapy is the critical determinant of survival in human septic shock**. Critical Care Medicine, 34(6), 1589–1596. <https://doi.org/10.1097/01.ccm.0000217961.75225.e9>
- Lamontagne, F., Rochwerg, B., Lytvyn, L., Guyatt, G., Møller, M. H., Annane, D., Kho, M., Adhikari, N., Machado, F., Vandvik, P., Dodek, P., Leboeuf, R., Briel, M., Hashmi, M., Camsooksai, J., Shankar-Hari, M., Baraki, M. K., Fugate, K., Chua, S., . . . Siemieniuk, R. (2018). **Corticosteroid therapy for sepsis: a clinical practice guideline**. BMJ, k3284. <https://doi.org/10.1136/bmj.k3284>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). **Deep Learning**. Nature, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Liu, L., & Si, Y.-W. (2022). **1D convolutional neural networks for chart pattern classification in financial time series**. The Journal of Supercomputing, 78(12), 14191–14214.

<https://doi.org/10.1007/s11227-022-04431-5>

Luo, R., Gong, M., & Li, C. (2023). **PT3: A Transformer-based model for sepsis death risk prediction via vital signs time series.** In Proceedings of the 2023 International Joint Conference on Neural Networks (IJCNN) (pp. 1–8). IEEE.

Lundberg, S. M., & Lee, S.-I. (2017). **A unified approach to interpreting model predictions.** Advances in Neural Information Processing Systems, 30, 4765–4774.

Marik, P. E., & Taeb, A. M. (2017). **SIRS, qSOFA and new sepsis definition.** Journal of Thoracic Disease, 9(4), 943–945. <https://doi.org/10.21037/jtd.2017.03.125>

MIMIC-III Clinical Database v1.4. (2016). **MIMIC-III Clinical Database.** ค้นเมื่อ 1 ตุลาคม 2567, จาก <https://physionet.org/content/mimiciii/1.4/>

Narkhede, S. (2018). **Understanding AUC - ROC Curve.** ค้นเมื่อ 3 ตุลาคม 2567, จาก <https://towardsdatascience.com/understanding-auc-roc-curve-68b2303cc9c5>

Natthawat Phongchit. (2018). **Convolutional Neural Network (CNN) คืออะไร.** ค้นเมื่อ 12 กันยายน 2567, จาก <https://medium.com/@natthawatphongchit/มาลองดูวิธีการคิดของ-cnn-กัน-e3f5d73eebaa>

Nelson, D. (2020). **RNN และ LSTM ใน Deep Learning คืออะไร.** ค้นเมื่อ 29 กันยายน 2567, จาก <https://www.unite.ai/th/what-are-rnns-and-lstms-in-deep-learning/>

Nickson, C. (2020, November 3). **Sepsis Definitions and Diagnosis.** ค้นเมื่อ 11 กันยายน 2567, จาก <https://litfl.com/sepsis-definitions-and-diagnosis/>

Ospina-Tascón, G. A., Teboul, J. L., Hernandez, G., Alvarez, I., Sánchez-Ortiz, A. I., Calderón-Tapia, L. E., Manzano-Nunez, R., Quiñones, E., Madriñan-Navia, H. J., Ruiz, J. E., Aldana, J. L., & Bakker, J. (2020). **Diastolic shock index and clinical outcomes in patients with septic shock.** Annals of Intensive Care, 10(1), 41. <https://doi.org/10.1186/s13613-020-00658-8>

Pagon Gatchalee. (2019). **Confusion Matrix เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย ใน Machine learning.** ค้นเมื่อ 3 ตุลาคม 2567, จาก <https://medium.com/@pagongatchalee/confusion-matrix-เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย-ในmachine-learning-fba6e3f9508c>

- Pasith Thanapatpisarn. (2022). [Fundamental Data Analytics & Data Scientist EP.21] วัดประสิทธิภาพของแบบจำลองด้วย Evaluation Metrics Part 2. ค้นเมื่อ 3 ตุลาคม 2567, จาก <https://datascihaeng.medium.com/evaluation-matrix-part2-a7d83aea6537>
- Pollard, T. J., Johnson, A. E. W., Raffa, J. D., Celi, L. A., Mark, R. G., & Badawi, O. (2018). The eICU Collaborative Research Database, a freely available multi-center database for critical care research. *Scientific Data*, 5(1). <https://doi.org/10.1038/sdata.2018.178>
- Ospina-Tascón, G. A., Teboul, J. L., Hernandez, G., Alvarez, I., Sánchez-Ortiz, A. I., Calderón-Tapia, L. E., Manzano-Nunez, R., Quiñones, E., Madriñan-Navia, H. J., Ruiz, J. E., Aldana, J. L., & Bakker, J. (2020). Diastolic shock index and clinical outcomes in patients with septic shock. *Annals of intensive care*, 10(1), 41. <https://doi.org/10.1186/s13613-020-00658-8>
- Sakr, Y., Jaschinski, U., Wittebole, X., Szakmany, T., Lipman, J., Ñamendys-Silva, S. A., Martin-Loeches, I., Leone, M., Lupu, M. N., Vincent, J. L., & ICON Investigators. (2018). Sepsis in intensive care unit patients: Worldwide data from the intensive care over nations audit. *Open Forum Infectious Diseases*, 5(12), ofy313. <https://doi.org/10.1093/ofid/ofy313>
- Saxena, A. (2023, January 3). Recurrent Neural Networks (RNNs) - Analytics Vidhya - Medium. Medium. ค้นเมื่อ 9 ตุลาคม 2567, จาก <https://medium.com/@archit.saxena/recurrent-neural-network-rnn-92faf7c01fd4>
- Seymour, C. W., Liu, V. X., Iwashyna, T. J., Brunkhorst, F. M., Rea, T. D., Scherag, A., Rubenfeld, G., Kahn, J. M., Shankar-Hari, M., Singer, M., Deutschman, C. S., Escobar, G. J., & Angus, D. C. (2016). Assessment of Clinical Criteria for Sepsis. *JAMA*, 315(8), 762-774. <https://doi.org/10.1001/jama.2016.0288>
- Shankar-Hari, M., Phillips, G. S., Levy, M. L., Seymour, C. W., Liu, V. X., Deutschman, C. S., Angus, D. C., Rubenfeld, G. D., & Singer, M. (2016). Developing a New Definition and Assessing New Clinical Criteria for Septic Shock. *JAMA*, 315(8), 775-787. <https://doi.org/10.1001/jama.2016.0289>
- Sharma, S. (2017). Activation Functions in Neural Networks. Medium; Towards Data Science. ค้นเมื่อ 29 กันยายน 2567, จาก <https://towardsdatascience.com/activation-functions-neural-networks-1cbd9f8d91d6>

- Shearer, C. (2000). **The CRISP-DM model: The new blueprint for data mining.** Journal of Data Warehousing, 5(4), 13–22.
- Singer, M., Deutschman, C. S., Seymour, C. W., Shankar-Hari, M., Annane, D., Bauer, M., Bellomo, R., Bernard, G. R., Chiche, J. D., Coopersmith, C. M., Hotchkiss, R. S., Levy, M. M., Marshall, J. C., Martin, G. S., Opal, S. M., Rubenfeld, G. D., Van der Poll, T., Vincent, J. L., & Angus, D. C. (2016). **The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3).** JAMA, 315(8), 801-810. <https://doi.org/10.1001/jama.2016.0287>
- Stasko, J. (2013). Time Series Data. Georgia Institute of Technology. ค้นเมื่อ 6 ตุลาคม 2567, จาก <https://faculty.cc.gatech.edu/~stasko/7450/13/Notes/time.pdf>
- Surapong Kanoktipsatharporn. (2019). Recurrent Neural Network (RNN) คืออะไร Gated Recurrent Unit (GRU) คืออะไร สอนสร้าง RNN ถึง GRU ด้วยภาษา Python – NLP ep.9. ค้นเมื่อ 26 กันยายน 2567, จาก <https://www.bualabs.com/archives/3103/what-is-rnn-recurrent-neural-network-what-is-gru-gated-recurrent-unit-teach-how-to-build-rnn-gru-with-python-nlp-ep-9/>
- Tang, Y., Zhang, Y., & Li, J. (2024). A time series driven model for early sepsis prediction based on transformer module. BMC Medical Research Methodology, 24 (1) . <https://doi.org/10.1186/s12874-023-02138-6>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. ArXiv. <https://arxiv.org/abs/1706.03762>
- Verpalen, J. (2019). Predicting player movements in soccer using Deep Learning A comparative study between LSTM and GRU on a real-life sports case. ค้นเมื่อ 9 ตุลาคม 2567, จาก <https://arno.uvt.nl/show.cgi?fid=148968>
- Vincent, J. L., & De Backer, D. (2013). Circulatory shock. The New England Journal of Medicine, 369(18), 1726-1734. <https://doi.org/10.1056/NEJMra1208943>
- Wen, Q., Zhou, T., Zhang, C., Chen, W., Ma, Z., Yan, J., & Sun, L. (2023). Transformers in Time Series: A Survey. ArXiv. <https://doi.org/10.48550/arXiv.2202.07125>
- White, I. R., & Thompson, S. G. (2005). Adjusting for partially missing baseline measurements in randomized trials. Statistics in Medicine, 24(7), 993–1007. <https://doi.org/10.1002/sim.1981>

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. In Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39).

World Health Organization. (2024). **Sepsis**. ค้นเมื่อ 19 กันยายน 2567, จาก <https://www.who.int/news-room/fact-sheets/detail/sepsis>

## ภาคผนวก

ภาคผนวก ก

ตัวแปรอิสระ

ตาราง ก.1 ตัวแปรอิสระ

ชื่อตัวแปร	แหล่งที่มาของตัวแปร	คำอธิบาย
Age	ข้อมูลผู้ป่วย (Admission Info)	อายุ
Sex	ข้อมูลผู้ป่วย (Admission Info)	เพศ
weight	ข้อมูลประวัติการรักษา (Redcap)	น้ำหนัก
height	ข้อมูลประวัติการรักษา (Redcap)	ส่วนสูง
BMI	ข้อมูลประวัติการรักษา (Redcap)	ดัชนีมวลกาย
lactate 24h	ข้อมูลประวัติการรักษา (Redcap)	ค่า lactate ล่าสุด 24 ชั่วโมง
CKD	ข้อมูลประวัติการรักษา (Redcap)	โรคไตเรื้อรัง
AKI	ข้อมูลประวัติการรักษา (Redcap)	ภาวะไตวายเนียบพลัน
RRT	ข้อมูลประวัติการรักษา (Redcap)	มีการบำบัดทดแทนไต
SOFA	ข้อมูลประวัติการรักษา (Redcap)	คะแนนแบบประเมินการล้มเหลวของอวัยวะ
cci total	ข้อมูลประวัติการรักษา (Redcap)	ผลรวมค่า charlson comorbidity index
Apache III	ข้อมูลประวัติการรักษา (Redcap)	ค่าคะแนน APACHE-III
SAP II	ข้อมูลประวัติการรักษา (Redcap)	ค่าคะแนน SAP II
SETTING FIO2	ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)	ค่าความเข้มข้นของออกซิเจนจากเครื่องช่วยหายใจ
LIVE Tidal Volume	ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)	ปริมาตรหายใจเข้าออกปกติ
LIVE RR	ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)	อัตราการหายใจ
Temp	ข้อมูลผลตรวจทางห้องปฏิบัติการ (Bedccr)	อุณหภูมิร่างกาย
IO 24hr	ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	ปริมาณการรับสารน้ำ - ปริมาณสารน้ำออก ทั้งหมดของวันนั้น
Total Intake 24hr	ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	ปริมาณการรับสารน้ำทั้งหมดของวันนั้น
Total Output 24hr	ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	ปริมาณสารน้ำออกทั้งหมดของวันนั้น

ชื่อตัวแปร	แหล่งที่มาของตัวแปร	คำอธิบาย
Total Intake ORAL	ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	ปริมาณการรับสารผ่านทางปาก
Total Intake IV	ข้อมูลบันทึกสมดุลสารน้ำ (Intake Output)	ปริมาณการรับสารผ่านการฉีดเข้าเส้นเลือด
HR	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	อัตราการเต้นของหัวใจ
RR	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	อัตราการหายใจ
BP SYS	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	ความดันโลหิตขณะหัวใจบีบตัว
BP DIA	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	ความดันโลหิตขณะหัวใจคลายตัว
BP TYPE	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	ประเภทการวัดค่าความดันโลหิต
MAP	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	ค่าความดันโลหิตหลอดเลือดแดงเฉลี่ย
O2SAT	ข้อมูลบันทึกสัญญาณชีพ (Bedmonitor track)	ความเข้มข้นของออกซิเจนในเลือด
DSI	Feature engineering	ดัชนีชี้อักไดแอสโตลิก (Diastolic Shock Index)
SI	Feature engineering	ดัชนีชี้อัก (Shock Index)
MSI	Feature engineering	ดัชนีชี้อักแบบดัดแปลง (Modified Shock Index)
ASI	Feature engineering	ดัชนีชี้อักแบบปรับ (Adjusted Shock Index)
AMSI	Feature engineering	ดัชนีชี้อักแบบปรับตามอายุ (Age Modified Shock Index)
RASI	Feature engineering	ดัชนีชี้อักแบบปรับตามการหายใจ (Respiratory Adjusted Shock Index)

ภาคผนวก ข

ผลิติที่ใช้ในการวิจัย

## ผลการทดสอบทางสถิติด้วย SciPy

### 1. การทดสอบการแจกแจงแบบปกติของตัวแปรอิสระของกลุ่มผู้ป่วยที่ซื้อและไม่ซื้อ

```

1 from scipy.stats import kstest
2 normality_results = []
3 for feature in cont_features:
4     for shock_val in [0, 1]:
5         data = concat_EDA.loc[concat_EDA["shock"] == shock_val, feature].dropna()
6         # หากข้อมูลมีจำนวนตัวอย่างไม่ถือกว่า 3 ตัวจะงดทำการทดสอบได้
7         if len(data) >= 3:
8             stat, p = shapiro(data)
9             ks_stat, ks_p = kstest(data, 'norm')
10        else:
11            stat, p = (None, None)
12        normality_results.append({
13            "Feature": feature,
14            "shock": shock_val,
15            "Kolmogorov-Smirnov Statistic": ks_stat,
16            "KS p-value": ks_p,
17            "Shapiro Statistic": stat,
18            "p-value": p
19        })
20 normality_df = pd.DataFrame(normality_results)
21
460] ✓ 0.0s

```

```

1 print(tabulate(normality_df, headers=normality_df.columns, tablefmt='grid', showindex=False))
461] ✓ 0.0s
```
+-----+-----+-----+-----+-----+-----+
| Feature | shock | Kolmogorov-Smirnov Statistic | KS p-value | Shapiro Statistic | p-value |
+-----+-----+-----+-----+-----+-----+
| Age    | 0    | 1               | 0           | 0.936434   | 3.62544e-05 |
+-----+-----+-----+-----+-----+-----+
| Age    | 1    | 1               | 0           | 0.955553   | 7.33966e-10 |
+-----+-----+-----+-----+-----+-----+

```

ภาพที่ ช.1 การทดสอบการแจกแจงแบบปกติของข้อมูลคงที่ในผู้ป่วยที่ซื้อและไม่ซื้อ

```

1 from scipy.stats import kstest
2 normality_results = []
3 for feature in cont_features:
4     for shock_val in [0, 1]:
5         data = concat_EDA.loc[concat_EDA["shock"] == shock_val, feature].dropna()
6         # หากมีข้อมูลจำนวนต่ำกว่า 3 ตัวจะไม่สามารถทดสอบได้
7         if len(data) >= 3:
8             stat, p = shapiro(data)
9             ks_stat, ks_p = kstest(data, 'norm')
10        else:
11            stat, p = (None, None)
12    normality_results.append({
13        "Feature": feature,
14        "shock": shock_val,
15        "Kolmogorov-Smirnov Statistic": ks_stat,
16        "KS p-value": ks_p,
17        "Shapiro Statistic": stat,
18        "p-value": p
19    })
20 normality_df = pd.DataFrame(normality_results)
21
[487] ✓ 0.0s

```

```

1 print(tabulate(normality_df, headers=normality_df.columns, tablefmt='grid', showindex=False))
[488] ✓ 0.0s
...
+-----+-----+-----+-----+-----+-----+
| Feature | shock | Kolmogorov-Smirnov Statistic | KS p-value | Shapiro Statistic | p-value |
+-----+-----+-----+-----+-----+-----+
| sap_2_red | 0 | 1 | 0 | 0.970385 | 0.0118928 |
+-----+-----+-----+-----+-----+-----+
| sap_2_red | 1 | 1 | 0 | 0.956949 | 1.17317e-09 |
+-----+-----+-----+-----+-----+-----+
| cci_total_red | 0 | 0.829424 | 3.34946e-88 | 0.960951 | 0.00199641 |
+-----+-----+-----+-----+-----+-----+
| cci_total_red | 1 | 0.895322 | 0 | 0.964277 | 1.62816e-08 |
+-----+-----+-----+-----+-----+-----+
| lactate_24h_red | 0 | 0.999991 | 0 | 0.666037 | 8.19843e-15 |
+-----+-----+-----+-----+-----+-----+
| lactate_24h_red | 1 | 0.99865 | 0 | 0.728996 | 1.94775e-25 |
+-----+-----+-----+-----+-----+-----+
| apache_3_red | 0 | 1 | 0 | 0.984638 | 0.213778 |
+-----+-----+-----+-----+-----+-----+
| apache_3_red | 1 | 1 | 0 | 0.958261 | 1.8394e-09 |
+-----+-----+-----+-----+-----+-----+
| height_red | 0 | 1 | 0 | 0.982421 | 0.13682 |
+-----+-----+-----+-----+-----+-----+
| height_red | 1 | 1 | 0 | 0.986347 | 0.000609356 |
+-----+-----+-----+-----+-----+-----+
| bmi_red | 0 | 1 | 0 | 0.952707 | 0.00047173 |
+-----+-----+-----+-----+-----+-----+
| bmi_red | 1 | 1 | 0 | 0.945282 | 3.0071e-11 |
+-----+-----+-----+-----+-----+-----+
| sofa_red | 0 | 0.846815 | 8.38314e-94 | 0.965096 | 0.00429594 |
+-----+-----+-----+-----+-----+-----+
| sofa_red | 1 | 0.955563 | 0 | 0.94632 | 4.077e-11 |
+-----+-----+-----+-----+-----+-----+
| weight_red | 0 | 1 | 0 | 0.950254 | 0.000313182 |
+-----+-----+-----+-----+-----+-----+
| weight_red | 1 | 1 | 0 | 0.913204 | 1.0607e-14 |
+-----+-----+-----+-----+-----+-----+

```

ภาพที่ ช.2 การทดสอบการแจกแจงแบบปกติของข้อมูลรายวันในผู้ป่วยที่ซื้อคิลและไม่ซื้อคิล

| Feature              | shock | Kolmogorov-Smirnov Statistic | KS p-value   | Shapiro Statistic | p-value     |
|----------------------|-------|------------------------------|--------------|-------------------|-------------|
| IO_24hr_in           | 0     | 0.565217                     | 3.28488e-35  | 0.9944            | 0.928159    |
| IO_24hr_in           | 1     | 0.761446                     | 1.84699e-251 | 0.964862          | 2.03621e-08 |
| TotalIntake_24hr_in  | 0     | 1                            | 0            | 0.92784           | 1.06247e-05 |
| TotalIntake_24hr_in  | 1     | 1                            | 0            | 0.928858          | 3.77711e-13 |
| TotalOoutput_24hr_in | 0     | 0.991304                     | 2.09304e-237 | 0.935813          | 3.30894e-05 |
| TotalOoutput_24hr_in | 1     | 1                            | 0            | 0.931456          | 7.19003e-13 |
| TotalIntake_ORAL_in  | 0     | 0.93913                      | 3.21419e-140 | 0.953921          | 0.000579582 |
| TotalIntake_ORAL_in  | 1     | 0.843373                     | 0            | 0.868522          | 2.99111e-18 |
| TotalIntake_IV_in    | 0     | 0.991304                     | 2.09304e-237 | 0.871088          | 1.44186e-08 |
| TotalIntake_IV_in    | 1     | 0.995181                     | 0            | 0.933206          | 1.11965e-12 |

ภาพที่ ข.3 การทดสอบการแจกแจงแบบปกติของข้อมูลรายวันของผู้ป่วยที่ซื้อและไม่ซื้อ (ต่อ)

## 2. การทดสอบ Chi-square ของตัวแปรเชิงกลุ่มในผู้ป่วยที่ซื้อและไม่ซื้อ

```

1 chi_results = []
2
3 for feature in cate_feature:
4     # สร้าง contingency table จากข้อมูล
5     contingency = pd.crosstab(concat_EDA["shock"], concat_EDA[feature])
6     # ทดสอบ chi-square
7     chi2, p, dof, expected = chi2_contingency(contingency, correction=False)
8     chi_results.append({
9         "Feature": feature,
10        "Chi2 Statistic": chi2,
11        "Degrees of Freedom": dof,
12        # "Expected value" : expected,
13        "p-value": p
14    })
15 chi_df = pd.DataFrame(chi_results)
16
17 0.05

```

```

1
2 print(tabulate(chi_df, headers=chi_df.columns, tablefmt='grid', showindex=False))
3 0.05

```

| Feature | Chi2 Statistic | Degrees of Freedom | p-value  |
|---------|----------------|--------------------|----------|
| Sex     | 0.0677406      | 1                  | 0.794655 |

ภาพที่ ข.4 การทดสอบความสัมพันธ์ของข้อมูลเชิงกลุ่มคงที่ของผู้ป่วยที่ซื้อและไม่ซื้อ

```

1 chi_results = []
2 # สมมติว่า cate_static เป็นรายชื่อคอลัมน์ที่เป็น categorical ใน concat_EDA
3 for feature in cate_feature:
4     # สร้าง contingency table จากข้อมูล
5     contingency = pd.crosstab(concat_EDA["shock"], concat_EDA[feature])
6     # ทดสอบ chi-square
7     chi2, p, dof, expected = chi2_contingency(contingency, correction=False)
8     chi_results.append({
9         "Feature": feature,
10        "Chi2 Statistic": chi2,
11        "Degrees of Freedom": dof,
12        "p-value": p
13    })
14 chi_df = pd.DataFrame(chi_results)
15
485] ✓ 0.0s

```

```

1 print(tabulate(chi_df, headers=chi_df.columns, tablefmt='grid', showindex=False))
486] ✓ 0.0s
...
+-----+-----+-----+-----+
| Feature | Chi2 Statistic | Degrees of Freedom | p-value |
+=====+=====+=====+=====+
| ckd_red | 3.69172 | 1 | 0.0546833 |
+-----+-----+-----+-----+
| aki_red | 64.1717 | 1 | 1.14034e-15 |
+-----+-----+-----+-----+
| rrt_red | 36.3569 | 1 | 1.64295e-09 |
+-----+-----+-----+-----+

```

ภาพที่ ข.5 การทดสอบความสัมพันธ์ของข้อมูลเชิงกลุ่มรายวันของผู้ป่วยที่ซื้อกและไม่ซื้อก

### 3. การทดสอบค่ากลางของตัวแปรเชิงปริมาณในผู้ป่วยที่ซื้อกและไม่ซื้อก

```

1 mannwhitney_results = []
2 for feature in cont_features:
3     group0 = concat_EDA.loc[concat_EDA["shock"] == 0, feature].dropna()
4     group1 = concat_EDA.loc[concat_EDA["shock"] == 1, feature].dropna()
5     # ใช้ Mann-Whitney U test แบบ two-sided
6     try:
7         stat, p = mannwhitneyu(group0, group1, alternative='two-sided')
8     except Exception as e:
9         stat, p = (None, None)
10    mannwhitney_results.append({
11        "Feature": feature,
12        "Mann-Whitney Statistic": stat,
13        "Non-Shock Median": np.median(group0),
14        "Shock Median": np.median(group1),
15        "p-value": p
16    })
17 mannwhitney_df = pd.DataFrame(mannwhitney_results)
18
464] ✓ 0.0s

```

```

1 print(tabulate(mannwhitney_df, headers=mannwhitney_df.columns, tablefmt='grid', showindex=False))
465] ✓ 0.0s
...
+-----+-----+-----+-----+
| Feature | Mann-Whitney Statistic | Non-Shock Median | Shock Median | p-value |
+=====+=====+=====+=====+
| Age | 19612 | 64 | 67 | 0.0034402 |
+-----+-----+-----+-----+

```

ภาพที่ ข.6 การทดสอบค่ากลางของตัวแปรคงที่เชิงปริมาณในผู้ป่วยที่ซื้อกและไม่ซื้อก

```

▷ 
1 mannwhitney_results = []
2 for feature in cont_features:
3     group0 = concat_EDA.loc[concat_EDA["shock"] == 0, feature].dropna()
4     group1 = concat_EDA.loc[concat_EDA["shock"] == 1, feature].dropna()
5     # ໃຊ້ Mann-Whitney U test ແນ້ນ two-sided
6     try:
7         stat, p = mannwhitneyu(group0, group1, alternative='two-sided')
8     except Exception as e:
9         stat, p = (None, None)
10    mannwhitney_results.append({
11        "Feature": feature,
12        "Mann-Whitney Statistic": stat,
13        "Non-Shock Median": np.median(group0),
14        "Shock Median": np.median(group1),
15        "p-value": p
16    })
17 mannwhitney_df = pd.DataFrame(mannwhitney_results)
18
[491] ✓ 0.0s

1 print(tabulate(mannwhitney_df, headers=mannwhitney_df.columns, tablefmt='grid', showindex=False))
[492] ✓ 0.0s

...
+-----+-----+-----+-----+-----+
| Feature | Mann-Whitney Statistic | Non-Shock Median | Shock Median | p-value |
+-----+-----+-----+-----+-----+
| sap_2_red | 10290 | 34 | 46 | 9.55535e-21 |
+-----+-----+-----+-----+-----+
| cci_total_red | 21633.5 | 5 | 5 | 0.123666 |
+-----+-----+-----+-----+-----+
| lactate_24h_red | 17942.5 | 20.6 | 31 | 4.63206e-05 |
+-----+-----+-----+-----+-----+
| apache_3_red | 10134 | 60 | 86 | 3.47632e-21 |
+-----+-----+-----+-----+-----+
| height_red | 25654 | 163.601 | 163.007 | 0.216652 |
+-----+-----+-----+-----+-----+
| bmi_red | 26739 | 22.86 | 21.9149 | 0.0478038 |
+-----+-----+-----+-----+-----+
| sofa_red | 11691 | 4 | 7 | 4.78841e-17 |
+-----+-----+-----+-----+-----+
| weight_red | 27395 | 61.0268 | 58.6711 | 0.015033 |
+-----+-----+-----+-----+-----+
| IO_24hr_in | 16953.5 | 199.233 | 764.2 | 1.99432e-06 |
+-----+-----+-----+-----+-----+
| TotalIntake_24hr_in | 17366.5 | 1820.85 | 2323.9 | 7.82935e-06 |
+-----+-----+-----+-----+-----+
| TotalOuput_24hr_in | 27133 | 1755 | 1463.5 | 0.0244353 |
+-----+-----+-----+-----+-----+
| TotalIntake_ORAL_in | 27705.5 | 545 | 425 | 0.0081616 |
+-----+-----+-----+-----+-----+
| TotalIntake_IV_in | 17157.5 | 1185.45 | 1871.86 | 3.95717e-06 |
+-----+-----+-----+-----+-----+

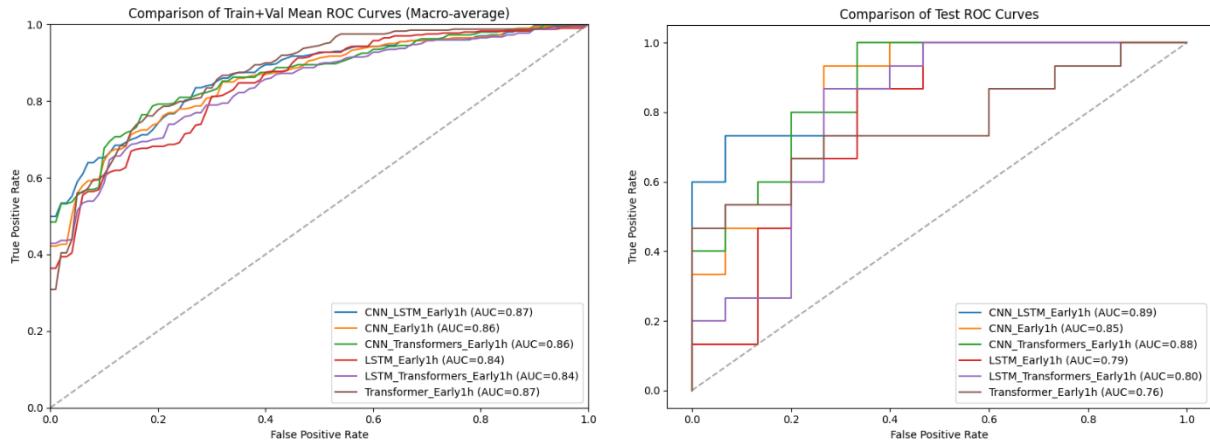
```

ກາພທີ ໜ.7 ກາຮທດສອບຄ່າກລາງຂອງຕັ້ງແປຣຍວັນເຈີງປະມານໃນຜູ້ປ່າຍທີ່ຂົກແລະໄມ້ຂົກ

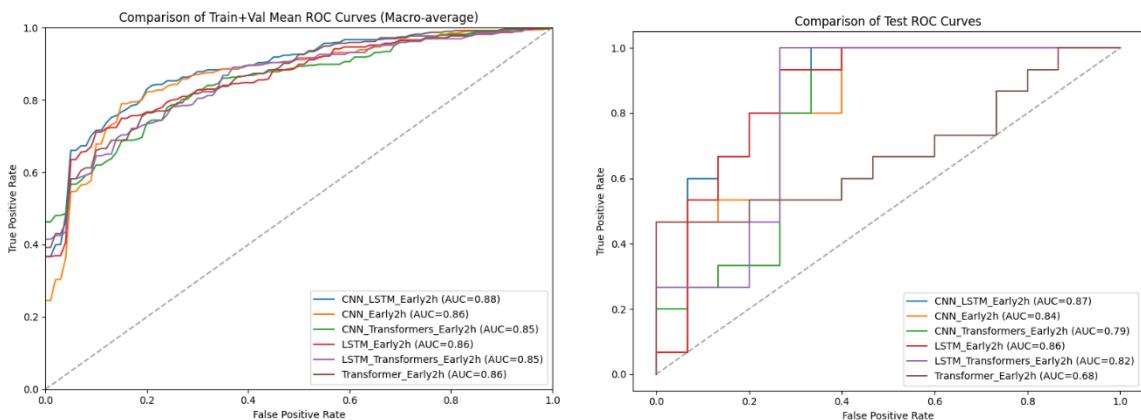
ภาคผนวก ค

ผลการทดสอบแบบจำลอง

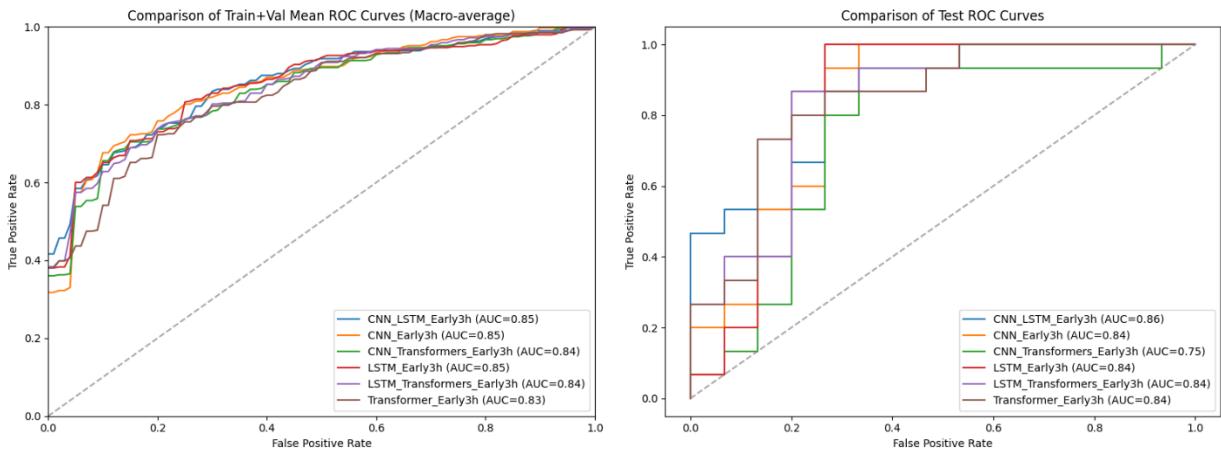
### 1. ผลการฝึกสอนและทดสอบแบบจำลองเพื่อทำนายล่วงหน้า 1, 2 และ 3 ชั่วโมง



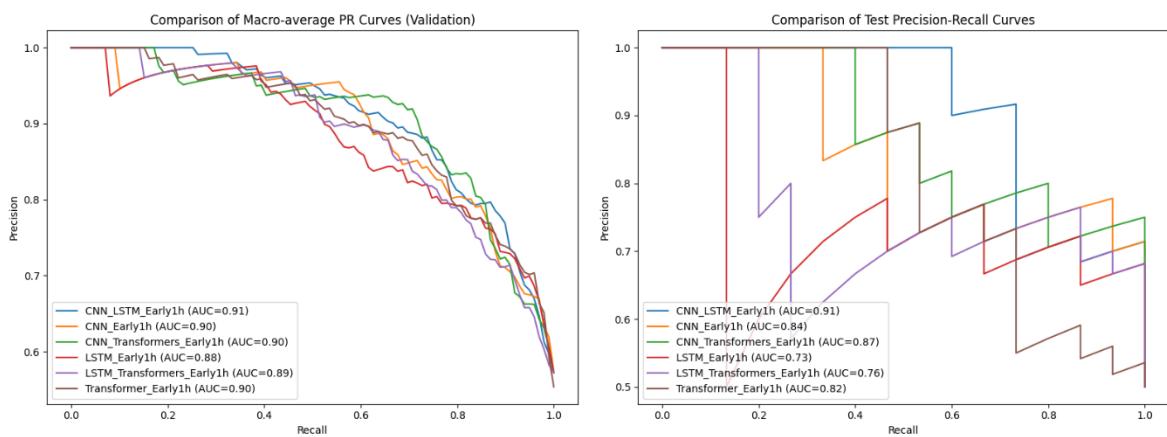
ภาพที่ ค.1 กราฟ AUC-ROC ของการฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อในอีก 1 ชั่วโมง



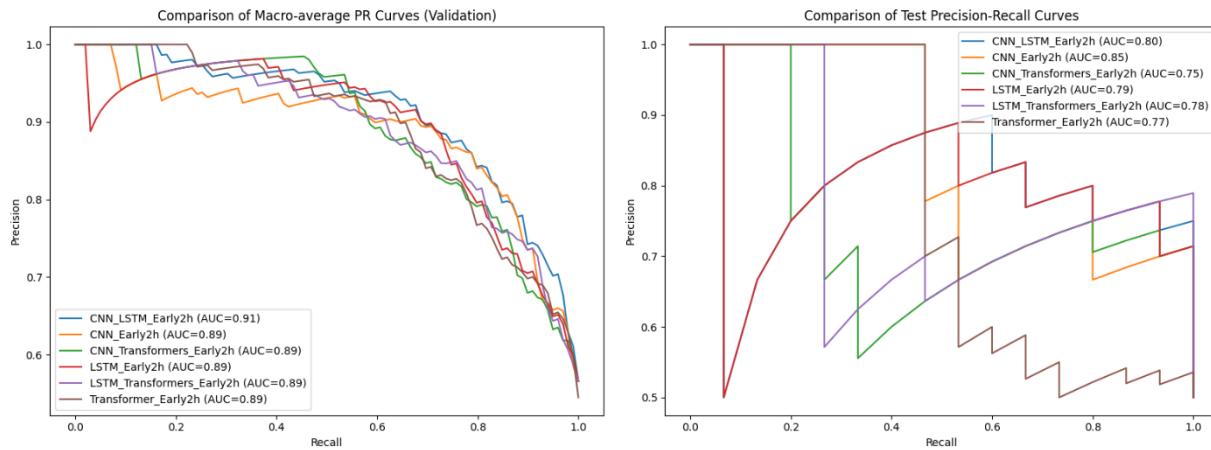
ภาพที่ ค.2 กราฟ AUC-ROC การฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อในอีก 2 ชั่วโมง



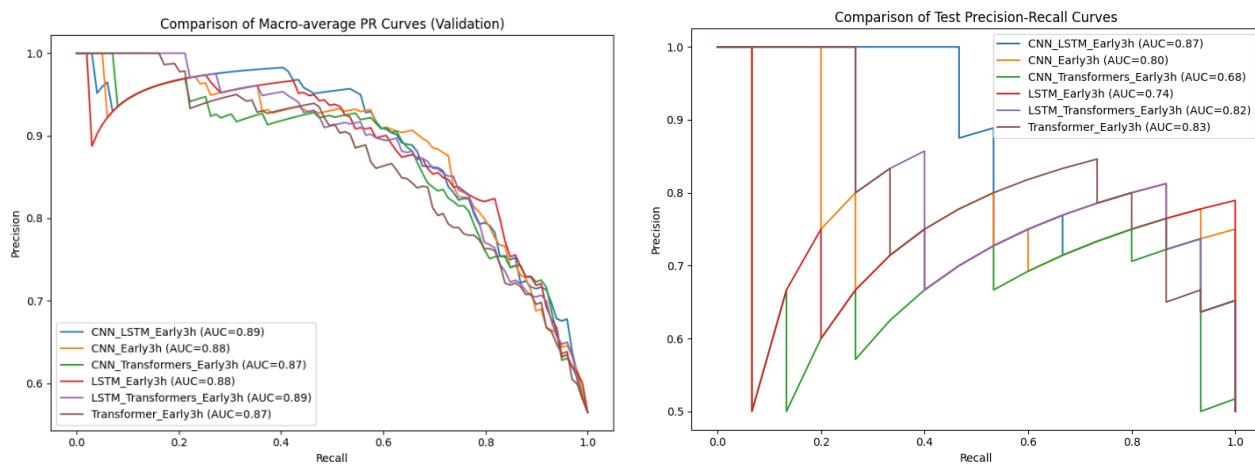
ภาพที่ ค.3 กราฟ AUC-ROC ของการฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อกินอีก 3 ชั่วโมง



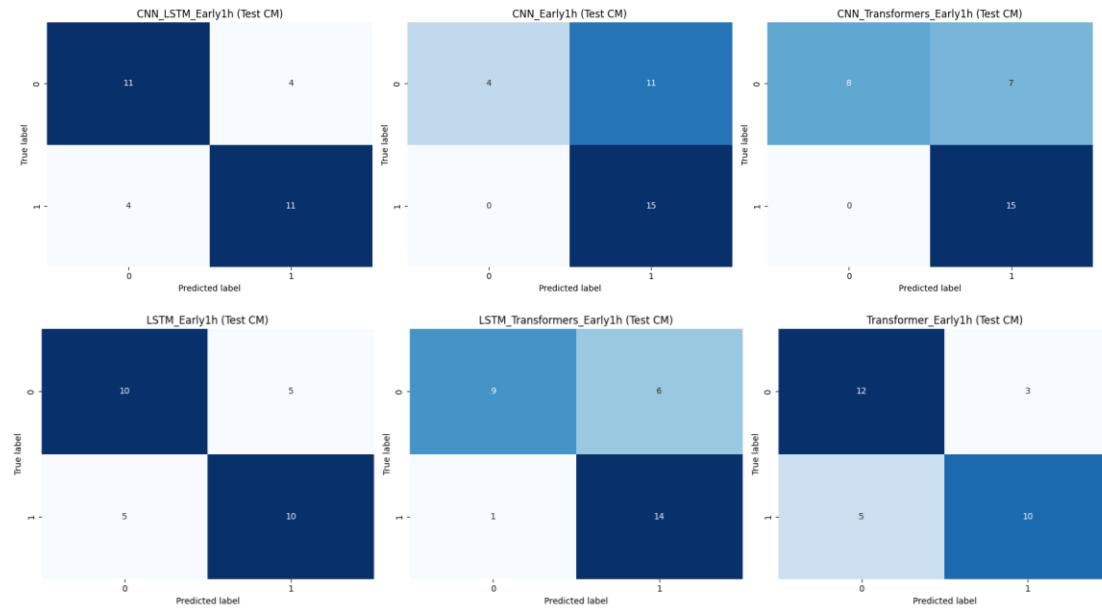
ภาพที่ ค.4 กราฟ AUC-PR ของการฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อกินอีก 1 ชั่วโมง



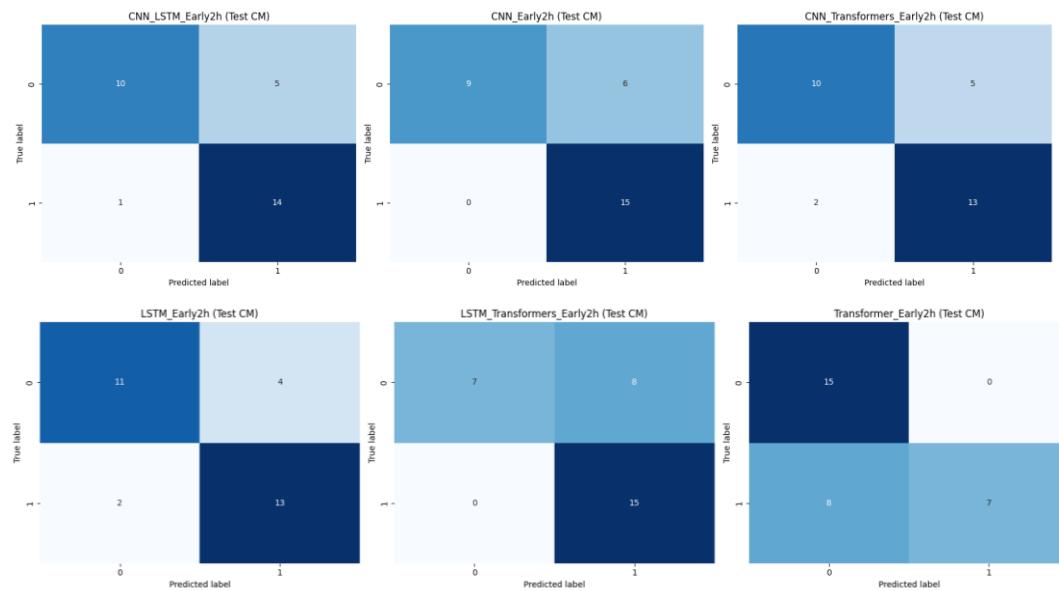
ภาพที่ ค.5 กราฟ AUC-PR ของการฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อในอีก 2 ชั่วโมง



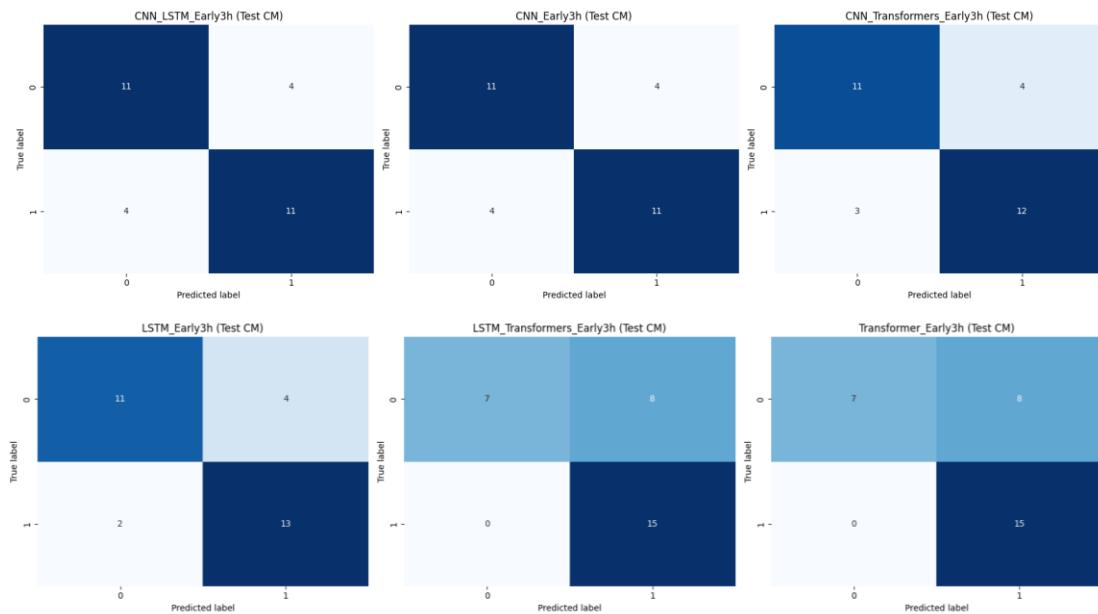
ภาพที่ ค.6 กราฟ AUC-PR ของการฝึกและทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อในอีก 3 ชั่วโมง



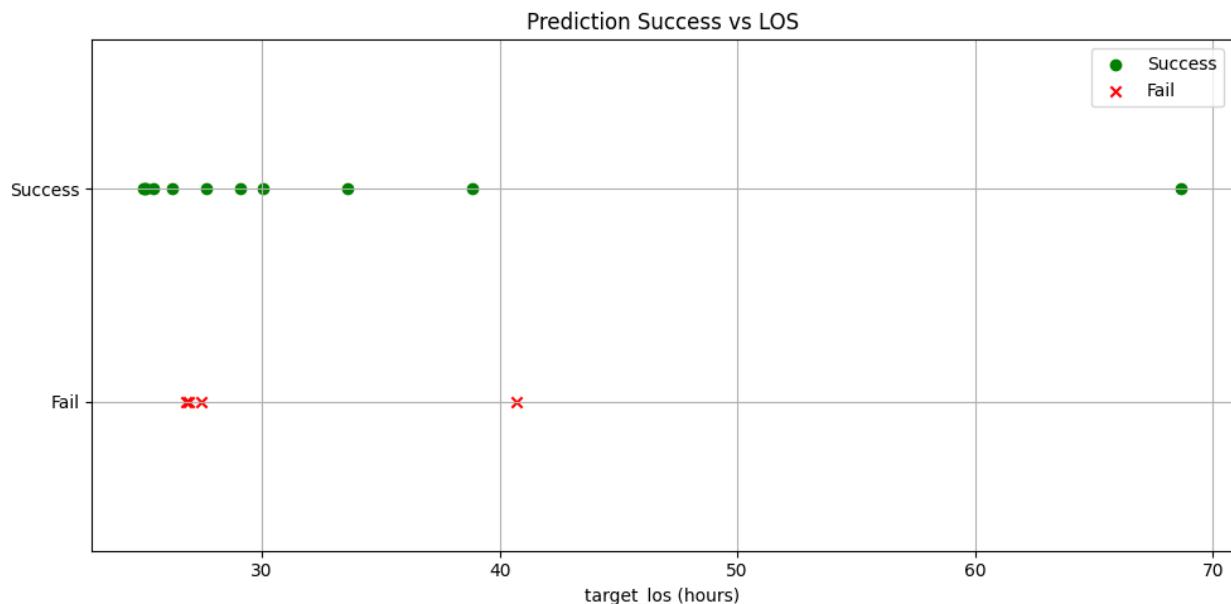
ภาพที่ C.7 confusion matrix ของการทดสอบของแต่ละแบบจำลองในการทำนายภาวะซึ่งกันในวีก 1 ชั่วโมง



ภาพที่ C.8 confusion matrix ของการทดสอบของแต่ละแบบจำลองในการทำนายภาวะซึ่งกันในวีก 2 ชั่วโมง



ภาพที่ ค.9 confusion matrix ของการทดสอบของแต่ละแบบจำลองในการทำนายภาวะซื้อกินอีก 3 ชั่วโมง



ภาพที่ ค.10 การทำนายคนที่ซื้อกว่าเป็นซื้อกจริงและซื้อกไม่จริง ตลอดระยะเวลาการเข้ามาใน ICU

ภาคผนวก ๔

ตารางการดำเนินการวิจัย

| ขั้นตอนการดำเนินงาน                                     | พ.ศ. 2567 |   |   |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
|---------------------------------------------------------|-----------|---|---|---|---------|---|---|---|---------|---|---|---|---------|---|---|---|--------|---|---|---|
|                                                         | มิถุนายน  |   |   |   | กรกฎาคม |   |   |   | สิงหาคม |   |   |   | กันยายน |   |   |   | ตุลาคม |   |   |   |
|                                                         | 1         | 2 | 3 | 4 | 1       | 2 | 3 | 4 | 1       | 2 | 3 | 4 | 1       | 2 | 3 | 4 | 1      | 2 | 3 | 4 |
| 1. กำหนดหัวข้อโครงการ และขอบเขตการดำเนินการ             | ●         | ● |   |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 2. ศึกษาวรรณกรรม และงานวิจัยที่เกี่ยวข้อง               |           | ● | ● |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 3. ทำความ深ด้วยข้อมูลและเตรียมข้อมูลสำหรับใช้สร้างตัวแบบ |           |   |   |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.1 ทำความเข้าใจข้อมูล                                  |           |   |   | ● |         |   |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.2 รวมข้อมูลจากหลาย ๆ ตาราง                            |           |   |   |   | ●       | ● |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.3 เลือกตัวแปร (feature)                               |           |   |   |   |         | ● |   |   |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.4 จัดการค่าผิดปกติ และค่าอนอก敦์                       |           |   |   |   |         |   | ● | ● |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.5 จัดการค่าสูญเสีย                                    |           |   |   |   |         |   |   | ● |         |   |   |   |         |   |   |   |        |   |   |   |
| 3.6 ระบุจุดที่เกิดการซื้อของผู้ป่วย                     |           |   |   |   |         |   |   |   | ●       | ● |   |   |         |   |   |   |        |   |   |   |
| 3.7 คัดเลือกช่วงข้อมูล                                  |           |   |   |   |         |   |   |   |         | ● | ● |   |         |   |   |   |        |   |   |   |
| 3.8 จัดการແກນเวลาให้มีมิติเพื่อทำกัน                    |           |   |   |   |         |   |   |   |         | ● | ● |   |         |   |   |   |        |   |   |   |
| 3.9 สร้าง Labels สำหรับทำนาย                            |           |   |   |   |         |   |   |   |         |   | ● | ● |         |   |   |   |        |   |   |   |
| 4. จัดทำเค้าโครงงานวิจัย                                |           |   |   |   |         |   |   |   |         |   |   |   | ●       | ● |   |   |        |   |   |   |
| 4.1 จัดทำบทที่ 1 บทนำ                                   |           |   |   |   |         |   |   |   |         |   |   |   | ●       | ● |   |   |        |   |   |   |
| 4.2 จัดทำบทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง         |           |   |   |   |         |   |   |   |         |   |   |   | ●       | ● |   |   |        |   |   |   |
| 4.3 จัดทำบทที่ 3 วิธีการดำเนินการวิจัย                  |           |   |   |   |         |   |   |   |         |   |   |   |         | ● | ● | ● |        |   |   |   |
| 4.4 เชิญนักเรียนร่วมวิจัย                               |           |   |   |   |         |   |   |   |         |   |   |   |         |   |   |   | ●      | ● |   |   |
| 4.5 นำเสนอความท้าทาย                                    |           |   |   |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   | ● |   |
| 4.6 นำเสนอเค้าโครงงาน (บทที่ 1-3)                       |           |   |   |   |         |   |   |   |         |   |   |   |         |   |   |   |        |   | ● | ● |

ภาพที่ ๔.1 ตารางการดำเนินการวิจัย

| ขั้นตอนการดำเนินงาน                                                                       | พ.ศ. 2567 |   |   |   |         |   |   |   | พ.ศ. 2568 |   |   |   |            |   |   |   |        |   |   |   |   |
|-------------------------------------------------------------------------------------------|-----------|---|---|---|---------|---|---|---|-----------|---|---|---|------------|---|---|---|--------|---|---|---|---|
|                                                                                           | พฤศจิกายน |   |   |   | ธันวาคม |   |   |   | มกราคม    |   |   |   | กุมภาพันธ์ |   |   |   | มีนาคม |   |   |   |   |
|                                                                                           | 1         | 2 | 3 | 4 | 1       | 2 | 3 | 4 | 1         | 2 | 3 | 4 | 1          | 2 | 3 | 4 | 1      | 2 | 3 | 4 |   |
| 7. สร้างตัวแบบ ทดสอบ และปรับปรุงการทำงานนายชื่อ มูลด้วยการเรียนรู้เชิงลึก (Deep Learning) |           |   |   |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.1 ปรับมาตรฐานข้อมูล (Standardization)                                                   | ■         |   |   |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.2 สร้างข้อมูลนำเข้า                                                                     | ■         |   |   |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.3 แบ่งชุดข้อมูลฝึกสอนและข้อมูลทดสอบ                                                     | ■         |   |   |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.4 สร้างและฝึกสอนตัวแบบ CNN                                                              |           | ■ | ■ |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.5 สร้างและฝึกสอนตัวแบบ LSTM                                                             |           |   |   | ■ | ■       | ■ |   |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.6 สร้างและฝึกสอนตัวแบบ Transformer                                                      |           |   |   |   | ■       | ■ | ■ |   |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.7 สร้างและฝึกสอนตัวแบบ CNN + LSTM                                                       |           |   |   |   |         | ■ | ■ | ■ |           |   |   |   |            |   |   |   |        |   |   |   |   |
| 7.8 สร้างและฝึกสอนตัวแบบ CNN + Transformer                                                |           |   |   |   |         |   | ■ | ■ | ■         | ■ |   |   |            |   |   |   |        |   |   |   |   |
| 7.9 สร้างและฝึกสอนตัวแบบ LSTM + Transformer                                               |           |   |   |   |         |   |   | ■ | ■         | ■ |   |   |            |   |   |   |        |   |   |   |   |
| 7.10 ประเมินผลและปรับปรุงตัวแบบ                                                           |           |   |   |   |         |   |   |   | ■         | ■ | ■ |   |            |   |   |   |        |   |   |   |   |
| 7.11 นำตัวแบบมาท่านายชื่อ มูลทดสอบและวิเคราะห์ผล                                          |           |   |   |   |         |   |   |   |           | ■ | ■ | ■ |            |   |   |   |        |   |   |   |   |
| 9. จัดทำบทที่ 4 ผลการวิจัย                                                                |           |   |   |   |         |   |   |   |           |   |   | ■ | ■          |   |   |   |        |   |   |   |   |
| 10 จัดทำบทที่ 5 สรุปและอภิปรายผล                                                          |           |   |   |   |         |   |   |   |           |   |   |   | ■          | ■ | ■ |   |        |   |   |   |   |
| 11 จัดทำรูปเล่มรายงานฉบับสมบูรณ์                                                          |           |   |   |   |         |   |   |   |           |   |   |   |            | ■ | ■ | ■ | ■      |   |   |   |   |
| 12 นำเสนอโครงงาน                                                                          |           |   |   |   |         |   |   |   |           |   |   |   |            |   |   |   |        |   |   |   | ■ |

ภาพที่ ๔.2 ตารางการดำเนินการวิจัย